

家庭環境知識に基づく行動前提条件の検証を伴う LLM エージェントの逐次的行動計画生成

Sequential Action Planning for LLM Agents with Verification of Action Preconditions Based on Home Environment Knowledge

青山 仁
Jin Aoyama

青山学院大学
Aoyama Gakuin University

チャクラボルティ シュデシナ
Sudesna Chakraborty (同 上)

森田 武史
Takeshi Morita (同 上)
morita@it.aoyama.ac.jp

江上 周作
Shusaku Egami 産業技術総合研究所
National Institute of Advanced Industrial Science and Technology

鵜飼 孝典
Takanori Ugai (同 上)

福田 賢一郎
Ken Fukuda (同 上)

keywords: Task Planning, Large Language Model, Natural Language Processing, Embodied AI, Simulation

Summary

Household action planning requires identifying relevant objects and tracking their states and relations as actions are executed. This study examines a concrete implementation of sequential planning with large language models (LLMs) in VirtualHome. Code extracts object identifiers, states, support and containment relations, and agent relations from simulator graphs and converts them into text. An LLM generates an action, checks natural-language preconditions, and, when it rejects the candidate, identifies unmet conditions and regenerates the action once. The regenerated action is executed without another check. Verification and replanning are not claimed as new planning principles; the contribution is a documented implementation, a task collection, and diagnostic evidence about their limitations.

The collection contains 618 instances with templated instructions and varied initial conditions: 312 state-change and 103 placement test instances, with 203 instances reserved as prompt examples. The evaluation links overall task performance, component comparisons, and case analysis. The overall evaluation covers 18 conditions across the two task categories. GPT-4o with Multi Prompts and verification achieved 279/312 (89.4%) successes for state changes and 84/103 (81.6%) for placement. Success- and failure-specific action lengths characterize execution outcomes, while retrieval analysis examines the similarity between instructions and selected examples.

Component comparisons use four selected tasks, two models, ten conditions, and three repetitions, for a total of 240 episodes with verified initial-state alignment. LLM verification versus no verification yielded 9/12 successes for GPT-4o mini and 8/12 for GPT-4o, and 9/12 successes for Both. Each count includes three successes on an initially completed task. Symbolic checks, post-failure repair, deliberation, and retrieval changes did not establish a uniform advantage. Process logs and case analyses distinguish precondition decisions, erroneous termination, and simulator execution failures. Of eight rejected-candidate replays, only two matched the corresponding decision state under symbolic and transform checks. Human ratings of decision responses did not assess the separately logged explanations for unmet conditions. Differences in task coverage, execution settings, and available records limit comparisons across evaluation components. The findings provide diagnostic evidence, not general superiority, verified explanation quality, or real-world safety.

1. はじめに

近年, Embodied AI [Duan 22] と呼ばれる, 身体性を持つエージェントが現実世界や仮想空間で学習を行

い、多様な物体が存在する複雑な環境でさまざまなタスクを遂行しようとする研究が行われている。例えば、「エージェントが人間のある指示に従って家事（例：掃除、洗濯）をする」、「エージェントが環境の中にある特定の物を見つけて案内を行う」といったタスクが挙げられる。この研究分野では、自然言語の指示に従って、エージェントがタスクを実行するためのタスクプログラミング（行動計画）をするために、大規模言語モデル（Large Language Models, LLMs）を活用することが注目されている [Huang 22, Rana 23, Song 23]。これらの研究により、LLM は日常生活でタスクを実行する上で重要な常識知識を有することが実証されてきた。

LLM を用いて、環境の状況（オブジェクト（物体）の状態や位置、物体間の位置関係）に応じてエージェントの行動を計画する研究も進められている [Lin 23]。このような行動計画を LLM によって実現するためには、LLM に環境の状況を正確に認識させることが課題となる。しかし、環境が広範・複雑であるほど情報量が多くなるため、すべての情報を LLM に認識させることは非現実的である。そのため、必要な情報を絞り込むことが課題となる。

本研究では、既存の家庭内タスクベンチマーク [Puig 18, Shridhar 20] を代替するのではなく、同じ指示に対して初期状態に応じた行動変更が必要となる設定を診断対象とする。例えば“Turn on all lightswitches”では、同名の物体を ID で区別し、ON 済みの物体と OFF の物体を追跡する必要がある。すべて ON なら行動せずに終了する判断も必要となる。指示文だけでは個々の現在状態は決まらないが、これを理由に既存研究が環境状態を扱わない、あるいは同様のタスクが存在しないとは主張しない。

本研究では、物体の状態・ID・関係を家庭環境知識として LLM に提示し、行動を逐次生成する実装を扱う。知識の抽出・自然言語化はコードで行い、この抽出自体には LLM を用いない。LLM が生成候補の前提条件を充足と判定すれば実行し、棄却すれば別要求で未充足条件を尋ね、1 回再生成して再検証せず実行する。したがって全行動の実行可能性を保証するものではない。ここで、行動計画はタスク遂行のための一連の行動、アクションステップは各個別の行動を指す。

提案手法の評価を行うために、本研究では、家庭内での活動を三次元仮想空間内でシミュレートするマルチエージェントプラットフォーム VirtualHome [Puig 18] を用いて、家庭環境の把握が不可欠な家庭内タスクのデータセットを作成する。具体的には、物体の状態に着目した「状態変化タスク」と、物体間の関係に着目した「配置タスク」の 2 種類を対象とする。これらのタスクでは、コンピュータビジョン分野の研究のように、エージェント視点の視覚情報を処理して環境を認識する手法 [Song 23, Kim 23, Nakajima 24] ではなく、

シミュレータの内部から取得したデータを家庭環境知識として用いることを前提とする。また、本研究では、家庭環境知識を LLM に認識させることで、家庭環境知識に基づいた適切な行動計画を生成する手法を提案する。

本論文の貢献は以下の通りである。

- 定型指示の下で同名物体の識別と初期状態に応じた行動変更を扱う、状態変化・配置の計 618 インスタンスの構成と、対象範囲・分割・参照手順の明示。
- 状態・ID・支持／包含関係の抽出と自然言語化、事例検索、LLM による前提条件判定、1 回の再生成、停止・採点を追跡できる具体的実装の仕様化。
- 基本性能評価、構成要素比較、ケース分析を通じて、タスク達成率と行動列長を評価し、判定・再生成・終了・実行の失敗過程を明らかにする診断的知見。

評価は、まず全 415 タスクに対する基本性能を調べ、次に 4 タスク・2 モデル・10 条件・3 反復の 240 エピソードで構成要素の働きを比較し、実行ログとケース分析から結果を解釈する流れで行う。前提条件検証・再計画の一般原理自体の新規性は主張しない。構成要素比較で LLM 検証あり／なしの成功数は GPT-4o mini で 9/12 対 8/12, GPT-4o で 9/12 対 9/12 であり、一律の改善や固有の優位性は確認できなかった。各分母 12 は目的選択した 4 タスクの各 3 反復で、独立な 12 タスクではない。本研究の結論はこの実装と評価範囲に限定する。

本論文の構成は次の通りである。第 2 章では、本研究の関連研究について述べる。第 3 章では、タスク設定とデータセット構築について述べる。第 4 章では、本研究の提案手法とその構成について述べる。第 5 章では、評価実験、結果、考察について述べる。最後に第 6 章では、本研究の結論と今後の課題について述べる。

なお、本論文は、青山らの研究成果 [青山 24, Aoyama 25] を発展させ、基本性能と各構成要素の評価をまとめたものである。提案手法のソースコードとデータセットは GitHub リポジトリにまとめている^{*1}。実験条件、評価手順、結果の解釈に必要な集計値は本文と付録に示す。

2. 関連研究

2.1 LLM を活用した家庭内タスクプログラミング

近年、エージェントが、人間から与えられた自然言語の指示に従って、タスクを実行するための行動計画をすることを目的とした研究分野において、LLM の活用が注目を集めている。LLM の活用には以下の複数の

*1 <https://github.com/takanori-ugai/Precheck-LLM-Planner>

利点が挙げられる。

- LLM の言語理解能力によって、エージェントは人間から与えられる「言葉」の多様な言い回しに対応できるようになる。これにより、文脈に応じた適切な解釈が可能となる。
- LLM の常識知識と推論能力を利用することで、行動計画の候補を生成できる。ただし、環境状態の欠落や誤解釈が残るため、性能向上はタスクと提示条件に依存する。
- 従来手法 [Zhang 21, Blukis 22] と異なるデータ効率の可能性が報告されている [Song 23] が、少量データで高性能になることを本研究の結果から一般化しない。

Huang ら [Huang 22] は、GPT-3 と BERT [Devlin 19] を用いて、自然言語で表現された抽象的なタスク（例：Make breakfast）をシミュレータ上で実行可能なアクションシーケンスに変換する方法を提案している。Huang らの手法では、初めに、Planning LM (GPT-3) を用いて、タスク達成に有効な次のアクションを一つ自由形式で生成する。その後、Translation LM (BERT) を用いて、Planning LM が生成したアクションをシミュレータで実行可能な形式に変換している。二巡目以降は、直前までのアクションも参照してプランニングを再帰的に行う。

しかし、タスクを達成するためのアクションを生成して実行する際、生成したアクションが必ずしも実行可能である状況であるとは限らないといった課題が生じる。例えば、リンゴを手に保持していない状態で、“Put the apple on the table” を生成して実行する可能性がある。このようなプランニング中に発生する前提条件エラーを対処するための手法 [Raman 24] を紹介する。

Raman ら [Raman 24] は、Huang らの手法を拡張し、プランニング中のアクション実行時に発生する前提条件エラーに対処するための修正アクションを自動生成する手法を提案している。Raman らの手法は、シミュレータからのエラーフィードバックと Few-shot Reasoning を活用することで、生成されるアクションの質を向上させている。これにより、ベースライン手法 [Ahn 22, Huang 22] と比較して、より多くのタスクを正確に達成した。本研究の提案手法は実行前に条件を LLM へ問い合わせるが、このタイミングの違いだけを新規性や優位性の根拠とはしない。構成要素比較では、検証なし、LLM 検証、記号検証、失敗後修復を区別して評価する。失敗後修復条件 C3 は本実装上の独自対照であり、Raman らの CAPE を忠実に再現した比較ではない。

環境情報の提示について、Lin ら [Lin 23] の G-PlanET は、物体種・位置・姿勢・包含先を表として符号化し、目標文とともに BART 等へ与える。生成済みステップを入力に加える反復デコードを用い、ALFRED 由来の計画を参照列との KAS 等で評価する。本研究のように

各候補の自然言語条件を別要求で検証する手法ではなく、その反復デコードを VH の実行エラーによる再計画と同一視しない。本研究では、指示中の名詞から対象と支持物・容器を限定し、状態・ID・関係を自然言語へ変換する具体的な処理と制約を示す。表形式に対する自然言語形式の固有効果を比較した実験ではない。

2.2 記号的な実行監視と計画修復

Fikes の PLANEX1 [Fikes 71] は、STRIPS が生成した計画と、行動の前提条件・ゴールの証明に必要な状態記述を用いて実行を監視する。不要になった部分を省略し、期待した結果を得られなければ部分再実行または再計画を要求する。条件を確認して実行を変更する原理は LLM 以前から扱われている。本実装の抽出知識と自然言語条件はこのような形式モデルと同じ保証を持たず、再生成後にも検証しない点に制約がある。

Fox ら [Fox 06] は、状態・ゴールの変化に対する再計画と、既存計画を起点とする LPG の修復を比較し、計画の変更量を表す安定性も評価した。記号モデル上の修復問題に対する結果であり、LLM への違反説明の品質や VH の物理的実行可能性の証明ではない。本研究は C2 / C5 で限定的な条件辞書を評価するが、PLANEX1 や LPG を再実装した比較ではない。記号的な監視・修復と本方式との差は、判定主体、利用情報、修正範囲、評価尺度を分けて整理する。

2.3 家庭内タスクベンチマーク

人間から与えられる自然言語の指示から、タスクを実行するための適切な行動計画を行う研究のための代表的なデータセットとして、VirtualHome (VH) データセット [Puig 18] と ALFRED [Shridhar 20] の二つがある。

VH データセットは、エージェントに家庭内での活動を学習させるために収集したデータセットであり、人間が家庭で行う活動（例：コーヒーを入れる）と、その活動を実行することができる様々な方法を自然言語で記述した複数の説明、それぞれの説明に対してエージェントがアクティビティを実行するために必要なアクションシーケンスによって構成されている。参照列との比較には Longest Common Subsequence (LCS) [Puig 18] が用いられるが、参照列との一致とゴール状態の充足は異なる。本研究では、初期状態に応じた行動列の違いを許し、指定した ID の最終状態・関係を採点する。この選択は、既存データセットが状態に応じた行動を評価できないことを意味しない。

ALFRED は、自然言語による指示とエージェントの視覚情報から、家庭内タスクを実行するためのアクションシーケンスへのマッピングを学習するためのベンチマークである。ALFRED データセットは、デモンストレーションに対応する自然言語の指示で構成されている。各指示にはタスクと、段階的な手順が含まれてい

る。各デモンストレーションは、エージェント視点から観察した視覚情報と、各時間ステップで取ったアクションシーケンスで構成されており、AI2THOR 2.0 [Kolve 17] で再生可能なコマンドで記述される。ALFRED では、Task Success と Goal-Condition Success を評価する。Task Success は、物体の位置や状態がタスクのゴール条件に正しく対応していれば 1、そうでなければ 0 と定義される。Goal-Condition Success は、タスク完了に必要なゴール条件に対する完了したゴール条件の割合である。

ただし、これらのデータセットの主目的は本研究と異なり、物体の現在状態・識別番号・関係を明示的に入力して前提条件を検証することに限定されない。本研究はその能力を診断する補完的なタスク設定として位置付け、既存データセットに同様のタスクが存在しないとは断定しない。

表 1 は評価対象と再現範囲を整理する表であり、同一実装・同一入力による性能順位を示すものではない。本方式もタスク名を埋め込みベクトル化して事例検索するため、文字列一致への置換という差ではない。検索入力をタスク名だけに限ることの制約と、意味類似・random・fixed・none の構成要素比較を 5.5 節に示す。

3. タスクの設定とデータセットの要件

本章では、家庭環境の理解を必要とする家庭内タスクについて説明し、その評価に必要なデータセットの概要を述べる。家庭環境知識とは、家庭環境内の物体に関する詳細な情報を指し、物体の現在の状態、識別番号、および物体間の関係を含む。これらの家庭環境知識に依存する家庭内タスクを評価するために必要なデータセットの要件を以下に示す。

- 物体の識別番号の特定が必要なタスクとすること。これは、同じ種類の物体が複数存在する場合に、どの物体を対象とすべきかを明確にするためである。
- 物体の初期状態を常識的に推論すると失敗するタスクを含めること。例えば、“Turn on the light” という指示を受けた場合、常識的にはライトの状態が“OFF”であると考えられる。しかし、実際には“ON”である可能性もある。本研究では、常識知識のみに依存せず、家庭環境知識を活用することを目的とするため、このようなタスクを含める。
- タスクの達成条件（ゴール）が一意に定まるタスクとすること。家庭内タスクの例として“Clean up”が挙げられる。しかし、このようなタスクはゴールの定義が曖昧であり、解釈が複数存在するため、自動評価が困難である。通常は人手による評価が必要となるが、これには高い評価コストが伴うため、ゴールが明確に定義されたタスクとする。
- シミュレータ内部の環境グラフを取得可能とし、

視覚情報による環境認識は行わないこと。ただし、グラフからの抽出・自然言語化で必要な情報がすべて保持されるとは仮定しない。その変換と、得られた記述を用いる計画過程を評価対象とする。

本研究では、上記の要件を統制して評価するため、同一種類の物体の識別と、初期状態・配置関係に応じた行動の変更を必要とするデータセットを構成する。評価はシミュレータ内部の環境グラフを利用する条件で行い、視覚認識の精度は対象としない。また、ゴール条件をデータとして保持し、指定された物体 ID の状態または関係に基づいて評価する。

そこで、本研究では、評価に必要な要件を満たす 2 種類のタスクを設定した。一つ目は、複数の物体を特定の状態に変化させる「状態変化タスク」であり、主に物体の状態を認識することが課題となるタスクである。もう一つは、複数の物体を特定の場所（物体の上または中）に配置する「配置タスク」であり、主に物体間の関係を認識することが課題となるタスクである。

3.1 指示文の範囲と粒度

本論文では、自然言語の指示文を「タスク名」、指示文とシーン・初期条件・ゴール条件・参照行動列を組にしたデータ 1 件を「タスクインスタンス」と呼ぶ。評価対象は、状態変化では“Turn on/off all [対象クラス]”，配置では“Put all [対象クラス] in/on the [配置先クラス]”という定型の指示である。各インスタンスは一つの対象クラスを扱い、配置タスクでは一つの配置先を指定する。異種物体を同時に操作する複合指示や、自由な言い換えの理解能力は評価していない。

“all”は、当該シーン（家屋）内でタスクが対象とするクラスの物体全体を指す設定である。初期部屋にある物体だけに限定する指示ではない。対象 ID、個数、現在状態、所属部屋は指示文に列挙せず、環境知識から取得する。例えば、“Turn on all lightswitches in the kitchen”は対象範囲を限定し、“Turn on all 4 lightswitches”は個数を追加する別条件であり、今回の指示文集合には含まれない。生活習慣や同居人との暗黙の共有文脈を推定することは課題に含めない。ただし、公開実装のプロンプトには、この“all”の規約を別途説明する追加文はない。実装はタスク中の名詞に対応する物体を家屋全体のグラフから抽出する。

3.2 入力、初期化および評価情報

データの各フィールドの用途を表 2 に示す。エージェントの初期位置は initial_room で指定し、実行中の所属部屋・近接関係はグラフから取得する。移動は対象名と ID を指定した高レベル操作 WALK による。したがって、初期部屋は初期化と実行状態に関係するが、物体検索の範囲をその部屋に制限するものではない。経路上の前進・回転等を本手法が逐次計画する設

表 1 関連研究との評価対象の比較（数値の直接比較ではない）

研究	入力情報	検証・照合時点	判定主体	修正方法	評価条件・尺度
PLANEX1 [Fikes 71]	計画, 述語の世界モデル, 必要条件	実行中の状態照合	記号的実行器	省略・部分再実行・再計画	ロボットの実行シナリオ
Fox ら [Fox 06]	既存計画, 変更後の初期状態・ゴール	実行文脈の変化後	LPG の記号的探索	既存計画の修復／新規計画	計画問題の変形; 時間・品質・安定性
Huang ら [Huang 22]	タスク, 検索事例, 変換後の行動履歴	生成時の行動形式への変換; 状態検証ではない	生成 LM と埋め込みによる Translation LM	変換した行動を次の文脈へ追加	VH; 実行可能性・LCS・人手正しさ
Raman ら [Raman 24]	タスク・履歴, 前提条件エラー	環境での行動検証・失敗時	環境側の条件判定, LLM による修正	エラーを含む再プロンプト	VH と Spot; 実行可能性・正しさ
Lin ら [Lin 23]	目標, 物体表, 生成済みステップ	反復デコード; 独立の前提条件検査ではない	計画生成 LM	履歴付き次ステップ生成	ALFRED 由来; KAS 等の参照比較
本研究	抽出状態・ID・関係, 事例, 履歴	候補実行前; 再生成後は未検証	C1 は LLM, C2 / C5 は条件辞書の規則	棄却時に 1 回再生成	VH; 基本性能 18 条件・構成要素 240 件・ケース分析

定ではない。

3.3 推論の範囲とゴール以外の制約

評価する推論は、同名物体の識別、現在状態に応じた操作対象の選択、物体の支持・包含関係の把握、配置前の把持や容器開放といった局所的な操作条件の判断である。複雑さを表す属性として、ゴール対象数、状態変更が必要な対象数、配置先の開閉状態、シーン、初期部屋、参照行動列長を記録する。これらの属性が異なることと、人間にとっての難しさや長期探索の難しさは同一ではない。

障害物の意図的な移動や、達成済みゴールを一時的に崩す必要があるかを分類した注釈は、公開データにはない。そのような依存関係を統制したベンチマークとは位置付けず、参照列から未確認のシーンにまで「後戻りが不要」と一般化しない。

ゴール条件は最終状態について定義する。配置タスクでは指定 ID 間の ON または INSIDE 関係の評価し、指示にない片付け、無関係な物体の原状回復、冷蔵庫の最終的な閉鎖や開放時間は独立の採点条件に含めない。途中状態の制約としてはシミュレータ自身の実行条件が適用されるが、生活上の安全性や快適性を別途評価する処理はない。参照行動列は実行方法の一例であり、唯一の正解や最短列ではない。実行エラーと試行上限を含む成功・失敗の判定順序は 5.2 節と 5.3 節に示す。

4. 提案手法

本章では、五つのコンポーネントから構成される提案手法について述べる。提案手法は、LLM とシミュレータから取得した家庭環境知識を用いて、タスクを実行するためのアクションを逐次的に生成する。さら




図 1 提案手法の構成。図は処理の概略を表し、終了判定・上限判定の順序は Algorithm 1 に従う。

に、LLM を用いて生成されたアクションの前提条件を検証し、違反と判定した場合には代替アクションを 1 回再生成する。提案手法の構成図を図 1 に示す。以下の詳細仕様は公開された `single-prompt.ipynb` および `multi-prompts.ipynb` のコードに基づく。このコードと各実験条件との対応については 5.2.1 節に制約を述べる。

4.1 家庭環境知識の取得

図 1 の「家庭環境知識の取得」では、シミュレータのグラフをコードで抽出・自然言語化する。この抽出処理自体に LLM は用いない。まず `spaCy` の `en_core_web_sm` でタスク文を解析し、品詞が `NOUN` の語と `inflection.singular`

表 2 データの入力先と用途 (公開実装)

フィールド／情報	用途
task	計画・完了判定の指示, 関連名詞の抽出, 事例検索のクエリ.
scene, initial.room	シーンを初期化し, 指定部屋にキャラクターを配置する. これらのフィールドをそのままプロンプトに渡す処理はない.
initial.states	指定 ID のノードの状態配列を上書きする. 物体位置を変更するフィールドではない.
実行中の環境グラフ	4.1 節の抽出・自然言語化を経て, 計画・完了判定・前提条件判定に渡す.
goal.states	通常終了時の採点に利用し, 計画用プロンプトには渡さない.
評価対象の action.scripts	参照行動列の長さを試行上限の設定に利用する. 行動列そのものは計画器に渡さない.
事例用データの task, action.scripts	選択した 1 件の指示・行動列をプロンプトに埋め込む. 事例の初期状態・シーンは埋め込まない.

による単数形候補を取得する. 次に, その語集合に `class_name` が一致する物体ノードを家屋全体から選ぶ. 文字列一致による選択であり, 同義語検索や指示中の修飾関係の解析は行わない.

選択した物体について, 状態配列と, 出辺の ON・INSIDE を走査する. INSIDE の相手が `bathroom`, `bedroom`, `kitchen`, `livingroom` のいずれかなら所属部屋として扱い, それ以外なら容器として扱う. ON の相手は支持物として扱うが, 相手クラスが `walk` または `floor` の場合は除外する. `walk` は公開コード中の文字列をそのまま記したものである. 支持物・容器を追加対象として一度だけ展開し, その状態・支持／包含関係・所属部屋を読む. 追加対象からさらにノード集合を再帰的に拡張する処理はない. また, 既に選択済みのノードが追加対象にも現れると, そのノードの記録を初期化して再走査する. 各 ON・INSIDE・所属部屋の格納欄は単一値であり, 複数の同種関係はグラフの走査順に上書きされる.

エージェントについては, ID 1 の出辺から所属部屋, 左右の手の保持物, 抽出対象への CLOSE 関係を取得する. エージェントのノード状態配列は自然言語化していない. 物体が保持する対象の列挙も, 走査時の抽出集合に含まれる物体に限られ, 全内容物の列挙ではない.

自然言語化では物体名と ID, 状態配列の先頭要素, ON または INSIDE 関係, 所属部屋を文章にする. ON と INSIDE の両方がある場合は ON を優先する. 所属部屋を得られない物体では基本の説明文を出力せず, 保持対象の列挙があればその部分のみを出力する. 保持対象が容器の中か支持物の上かは CONTAINERS 属性の有無で記述する. このため, シミュレータの完全なグラフを取得できることと, 計画器に必要な全情報が提示されることは同義ではない. 位置座標, 画像, 壁面や床面の任意の関係は入力しない. 正確な変換関数と説明用入力に対する出力例は付録 A.3 に示す.

4.2 タスク完了の判定

図 1 の「タスク完了の判定」では, LLM が家庭環境

知識に基づき, タスクが完了しているかを判定する.

Listing 1 は Multi Prompts における入力の内容を示す. 実装では環境知識に終了判定文を連結し, system メッセージと一つの user メッセージで問い合わせる. Single Prompt では終了判定文の文面が異なる. 両方式を示す.

出力が文字列 “End” と完全一致した場合に通常の採点へ進む. 前後の空白を除去する処理はない. 参照列長が 0 の場合は, 最初の出力が “End” ならゴールグラフを再確認せず成功, “Continue” なら上限到達による失敗として返す. これ以外の出力に対する専用の再問い合わせ処理はなく, 行動生成へ進む.

行動のカウンタは 1 から開始し, 成功実行の後に上限を検査し, 上限未満なら 1 加算する. 上限に達した場合は次の完了判定を行わず失敗として返す. したがって, 上限ちょうどで行動でゴールに達した場合も成功にはならない. 全体の判定順序を Algorithm 1 に, 上限の算出方法を 5.2 節に示す.

4.3 アクションステップ生成

図 1 の「アクションステップ生成」では, LLM と家庭環境知識を用いて, タスクを達成するために必要な次のアクションステップを一つ生成する.

本コンポーネントで用いるプロンプトテンプレートを Listing 2 に示す. 本プロンプトテンプレートは, 「実行可能なアクションとその出力形式 (Listing 2 の 3 行目と 4 行目)」, 「One-shot 学習用の例 (タスクと行動計画) (Listing 2 の 6 行目と 7 行目)」, 「家庭環境知識 (Listing 2 の 10 行目)」, 「タスクとアクションの実行履歴 (Listing 2 の 13, 14 行目)」の四つの要素から構成される.

これらに冒頭の生成指示を加えた 5 要素を, Single Prompt では一つの user メッセージに連結し, Multi Prompts では順序を保った五つの user メッセージとして渡す. これとは別に, 両方式とも system メッセージ 1 件を付ける. どちらも, 次の行動を生成する呼び出しは 1 回である. Multi Prompts は, 要素ごとに LLM の応答を

Listing 1 「タスク完了の判定」で用いるプロンプトテンプレート

```

1 The current states in the home are as follows:
2 [ Home environment knowledge ]
3
4 If the following task has already completed based on the current status, output "End";
   otherwise, output "Continue".
5 Task: [ Task description ]

```

Listing 2 「アクションステップ生成」で用いるプロンプトテンプレート

```

1 You need to generate a next action step for completing a household task.
2
3 Allowed actions: [ Allowed actions ]
4 Output format: [ Output format ]
5
6 Example Task: [ An example Task ]
7 [ Action plan for the example task ]
8
9 The current states in the home are as follows:
10 [ Home environment knowledge ]
11
12 Generate a only next action step to complete the following task and output only that.
13 Task: [ Task description ]
14 Step1:

```

得てから次を提示する方式ではない。各周回で更新した環境知識と、それまでに実行成功した行動履歴からメッセージを作り直す。修正前の候補行動や過去の前提条件判定は次周回の実行履歴には追加しない。

事例検索には sentence-transformers/all-MiniLM-L6-v2 を用いる。事例集合の異なるタスク名を埋め込み、入力タスク名とのコサイン類似度が最大の 1 名を選ぶ。同名の事例が複数ある場合は最長の参照行動列を採択する。長さ同点は JSON 中で先に現れる事例を選ぶ。検索の候補名は公開コードで set からリストへ変換されるため、類似度同点時の候補順序は固定されていない。シーン、初期状態、ゴール ID は検索に用いない。

4.4 前提条件の検証

図 1 の「前提条件の検証」では、LLM を用いて、生成されたアクションステップを実行するための前提条件を、現在の状況が満たしているかどうかを検証する。さらに、前提条件を満たしていなかった場合には、満たされていない前提条件を特定し、それに基づいてアクションステップの再生成を行う。一連のプロセスの概要を図 2 に示す。

初めに、Listing 3 の環境知識、判定指示、前提条件文を一つの user メッセージで与える。この呼び出しに system メッセージは付けない。前提条件文は precondition。操作名をキーとして選び、対象名・ID を代入する。

公開コードは出力に大文字小文字を区別した部分文字列 “Yes” が含まれれば充足とし、それ以外は違反条件の特定へ進む。厳密な二値応答の検証ではない。違反条件の特定には判定時の user 入力と assistant 出力を履歴として与え、Listing 4 の問い合わせを追加する。実際の連結では “Output only that.” と条件文の間に改行を追加しない。

条件辞書が JSON 形式で保存されていることと、条件をコードで真偽評価することは異なる。本節の提案手法は LLM 判定であり、5.5 節の C2 / C5 で用いる記号検証と診断用ラベル生成は比較条件と診断用評価の仕様である。また、判定応答と未充足条件の応答は別の要求であり、説明内容を評価する際にも区別する (5.5.4 節)。

違反条件の特定後は、Listing 5 の内容で再生成を行う。行動生成時の user 入力、候補行動の assistant 出力、違反理由の user 入力を履歴とし、タスク・実行履歴・次のステップ番号を含む指示の “Generate” を “Regenerate” へ置換した user 入力を追加する。前提条件判定用の履歴全体を再生成へ引き継ぐ処理ではない。

操作名が条件辞書にない場合は、違反条件の特定を行わず、形式不正というフィードバックで再生成する。空白区切りの引数解析は単純であり、不正な引数数等による例外を包括的に捕捉する実装ではない。いずれの再生成経路も 1 回で終了し、得られた行動を再検証




図2 前提条件の検証とアクションステップ再生成の概要。公開実装は再生成を1回行い、再生成後の行動は再検証せず実行する。

Listing 3 図2の「前提条件の検証」における「プロンプト B」の生成に用いるプロンプトテンプレート

```

1 The current states in the home are as follows:
2 [ Home environment knowledge ]
3
4 If the current status satisfies the preconditions, output "Yes"; otherwise, output "No".
5 Preconditions: [ Preconditions ]

```

せず実行する。従って、すべての実行行動について前提条件充足を保証する機構ではない。

4.5 アクション実行

図1の「アクション実行」では、生成したアクションステップをシミュレータ上で実行する。また、実行に成功した場合には、実行したアクションステップを実行履歴として図1の「アクションステップ生成」で用いるプロンプトの末尾に追加する。その後「家庭環境知識の取得」を再度行い、処理が終了するまで一連のプロセスを繰り返す。なお、アクションの実行に失敗した場合も処理を終了する。

実装は行動文字列に<char0>を付与し、render_scriptをfind_solution=Falseで呼ぶ。失敗した行動は保存列に追加しない。PreCheckなしのアブレーションは検証と再生成の分岐全体をスキップし、生成行動を直接実行する。

4.6 実装

本節では、提案手法の実装について述べる。提案手法の実装で用いるシミュレータに必要な機能条件を以下に示す。

- シミュレータの内部データとして、完全な家庭環境知識を取得することが可能であり、それには物体の状態や物体間の関係、エージェントと物体間の関係が表現されている。
- 前進や回転、アームを動かすなどの細かい動作でエージェントを動作させるのではなく、対象物とその識別番号を指定することで移動やインタラクションが可能な高レベルのコマンドが用意されている。
- アクションを実行するための前提条件が定義されている。

本研究では、これらの条件を満たすシミュレータとして VirtualHome (VH) [Puig 18] のバージョン 2.3 を用いて提案手法を実装した。VH は、高レベルのコマン

Listing 4 図2の「満たされていない前提条件の特定」における「プロンプト C」の生成に用いるプロンプトテンプレート

```

1 Which the preconditions are not satisfied?
2 Output only that.
3 Preconditions: [ Preconditions ]

```

Listing 5 図2の「アクションステップ再生成」における「プロンプト D」の生成に用いるプロンプトテンプレート

```

1 ' [ Generated action step
   ]' can not execute, because it is not satisfied the following precondition.
2 [ Unmet preconditions ]
3
4 Regenerate a only next action step to complete the following task and output only that.
5 Task: [ Task description ]
6 [ Action execution history ]
7 Step n:

```

ドが提供されているのが特徴的である。一方、他のシミュレータでは、細かい動作でエージェントを動かすことが多い。また、VHの家屋は、4から5の複数の部屋で構成されており、多くの部屋や物体が存在する環境下で、実験を行うことが可能である。

VHは、仮想家庭内で活動をシミュレートすることを目的としたシミュレータである。VHの環境は、JSON形式のグラフ構造として表されている。環境内に存在するオブジェクトのリストを“nodes”キーの値として記述し、部屋や物、またそれらに関する識別番号、位置座標、物の状態といったセマンティックデータを定義している。また、“nodes”キーの値として記述された各オブジェクトの識別番号を指定し、二つのオブジェクトの関係のリストを“edges”キーの値として定義している。

VHでは、一連のアクションステップを記述したアクションスクリプトに基づいて、エージェントを行動させることができる。各ステップは操作、対象名、対象IDで構成される（例：[WALK] *livingroom* (336)）。公開されたprecondition.jsonは8操作の自然言語条件を保持する。例えばSWITCHONでは対象への近接とOFF状態、PUTINでは対象物の保持、配置先への近接、配置先がCLOSEDでないことを要求する。全条件を付録A.2に示す。

前提条件はprecondition.jsonの固定した自然言語条件を用いる。参考資料としてVHのDocumentationとGitHubソースが実装資料に挙げられているが、固定版・該当箇所と各条件の対応、転記・整形・省略の手順は記録されていない。従って、自動抽出した、あるいはシミュレータの全実行条件を網羅するとは主張しない。例えば状態がOFFであるというSWITCHON

の条件は、冗長操作を避ける目的と実行可能性を判定する目的を併せ持ち得る。自然言語条件の充足と、VHによる実行の成否は区別する必要がある。

5. 評価実験

本章では、提案手法のタスク遂行能力と各構成要素の働きを、一連の実験と分析によって評価する。基本性能評価では状態変化312件・配置103件を対象に、提示方式・モデル・前提条件検証の有無による成功率と行動列長を調べる。構成要素比較では、代表4タスクの240エピソードを用いて、検証方式、失敗後修復、再考、事例検索の違いを比較する。さらに、固定入力での判定評価とケース分析によって、どの判断や実行過程に失敗が残るかを検討する。

各評価は同じタスク集合を基礎とするが、対象件数、初期化条件、記録の粒度は異なる。基本性能の18条件（各タスク種別9条件）と構成要素比較の結果はそれぞれの分母で示し、両者を合算した成功率は求めない。代表候補の再実行と人手確認は、個別過程を解釈するための分析として位置付ける。

5.1 評価用データセット

本研究では提案手法を評価するために、3章で示した要件を満たす新たなデータセットを構築した。具体的には、物体の状態に着目した「状態変化タスク」と、物体間の関係に着目した「配置タスク」の2種類のタスクを構築した。

§1 状態変化タスク

評価データに含まれる状態変化の指示は“Turn on all lightswitches”のようなON/OFF操作である。開閉操作は計画器の許可操作に含まれるが、窓や扉の開閉を最

Listing 6 状態変化タスクのデータセット例

```

1 {
2   "task": "Turn on all lightswitches",
3   "scene": 1,
4   "initial_room": "kitchen",
5   "initial_states": [
6     {"id": 71, "states": ["ON"]},
7     {"id": 173, "states": ["OFF"]},
8     {"id": 261, "states": ["ON"]},
9     {"id": 427, "states": ["OFF"]}
10  ],
11  "goal_states": [
12    {"id": 71, "states": ["ON"]},
13    {"id": 173, "states": ["ON"]},
14    {"id": 261, "states": ["ON"]},
15    {"id": 427, "states": ["ON"]}
16  ],
17  "action_scripts": [
18    "[WALK] <lightswitch> (173)",
19    "[SWITCHON] <lightswitch> (173)",
20    "[WALK] <lightswitch> (427)",
21    "[SWITCHON] <lightswitch> (427)"
22  ]
23 }

```

終ゴールとする指示は今回の状態変化データに含まれない。対象物の全種類と件数は表 3 に示す。

各指示は複数の同名物体を対象とし、同じ指示に初期状態の異なるインスタンスを対応させる。すべて目標状態の場合と一部が未達の場合とでは、必要な行動が異なる。ただし、複数物体であることだけで人間にとって難しいと定義したり、単一物体条件に対する難易度の増加を測定したりしたものではない。具体的な件数・参照列長を表 4 に、必要な判断を 5.6 節に示す。

§2 配置タスク

本タスクでは“Put all apples in the fridge”などの指示に対して、複数の物体を環境内の特定の場所に配置することが求められる。対象物には、ロボットが把持可能な物体と、他の物体を受け入れることができる物体(“receptacle”)が含まれる。

複数物体の保持・配置と残り対象の追跡を扱う。冷蔵庫のような開閉可能な配置先には、初期状態が OPEN と CLOSED のインスタンスがあり、格納前の開扉の要否を判断する必要がある。一方、すべての配置先が開閉可能な容器とは限らず、ON 関係をゴールとする支持物も含む。これらは要求される判断の違いであり、人間の難易度を採点した分類ではない。

§3 データセット構築

本研究では、4.6 節で述べたように、シミュレータとして VH を使用する。したがって、データセットは VH との互換性を持つように設計した。

Listing 7 配置タスクのデータセット例

```

1 {
2   "task": "Put all plums in the fridge",
3   "scene": 4,
4   "initial_room": "bedroom",
5   "initial_states": [
6     {"id": 103, "states": ["CLOSED"]}
7   ],
8   "goal_states": [
9     {
10      "from_id": 53,
11      "to_id": 103,
12      "relation_type": "INSIDE"
13    },
14    {
15      "from_id": 54,
16      "to_id": 103,
17      "relation_type": "INSIDE"
18    }
19  ],
20  "action_scripts": [
21    "[WALK] <plum> (53)",
22    "[GRAB] <plum> (53)",
23    "[WALK] <fridge> (103)",
24    "[OPEN] <fridge> (103)",
25    "[PUTIN] <plum> (53) <fridge> (103)",
26    "[WALK] <plum> (54)",
27    "[GRAB] <plum> (54)",
28    "[WALK] <fridge> (103)",
29    "[PUTIN] <plum> (54) <fridge> (103)"
30  ]
31 }

```

VH には 7 種類の異なるシーン(家屋)があり、それぞれに複数の部屋とそこに設置された様々な物体が含まれている。各タスクは、これらシーン毎の特性に応じて構成している。

本データで扱う主な状態は ON, OFF, OPEN, CLOSED である。状態変化の指示の対象は 7 種類、配置の対象は 12 種類、配置先は 9 種類である。表 3 に、指示文中の表記と全インスタンス数を列挙する。物体クラス名との照合には 4.1 節の単数形補完を用いる。配置先はタスクに明示された対象であり、飲食物を置くことの生活上の適切さを別に評価するデータではない。

データセットの例を、Listing 6 および 7 に示す。データセットは、タスクの記述、シーン、エージェントの初期位置、物体の初期状態、物体の目標状態、そしてタスクを完遂するために必要なアクションスクリプトで構成される。

Listing 6 は状態変化の test.task6、Listing 7 は配

表 3 指示文中の対象・配置先の全種類と件数（事例用とテストの合計）

区分	種類（件数）
状態変化対象：7 種類	candles (20), cellphones (44), computers (24), faucets (56), lightswitches (256), tablelamps (40), tvs (24)
配置対象：12 種類	alcohols (3), apples (12), bananas (18), bellpeppers (6), chips (14), crackers (6), creamybuns (8), cupcakes (26), juices (5), milks (13), peaches (21), plums (22)
配置先：9 種類	coffeetable (9), cuttingboard (1), desk (3), fridge (48), fryingpan (1), kitchencounter (7), kitchentable (26), microwave (56), oventray (3)

置の test_task65 に対応する（空の comment フィールドのみ省略）。後者の参照行動列は 9 ステップであり、冷蔵庫を閉める操作は含まれない。ゴールは ID 53 と 54 が ID 103 の INSIDE にあることで、冷蔵庫が CLOSED であることは要求しない。途中で毎回冷蔵庫を閉める必要性も評価していない。

同名インスタンスではシーン、初期部屋、物体の状態配列等を変えている。初期化はシーンの物体位置を基礎とし、initial_states に指定した状態配列を上書きする。言い換え表現を多数作る方式ではない。対象・配置先別の件数は表表 3、シーン・初期部屋別の件数は付録の表表 B.3 に示す。これらは観測した組合せの集計であり、全組合せを網羅したことを意味しない。対象除外の理由、シミュレータ不具合への対処、作成・検証手順の詳細を確認できる記録がなく、選択過程の再現性には制約がある。

§4 データの分割方法

対象・指示・シーン・状態上書き・初期部屋の組合せは付録 C.4 に全 618 件を展開して示す。同じ指示・初期状態を持つ行は ID と部屋の対応を保持してまとめている。データの分割方法について説明をする。状態変化タスクデータセットの事例数は 464 個、配置タスクデータセットの事例数は 154 個であり、テスト用と訓練用データセットの事例数が大体 2 対 1 の割合になるように、各データセットを分割する。

訓練用データセットは、4.3 節で述べた、プロンプトに与えるタスク例に対するアクションスクリプトの出力事例として用いる。状態変化タスクのテスト用事例数は 312 個、訓練用事例数は 152 個、配置タスクのテスト用事例数は 103 個、訓練用事例数は 51 個とした。

同名でも異なる初期条件を持つデータを別インスタンスとして扱う。状態変化ではテスト 6 名・事例用 6 名、配置ではテスト 38 名・事例用 19 名の指示があり、いずれも両集合間の同名指示の重複は 0 である。一方、両集合にはともにシーン 1～7 が含まれ、物体クラスや操作構造も共有する。したがって未知家屋への汎化を評価する分割ではない。評価には公開 JSON の固定分割を用い、分割生成時の seed とスクリプトは記録されていない。「訓練用」はモデルのパラメータ学習を意味せず、プロンプトに与える事例の候補集合を指す。

例えばテストの “Turn on all lightswitches” に対し、事例集合には “Turn on all tablelamps” がある。配置で

表 4 テスト集合の規模と参照行動列長

	状態変化	配置
インスタンス数	312	103
異なる指示数	6	38
ゴール要素数の範囲	2-5	2-6
参照列長（平均）	3.872	9.175
参照列長（中央値）	4	8
参照列長の範囲	0-10	0-25
参照列長 0 の件数	27	2

は “Put all bananas in the fridge” と “Put all apples in the fridge” のように対象だけが異なる指示が両集合に存在する。これは構造の類似例であり、後者が前者の最近傍として実際に採択されたとする主張ではない。検索入力タスク名の埋め込みで、選択規則は 4.3 節に示した。

事例検索の特性を調べるため、テスト指示と選択事例のコサイン類似度および対象・操作・配置先の一致率を分析した。テストインスタンスで重み付けした平均コサイン類似度は状態変化 0.624、配置 0.781 だった。配置 103 件での対象クラス・操作・配置先の一致率はそれぞれ 89.3%、54.4%、10.7% である。例えば “Put all plums in the fridge” には “Put all plums on the kitchentable” が類似度 0.761 で選ばれ、“Turn off all tablelamps” には “Turn on all tablelamps” が 0.910 で選ばれた。高い類似度は操作や配置先の一致を保証しない。この分析では候補名をソートして検索を実行しており、基本性能評価の各試行で採択された事例との一致は、個別検索ログがないため確認できない。構成要素比較で用いる事例名・選択規則と、意味類似検索の類似度・上位差・列長は付録 B.3 に示す。構造的な一致率を手による適合率とは扱わない。

表 4 はテスト集合の属性を示す。参照列長 0 のデータは初期状態で完了しているというデータ側の設定に対応し、終了判定の振る舞いも評価する。参照列は最短解と証明されておらず、ゴール数や列長だけから人間の成功率・難易度を決めることはできない。

5.2 実験条件と評価方法

実験の前段階として、データセットのシーンと初期状態を用いて VH 環境の初期設定をする。次に提案手法にデータセットのタスク記述を入力して、タスクを

$$SuccessRate(SR) = \frac{SumOfSuccesses}{SumOfTasks} \quad (1)$$

$$ActionExecutionFailureRate(AEFR) = \frac{SumOfActionExecutionFailures}{SumOfTasks} \quad (2)$$

$$FailureRateOfReachingMaximunAttempts(FRRMA) = \frac{SumOfReachingMaximunAttempts}{SumOfTasks} \quad (3)$$

$$ErroneousTerminateFailureRate(ETFR) = \frac{SumOfErroneousTerminateFailures}{SumOfTasks} \quad (4)$$

$$FailureRate(FR) = AEFR + FRRMA + ETFR \quad (5)$$

$$AverageSteps = \frac{SumOfActionStepsForAllTasks}{SumOfTasks} \quad (6)$$

実行するための適切な行動計画を生成する。

基本性能評価の提示方式は、4.3 節で定義した Single Prompt と Multi Prompts である。前者は要素を連結した一つの user メッセージ、後者は五つの user メッセージを用い、いずれも行動生成 1 ステップにつき 1 回の呼び出しを行う。前提条件検証あり／なしを各方式で比較する。両方式には終了判定・行動生成の文面と system メッセージ末尾の空白にも差があるため、結果の差をメッセージ分割だけの因果効果とは解釈しない。検証方式・再考・検索を個別に変える条件は 5.5 節で述べる。

アクションステップの生成時に用いる、タスクを遂行するためのアクションスクリプトの生成例の選択方法について説明する。例の選択は、訓練データセットの中から、入力となるタスク名と類似度の高いタスク名を 1 種類選択する。タスク名に対して複数個のデータが存在する場合には、タスクを遂行するためのアクションスクリプトの生成例が最長のものを選択する。

4.2 節の試行上限 M は、評価対象自身の参照行動列長 L_{ref} を用いて $M = 2L_{ref}$ とする。検索で選んだ事例の列長ではない。これは参照解の長さを利用する評価用予算であり、参照解を持たない実運用時の停止規則ではない。上限判定は成功実行の直後にいき、 $n \geq M$ なら、その時点でゴールを満たしていても上限失敗とする。この場合に LLM が追加行動を生成しようとした事実までは観測していない。 $L_{ref} = 0$ の特例と想定外の終了判定文字列の扱いも Algorithm 1 に従う。

ベースラインは、Huang らの手法 [Huang 22] の著者公開実装^{*2}を、本研究の状態変化・配置タスクデータセットで実行した比較条件である。掲載値は本研究で得た実験結果であり、原著の報告値の転載ではない。独自に再実装したものではなく、著者公開実装を用いた。物体 ID の探索をシミュレータの自動探索に委ねる条件として実験記録に記載されているが、実験時に使用した公開実装の版・変更点と具体的な探索設定値は確認できない。したがって、この結果だけで Huang らの方式一般の性能や、環境知識の必要性を実証したとは解釈しない。

評価する LLM は GPT-4o mini と GPT-4o の 2 種類で、ベースラインは GPT-4o のみである。基本性能評価は、2 モデル・2 提示方式・検証あり／なしの 8 条件とベースラインの計 9 条件を各タスク種別に適用する。モデル版と実行条件の確認範囲を以下に示す。

§1 評価間の条件差と記録範囲

基本性能評価では初期部屋と状態配列を指定し、構成要素比較ではさらに人物位置を固定して参照グラフとの一致を確認する。後者の位置・姿勢の照合を、基本性能評価にも実施したとは扱わない。また、構成要素比較では各判定の入力・応答と実行前後の状態を記録し、途中の失敗実行数や API 要求数も分析する。

基本性能評価のモデル版は実験記述では gpt-4o-mini-2024-08-06 と gpt-4o-2024-08-06 だが、実行ごとの API メタデータによる確認はできない。構成要素比較ではこれらのモデル ID と temperature 0 を要求ログで確認できる。基本性能評価のベースラインは公開実装の出所と本研究のデータセットでの実行を確認できているが、実験時の版・変更点・停止設定には確認できない項目があるため、各評価の比較可能性には制約がある。コード・結果の対応と記録範囲の詳細は付録 A.5 に示す。

5.3 評価指標

本研究では、既存研究 [Shridhar 20, Song 23] の評価で用いられているタスクの成功率によって提案手法を評価する。本評価の通常採点では、タスク JSON に指定された物体 ID を用いてゴール状態を照合する。

成功率は、式 1 に示すように、タスクの総数に対する成功したタスクの割合として定義する。公開実装の通常終了では、状態変化は指定 ID の状態配列の完全一致、配置は指定した from_id, to_id, relation_type の辺の存在を確認し、すべてのゴールを満たせば成功とする。ゴール以外のノード状態や辺は採点しない。実行失敗と上限到達は通常のゴール採点より優先し、参照列長 0・最初の End では採点を省略して成功を返す特例がある。従って「最終グラフがゴールを満たすこと」のみで成功ラベルを定義しているわけではない。

失敗には三つのタイプがある。一つ目はシミュレー

^{*2} <https://github.com/huangw118/language-planner>

タにおけるアクション実行による失敗、二つ目は設定された最大試行回数に達したことによる失敗、三つ目はタスク完了と判定したが、タスクのゴール状態をすべて満たせていないことによる失敗である。失敗の原因を分析するために、各失敗タイプの割合を式 2 から式 4 に定義する。

式 2 は、シミュレータにおけるアクション実行の失敗に起因する失敗率を示しており、タスクの総数に対するアクションの実行に失敗した回数の割合として定義する。式 3 は、設定された最大試行回数に達したことによる失敗率を示しており、タスクの総数に対する当該失敗回数の割合として定義する。式 4 は、タスク完了と判定されたにも関わらず、タスクのゴール状態を完全には満たしていないことによる失敗率を示しており、タスクの総数に対する当該失敗回数の割合として定義する。

また、式 6 により “AverageSteps” を求める。基本性能評価では結果 JSON の `attempts` を平均し、全 18 条件で記録行動列長と一致する。提案実装は実行成功した行動のみを記録し、実行失敗した最後の試行や再生成回数、LLM 呼び出し回数は含めない。ベースラインについても記録列長との一致は確認したが、記録処理の詳細は不明である。失敗による途中終了でも列長は短くなるため、全件平均の短さだけで効率の優劣を判断しない。参照列長 0 を含む件数と長さは表 4 に示した。構成要素比較では、記録行動列長に加えて途中の失敗を含む実行試行数と API 要求数を区別する。

5.4 基本性能評価

提案手法とベースライン手法の比較結果について、状態変化タスクデータセットに基づく結果を表 5 に、配置タスクデータセットに基づく結果を表 6 に示す。

表 5 と表 6 の “Baseline” は Huang らの手法 [Huang 22] の著者公開実装を本研究のデータセットで実行して得た値であり、引用は手法の出典を示すもので、数値の転載を意味しない。“Single Prompt” と “Multi Prompts” は 4.3 節に述べたメッセージの構成方式を指す。“w/o PreCheck” は、提案手法から前提条件検証とそれに伴う再生成を除いた条件である。

基本性能評価では、提案手法はベースライン条件より高い成功率を示した。ただし、入力される環境情報・ID 情報やベースライン実装の確認範囲が異なるため、この差だけで前提条件検証の固有の効果を示すものではない。Multi Prompts は多くの条件で Single Prompt を上回るが、GPT-4o mini の配置タスクでは逆転する。また文面の差もあるため、分割だけによる改善と断定しない。

ベースラインの状態変化の成功 10/312 件は、すべて参照列長 0 だった。非ゼロ長 285 件の成功は 0 件で、配置は 0/103 件だった。ゼロ長特例と実装条件の確認

範囲の制約があるため、この集計を前提条件検証の独立した効果の根拠にはしない。設定の確認範囲は付録 A.5 に示す。

前提条件検証の有無による成功率の差は、モデル・提示方式・タスク種別によって異なる。状態変化では検証ありの成功率が高いが、GPT-4o mini の配置タスクでは両提示方式で逆転する。したがって、検証を追加すれば一律に改善するとは解釈しない。

また、表 5 と表 6 では、配置タスクの成功率は状態変化タスクより全体的に低く、モデル間にも差がある。ただし、成功率の差だけから必要な推論能力や失敗過程を特定できない。対象の追跡、容器操作、終了判断などの具体的な要求は、後述する実行ログと代表ケースに分けて検討する。

表 7 に成功・失敗別の記録列長を示す。失敗集合での短い列は途中終了を含み、効率向上とは解釈しない。参照列は最短解と証明されておらず、成功列が参照より短くても限界性能を達成したとはいえない。全 18 条件の成功・失敗別集計は表表 B.4、検証あり／なしの両方で成功したタスクの列長比較は表表 B.5 に示す。長さ比では参照列長 0 の状態変化 27 件・配置 2 件を分母から除き、件数を別記した。

5.5 構成要素の比較

基本性能に関わる機構を検討するため、検証方式、修復のタイミング、再考、事例検索を変えて比較する。対象は状態変化の `test_task1`, `test_task6` と配置の `test_task1`, `test_task65` であり、4 タスク、2 モデル、10 条件、各 3 反復の計 240 エピソードである。初期充足、未達対象の追跡、複数物体の配置、容器操作という異なる判断を扱うために選択した。モデルは `gpt-4o-mini-2024-07-18` と `gpt-4o-2024-08-06`, `temperature` は 0、各要求の出力上限は 256 トークンとした。初期位置を固定し、各試行の API 呼出し前に参照グラフとの記号状態一致、全ノードの位置差 0.001 以下、四元数距離 0.0001 以下を確認した。全 240 件がこの照合を通過した。対象件数と初期化の統制は 5.4 節の基本性能評価と異なるため、本節内の条件間で比較する。

C0 は前提条件検証なし、C1 は提案手法の LLM 検証、C2 は同じ抽出知識と条件辞書による記号検証である。C3 は検証せず実行し、VH 失敗後の最新知識とエラーに基づき 1 回修復する独自対照で、失敗実行も参照列長の 2 倍の実行予算に含める。CAPE 等の忠実な再現とは位置付けない。C5 は検証器だけに完全グラフを与え、計画器への知識は変えない。同じ 8 操作の条件を評価するが、既知の空状態集合と情報不足の区別も C2 と異なるため、差を抽出漏れだけに帰属させない。

C1-budget と C4-budget は、毎回の行動決定で生成・レビュー・説明・再生成の 4 要求を行う専用対照であ

表 5 「状態変化タスク」の評価結果 ※ PreCheck: 「前提条件の検証」

Method	LLM	SR	FR			Average Steps
			AEFR	FRRMA	ETFR	
Baseline [Huang 22]	GPT-4o	0.032	0.000	0.535	0.433	10.481
Single Prompt	GPT-4o mini	0.625	0.026	0.231	0.119	4.747
	GPT-4o	0.788	0.016	0.173	0.022	4.381
Multi Prompts	GPT-4o mini	0.750	0.045	0.183	0.022	4.917
	GPT-4o	0.894	0.019	0.000	0.087	3.391
Single Prompt w/o PreCheck	GPT-4o mini	0.615	0.003	0.253	0.128	4.872
	GPT-4o	0.760	0.016	0.189	0.035	4.449
Multi Prompts w/o PreCheck	GPT-4o mini	0.696	0.016	0.253	0.035	5.080
	GPT-4o	0.872	0.010	0.016	0.103	3.478

表 6 「配置タスク」の評価結果 ※ PreCheck: 「前提条件の検証」

Method	LLM	SR	FR			Average Steps
			AEFR	FRRMA	ETFR	
Baseline [Huang 22]	GPT-4o	0.000	0.010	0.573	0.417	15.398
Single Prompt	GPT-4o mini	0.466	0.146	0.029	0.359	7.282
	GPT-4o	0.738	0.117	0.029	0.117	8.078
Multi Prompts	GPT-4o mini	0.408	0.117	0.029	0.447	6.447
	GPT-4o	0.816	0.117	0.019	0.049	8.272
Single Prompt w/o PreCheck	GPT-4o mini	0.476	0.117	0.019	0.388	6.592
	GPT-4o	0.680	0.165	0.029	0.126	7.320
Multi Prompts w/o PreCheck	GPT-4o mini	0.437	0.126	0.010	0.427	6.136
	GPT-4o	0.796	0.117	0.029	0.058	7.767

表 7 基本性能評価の GPT-4o・Multi・検証ありの記録列長と参照列長. 参照平均も各行と同じタスク集合で計算.

タスク	結果	件数	記録平均	参照平均
状態変化	成功	279	3.584	3.878
状態変化	失敗	33	1.758	3.818
配置	成功	84	8.976	9.333
配置	失敗	19	5.158	8.474

る. 前者は条件辞書, 後者は条件辞書を提示しない一般的な再考を用いる. 両者の出力上限合計は 1024 トークンだが, 入力長, 実際の出力長, 計画全体の要求数は一致しない. 必要時のみ再生成する C1 とは別仕様であり, 厳密な総計算量一致は主張しない. R-random, R-fixed, R-none は C1 の事例だけを, 保存済みの反復別ランダム 1 例, 固定 1 例, 空の事例メッセージに変更する. C1 が意味類似検索の基準となる. 反復ごとにタスク・モデルのブロックと条件順を seed 20260907 で並べ替え, 事前に保存した.

表 8 には参照再生が失敗した配置 1 件も含めた. 参照成功 3 件のみの成功数と反復別の成績は表表 B.7 に示す. 初期充足の状態変化 1 件は全条件・全反復で行動せず成功し, 表の各分子に 3 件ずつ含まれる. 4 タスクは 3 種類の指示名に対応し, 12 個の独立タスクを評価

表 8 構成要素比較の成功数 (各条件 4 タスク ×3 反復, 分母 12)

条件	GPT-4o mini	GPT-4o
C0	8	9
C1	9	9
C2	4	10
C3	5	9
C1-budget	4	11
C4-budget	6	10
C5	5	9
R-random	8	9
R-fixed	7	9
R-none	3	3

したわけではない. C1 と C0, C1-budget と C4-budget などの差の方向はモデルによって異なり, 一律な優位性や全 415 タスクへの一般化を示すものではない.

§1 対照条件と検索変更の結果

C1 と C0 の成功数の差は mini で 1 件, 4o で 0 件だった. C2 と C1 では mini で 5 件減, 4o で 1 件増となり, LLM 判定と記号判定の優劣も一様ではなかった. 前提条件を明示する C1-budget は一般的な再考の C4-budget に対して mini で 2 件少なく, 4o で 1 件多かった. また, 4o の C1 と C3 はともに 9/12 成功だが, 途中を含む失敗実行数は C1 で 3 回, C3 で 9 回である. 終端の成功

数と途中の失敗実行数を分けて評価する必要がある。

検索条件の none の成功 3 件はいずれも初期充足タスクだった。mini では意味類似検索の C1 が 9/12, random が 8/12, fixed が 7/12 だが、同一タスク・反復の対応比較では random だけが成功する組が 3 件, C1 だけが成功する組が 4 件あった。4o は三つの検索条件とも 9/12 だった。意味類似検索が個々のケースで常に優位とはいえ、タスク名以外の状態を検索に用いる効果も測定していない。random の保存済み反復別選択は両モデルで共有した。各反復の成功数は表表 B.7, 検索事例の選択規則は付録 B.3 に示す。

§2 判定・終了・実行の診断

判定過程について、C1 の候補に対する LLM 判定を、抽出辞書上の JSON 条件の true/false と照合した正答数は、mini で 34/43 (誤受理 4, 誤棄却 5), 4o で 45/54 (誤受理 9, 誤棄却 0) だった。これらは異なる軌跡で観測された判定であり、共通の固定問題集合に対するモデル比較ではない。情報不足のラベルは分母から除く規則としたが、この C1 集計には該当例がなかった。

これとは別の固定入力による静的評価では、既知の前提条件 24 入力を各 3 反復し、mini は 51/72, 4o は 53/72 が JSON ラベルと一致した。情報不足 4 入力の各 3 反復、計 12 判定を各モデルの分母から除いている。構造化事実から作った共通問題であり、VH 実行可能性の正解率ではなく、実行中の C1 の 43・54 判定と合算しない。入力の構成と判定規則は付録 B.6 に示す。

全 10 条件を合わせた終了判定は mini で 496 回、4o で 600 回であり、未達なのに厳密な文字列 End を返した回数はそれぞれ 26 回、0 回だった。達成済みなのに非 End は両モデル 0 回だが、4o には End/Continue 以外の応答が 2 回あり、書式違反として別記した。一方、完全グラフ上の JSON 条件が true だった実行でも、mini は 376 回中 28 回、4o は 447 回中 37 回で VH が失敗を返した。条件辞書の充足は VH の全実行制約の充足を保証しない。途中時点を含むため独立な標本ではなく、棄却して実行していない候補に VH 成否を付与したものでない。判定ラベルの定義は付録 B.4 に示す。

本比較では完全グラフ、抽出知識、全プロンプト・応答、生成候補、検証、再生成、実行前後の状態を記録した。評価用ドライバは End 判定の入力となった直前グラフで成否を計算し、終了後にも独立に最終グラフを取得する。4.2 節の Notebook 実装は End 後に再取得するため採点時点が異なるが、本比較の 240 件では成功ラベルと最終ゴール充足の不一致はなかった。成功 API 要求は 3047 件、入力 1052576 トークン、出力 30594 トークンであり、通常単価・キャッシュ割引なしの推定費用は 1.681766 米ドルだった。通信失敗と出力上限による打切りは 0 件である。この費用は本比較 240 件のみの値で、静的評価・ケース分析用試行を含む研究全体の費用や請求確定額ではない。反復別の成績

は表表 B.7, 実行設定・費用の算出方法は付録 B.2 に示す。

§3 棄却候補の再実行と状態再現の制約

棄却された行動の実行可能性を検討するため、構成要素比較で LLM 判定が棄却した 59 候補から 8 件を選び、候補に先行する成功行動の接頭列を再生してから候補を実行した。選択対象は precondition 段階で棄却された候補であり、保存順にタスクごとに異なるモデル・条件の組を最大 3 件選んだ。内訳は状態変化 test_task6 が 3 件、配置 test_task1 が 2 件、配置 test_task65 が 3 件で、初期充足の状態変化 test_task1 には該当候補がなかった。実際に選ばれたのは C1 と検索変更条件であり、C2 / C5 を含む均衡抽出ではない。未選択 51 件にこの再実行から VH 成否を付与しない。

棄却候補 8 件の再実行は VH 成功 6 件・失敗 2 件で、API 要求は 0 件だった。ただし、元の候補判定入力のグラフと候補再実行直前のグラフを事後照合したところ、記号状態が一致したのは 6/8 件、さらに構成要素比較の 240 件と同じ位置・姿勢の許容差を満たしたのは 2/8 件だった。初期位置の固定と成功接頭列の再生だけでは、候補時点の状態一致は保証できない。再生コードはこの一致を実行前に検査しておらず、8 件全体を同一状態の反実仮想実験とは位置付けない。VH 成功 6/8 を検証器の誤棄却率と解釈せず、構成要素比較の 240 件の指標にも混ぜない。候補ごとの条件・行動・VH 成否・状態照合値を表表 B.10 に示す。

候補時点の状態一致を実行の条件とする評価では、同じ 8 候補について初期化と成功接頭列の再生を行い、候補実行直前の最後のグラフ取得で照合した。途中グラフの転送は行わず、不一致候補は実行しなかった。8 件すべてで初期化照合と接頭列再生が完了し、記号一致は 7 件、位置・姿勢を含む照合通過は 2 件だった。通過した 2 件を実行し、いずれも VH 成功だったが、両者は接頭行動を持たない step 1 の候補である。残る 6 件は状態不一致による未実行であり、失敗とも成功とも数えない。API 要求は 0 件である。この結果は照合通過例に限定した観測であり、途中状態の復元を達成した証拠や、全候補の誤棄却率とは扱わない。手順と個別値は表表 B.11 に示す。

接頭列方式で不一致だった 6 件には、人物のいないシーンへ候補時点の保存グラフを 1 回転送する復元方式を適用し、同じ許容差で実行直前に照合した。配置 test_task65 の C1・GPT-4o と R-fixed・GPT-4o の 2 件は照合を通過し、候補 [OPEN] <fridge> (103) はともに VH 成功だった。他 4 件は、3 件で FACING 関係、1 件で cupcake の位置・姿勢と ON 関係が一致せず、候補未実行とした。この方式の API 要求と通信エラーは 0 件である。両方式を通じて異なる 4 候補を照合通過後に実行できたが、試行結果を確認した上で評

価範囲をこの 4 件と未再現 4 件の開示に限定したもので、当初から 4 件のみを選択した実験ではない。未選択 51 件を含む母集団の誤棄却率は推定しない。復元方式の個別値と対象範囲を表表 B.13 に示す。

§4 判定応答と違反説明の人手確認

前提条件の判定応答と、未充足条件を列挙する別要求の応答を区別する。例えば状態変化 `test_task6`, C1・GPT-4o・反復 0・step 4 では、ON 状態の `lightswitch 261` に対する候補 `[SWITCHON] <lightswitch> (261)` に No を返し、未充足条件の要求には `<lightswitch> (261) is OFF` を返し、`[WALK] <lightswitch> (427)` へ再生成した。OFF という文は「満たされない条件」を列挙する要求への応答であり、現在状態を OFF と断定した文とは限らない。状態だけでなく、どの要求への応答かを踏まえて説明を評価する必要がある。

判定応答を対象とした代表 8 件の票には、著者 `ugai` が 2026 年 9 月 7 日に全件「判断不能」、根拠「情報が不十分」と記入した。この票は `precondition` が対象であり、別要求 `unmet` の違反説明の評価とは区別する。8 件すべてに保存された `unmet` の応答全文・要求文・対応状態を示した著者確認では、最終記入は「正しい」1 件・「誤り」7 件だった。採点基準の説明と個別例の整合性照会を AI 支援で複数回行った後の、同一著者による記入結果であり、独立評価・盲検評価ではない。また一部の根拠には未充足条件の列挙という評価対象との対応に曖昧さが残るため、この記入比率を説明の確定正解率や全候補の説明品質とは扱わない。自動作成した仮ラベルも人手結果に含めない。採点対象と段階別応答は付録 B.7、ラベル・記入根拠全文と制約は付録 B.7.1 に示す。これは 5.6 節の 4 タスクの説明内容の確認とも別の作業である。

5.6 代表タスクのケース分析

定量評価で見られる失敗とタスクに必要な判断を具体化するため、構成要素比較と同じ状態変化 2 件・配置 2 件を対象に、初期状態、ゴール、参照手順、実行過程を分析する。これは被験者の成功率や所要時間を測る実験ではなく、著者による説明的なケース分析である。最短手順であることや、人間にとっての一般的な容易さは主張しない。以下は Windows VH の固定位置条件におけるケース分析用試行のログに基づき、構成要素比較の 240 件には合算しない。

状態変化 `test_task1` は、4 個の `lightswitch (71, 173, 261, 427)` が初期状態ですべて ON であり、参照列長は 0 である。必要なのは指示の動詞に応じて操作を始めることなく、対象全体の初期充足を確認して終了する判断である。

同じ指示の `test_task6` では、173 と 427 だけが OFF である。参照手順は 173 への移動と ON 操作、427 への移動と ON 操作の 4 行動であり、ON 済みの 71 と 261

との区別が必要となる。固定位置試行の GPT-4o mini・記号検証条件では、173 への移動と ON 操作、261 への移動が成功した後、427 が OFF のまま終了判定が End となった。各行動の前提条件を満たすことと、タスク全体を達成することは異なる。この例では検証による再生成は起きておらず、記号検証が誤終了を引き起こしたとは断定しない。

配置 `test_task1` は、`cupcake 195` と `196` を `kitchen-counter 238` に置く課題である。参照列は各物体への移動、把持、配置先への移動、配置を繰り返す 8 行動である。対象を 2 個とも追跡するとともに、保持・近接と物体の操作適合性を区別する必要がある。参照列の再生では最初の 3 行動が成功したが、4 行動目の PUT が失敗した。保持・近接を確認できても実行可能性の十分条件とはならず、一般的なエラー応答だけから物理的原因を特定することはできなかった。また LLM 検証条件では、OPEN desk という候補を棄却した後に OPEN `cupcake` へ再生成し、VH が失敗を返す例があった。再生成後に再検証しない実装上の限界も確認できる。

配置 `test_task65` は、`plum 53` と `54` を初期 CLOSED の `fridge 103` に入れる課題である。参照列は 1 個目の移動・把持・冷蔵庫への移動・開扉・格納と、2 個目の移動・把持・移動・格納の 9 行動であり、再生に成功した。途中の保持物と残り対象を管理する必要がある。検証なしの GPT-4o mini では、53 を格納し、54 を右手に持ったまま End を返す例があった。保持情報は終了判定の入力にも含まれていたため、この失敗を情報抽出漏れだけでは説明できない。なお、両物体の INSIDE 関係がゴールであり、最後に冷蔵庫を閉めることを評価時に追加要求してはいない。

これらは失敗過程と必要な判断を示す例であり、統計的代表標本ではない。4 ケースの説明内容は 2026 年 9 月 6 日に確認を受けた。確認範囲は、本節の 4 ケースの初期条件・参照手順・必要な判断・難しい点の説明であり、確認者自身による実行や所要時間の計測は含まない。人間の成功率や最短路を測定した実験でも、5.5.4 節の違反説明の正しさを採点する作業でもない。

行動列の実行可能性とゴール充足の関係を調べるため、基本性能評価の同じ 4 タスク・2 モデルから記録された行動列 8 本を固定位置で再生した。8 本とも記録列全体を再生でき、最終ゴールを満たしたのは 5 本だった。GPT-4o・Multi の配置 `test_task65` では 10 行動をすべて再生し、ゴールを満たした。これは 5.5.3 節の棄却候補 8 件とは分析対象が異なる。記録されていない終端の失敗行動は含まず、生成時の人物位置との一致も確認していないため、記録接頭列を固定位置で実行した結果として解釈する。各列の長さやゴール充足は表表 B.15 に示す。

5.7 考察

基本性能の分布を表表 C.17・表 C.18, 同一 ID の参照との差・比を表表 C.19 に示す. マクロ SR とタスク名クラスター区間は表表 C.20, 検証有無の対応変化は表表 C.21 に示す. 検索類似度の分布と層別成績は表表 C.22・表 C.23 に示す. これらは同じ結果の記述的分析であり, 初期状態違いのインスタンスや共有家屋を独立な反復とみなして機構の因果効果を主張するものではない. 基本性能評価では配置の成功率が状態変化より全体的に低い, タスク集合, 参照列長, 終了判定, VH 実行制約も異なる. したがって, その差を空間関係の推論能力だけで説明しない. 同様に, Single と Multi の差には文面の違いもあり, モデル内部の推論過程を終端ラベルから特定できない.

FRMA は参照列長に基づく上限で終了したことを表すが, その直前にゴールへ到達した場合も含み, 冗長な次行動を生成した証拠とは限らない. ETFR は End 後のゴール不充足を表すが, 抽出漏れ, 候補選択, 終了判断のどこに原因があるかは終端ラベルだけでは決まらない. ケース分析では保持情報が入力にあるのに未達終了した例があり, 情報不足と入力の誤解釈を分ける必要性が示された.

構成要素比較の JSON ラベルは 8 操作の条件辞書に対する診断であり, VH 実行可能性の正解ラベルではない. 完全グラフの条件が true でも実行失敗があり, LLM が棄却した候補には未実行のものが残る. SWITCHON の OFF 条件は冗長操作を避ける条件にもなり得るが, 条件充足・VH 成否・目標達成・行動列長の改善はそれぞれ異なる指標である. 5.5.3 節の状態不一致を伴う再実行から, 棄却一般の適否は推定しない.

成功数に加え, 修復機会と失敗実行数も解釈に関わる. C1 と C3 では途中の失敗実行数が異なる一方, C1-budget と C4-budget の比較は要求数と出力上限をそろえても総計算量はそろえていない. 今回の結果は, 前提条件を明示した LLM 判定が記号判定や一般的再考に一律に優るという結論を支持しない. 検索についても, 対応比較では改善例と悪化例が共存する. 個々の機構の評価を一つの成功率に集約せず, 入力・判定・再生成・終了・実行のログを併せて提示することが本診断の意義である.

5.8 限界

第一に, データは 2 種類の定型指示と限られた物体クラスを扱い, 事例・テスト間で家屋と操作構造を共有する. 自由な言い換え, 未知家屋, 障害物移動や後戻りを要する長期計画, 人間にとっての一般的な難易度は評価していない. 構築手順の詳細は確認できず, 全参照列の実行可能性も保証できない. 構成要素比較は目的選択した 4 タスクの 3 反復であり, 初期充足 1 件と参照再生失敗 1 件を含む. 全 415 タスクでの構成要

素の反復比較は未実施で, 独立標本としての有意差や一般化は主張しない.

第二に, 基本性能評価と構成要素比較では, タスク数, 初期化の統制, 実行記録の粒度が異なる. ベースラインに用いた著者公開実装の出所は明らかだが, 実験時の Action Translation・Dynamic Example の設定や変更点, 基本性能評価の各試行のモデル・コード版などには確認できない情報があり, 構成要素比較の設定を代用していない. これらを補う実験時の追加保有資料はなく, 現在の公開実装の既定値も当時の設定の証拠とはしない. 資料回収不能の範囲は付録 A.5 に明記し, 完全な実験再現を達成したとはしない. C3 も CAPE の忠実な再現ではなく, 厳密な総計算量一致対照は未実施である. これらの制約から, 一連の評価の各結果はそれぞれの比較範囲で解釈する.

第三に, グラフ取得後の抽出・自然言語化には情報の省略があり, 条件辞書は VH の全制約を網羅しない. 代表候補 8 件の接頭列方式で実行直前の状態照合を通過したのは 2 件で, 人物のいないシーンへの復元方式で他の 2 件が通過したが, 残る 4 件は本手順で状態を再現できず候補未実行だった. 結果確認後にこの範囲へ評価を限定したため, 全 8 件を同一状態での反実仮想評価とは扱えず, 全棄却候補への推定もできない. 違反説明自体についても著者の 8 件の記入を得たが, AI 支援による基準説明・個別例照会後の確認であり, 根拠と採点基準の対応に曖昧さが残る. 説明の意味的正しさの独立した検証や確定正解率を得たとはしない. 4 ケースの説明確認を, 人間性能や説明品質の採点として代用しない.

最後に, 本研究はシミュレータ内部グラフと高レベル行動に依存し, 視覚認識や実機制御を扱っていない. ゴール以外の原状回復, 容器の開放時間, 生活上の安全性・快適性は独立の評価条件にない. LLM による条件判定だけで実環境の安全性や全行動の実行可能性が保証されるとはいえない.

6. おわりに

6.1 まとめ

本研究では, 物体の状態・ID・関係を用いる家庭内タスクの逐次計画を対象に, 知識の抽出・自然言語化, 事例検索, LLM による前提条件判定と 1 回の再生成, 終了・採点を追跡できる実装を示した. その評価を基本性能, 構成要素比較, ケース分析の流れで行った. 前提条件検証・再計画の一般原理そのものを新規な技術とは位置付けず, LLM 判定と記号判定を比較しながら, 具体的な実装の働きと制約を検討した.

データは状態変化・配置の計 618 インスタンスで, テスト 415 件と事例用 203 件からなる. 定型指示の下で同名物体を識別し, 初期状態に応じて行動を変更する

設定であり、既存ベンチマークを補完する診断対象とした。シーン・操作構造は事例とテストで共有し、未知家屋への汎化や一般的な人間難易度を測るものではない。

基本性能評価の 18 条件では、GPT-4o・Multi・検証ありの成功数は状態変化 279/312 (89.4%)、配置 84/103 (81.6%) だった。成功・失敗別の列長を比較することで、途中終了による短い行動列と、成功時の手順の違いを区別した。ただし、条件間の入力差と実行記録の制約があるため、成功率の差を前提条件検証だけの因果効果とは解釈しない。

構成要素比較は 4 タスク・2 モデル・10 条件・3 反復の 240 エピソードである。LLM 検証あり／なしの成功数は mini で 9/12 対 8/12, 4o で 9/12 対 9/12 で、各分子に初期充足タスクの 3 反復を含む。記号検証、一般的再考、失敗後修復、検索変更との比較も一律の優位性を示さなかった。実行ログでは、条件判定、未達なのに End を返す判断、JSON 条件を満たしても生じる VH 失敗を分離した。棄却候補の再実行には状態一致の制約があり、違反説明の著者確認も AI 支援後の記入で、説明品質を独立に検証したものではない。これらを踏まえ、本研究の知見は具体的な実装の失敗過程を示す診断的証拠に限定する。

6.2 今後の課題

まず、接頭列方式と人物のいないシーンへの復元方式を用いても状態が不一致だった 4 件の再現と、違反説明に対する評価基準・判断根拠の妥当性の検証が課題である。本評価は照合通過 4 候補の結果と未再現範囲の開示に限定しており、この 4 件の VH 成功、事後照合を伴う再実行の VH 成功 6/8、著者の「正しい」1 件・「誤り」7 件という記入のいずれも、母集団の誤棄却率や違反説明の確定正解率として代用しない。

次に、ベースラインの設定とデータ構築手順を含む再現性を確保し、実行条件を統制した全 415 タスクの反復比較、共通候補での判定比較、入力・出力・総要求数を考慮した計算量対照を行う必要がある。状態情報を加える検索や再生成後の再検証も検討対象だが、本評価の仕様には含まれず、独立した条件として評価する必要がある。

さらに、定型指示と共有シーンを越える課題、より複雑な物体相互作用や未知環境への拡張が必要である。実機への適用には、センサーからの認識誤差、低レベル制御、ゴール以外の安全制約も含めた別の評価を要する。本研究のシミュレータ上の成功率や条件辞書の充足を、そのまま実世界の信頼性・安全性の保証とはしない。

謝 辞

本研究成果の一部は、国立研究開発法人新エネルギー・産業技術総合開発機構 (NEDO) の委託業務 (JPNP20006) の結果得られたものです。本研究の一部は JSPS 科研費 23K11221, 23K28377, 25K03232 の助成を受けたものです。

◇ 参 考 文 献 ◇

- [Ahn 22] Ahn, M., Brohan, A., Brown, N., Chebotar, Y., Cortes, O., David, B., Finn, C., Fu, C., Gopalakrishnan, K., Hausman, K., et al.: Do as i can, not as i say: Grounding language in robotic affordances, *arXiv preprint arXiv:2204.01691* (2022)
- [青山 24] 青山 仁, チャクラボルティ シュデシナ, 森田 武史, 鶴飼 孝典, 江上 周作, 福田 賢一郎: 大規模言語モデルを用いたオブジェクトの状態と関係に基づく家庭内タスクプランニング, 人工知能学会第二種研究会資料, Vol. 2024, No. SWO-063 (2024)
- [Aoyama 25] Aoyama, J., Chakraborty, S., Morita, T., Egami, S., Ugai, T., and Fukuda, K.: Household Task Planning with Multi-Objects State and Relationship Using Large Language Models Based Preconditions Verification, in *Proceedings of the 17th International Conference on Agents and Artificial Intelligence - Volume 2: ICAART*, pp. 472–483 (2025)
- [Blukis 22] Blukis, V., Paxton, C., Fox, D., Garg, A., and Artzi, Y.: A Persistent Spatial Semantic Representation for High-level Natural Language Instruction Execution, in *Proceedings of the 5th Conference on Robot Learning*, Vol. 164 of *Proceedings of Machine Learning Research*, pp. 706–717, PMLR (2022)
- [Devlin 19] Devlin, J., Chang, M.-W., Lee, K., and Toutanova, K.: BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding, in *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics*, pp. 4171–4186 (2019)
- [Duan 22] Duan, J., Yu, S., Tan, H. L., Zhu, H., and Tan, C.: A Survey of Embodied AI: From Simulators to Research Tasks, *IEEE Transactions on Emerging Topics in Computational Intelligence*, Vol. 6, No. 2, pp. 230–244 (2022)
- [Fikes 71] Fikes, R. E.: Monitored Execution of Robot Plans Produced by STRIPS, Technical Report 55, Stanford Research Institute, Artificial Intelligence Group (1971)
- [Fox 06] Fox, M., Gerevini, A., Long, D., and Serina, I.: Plan Stability: Replanning versus Plan Repair, in *Proceedings of the International Conference on Automated Planning and Scheduling*, pp. 212–221, AAAI Press (2006)
- [Huang 22] Huang, W., Abbeel, P., Pathak, D., and Mordatch, I.: Language Models as Zero-Shot Planners: Extracting Actionable Knowledge for Embodied Agents, in *International Conference on Machine Learning*, pp. 9118–9147PMLR (2022)
- [Kim 23] Kim, B., Kim, J., Kim, Y., Min, C., and Choi, J.: Context-aware planning and environment-aware memory for instruction following embodied agents, in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp. 10936–10946 (2023)
- [Kolve 17] Kolve, E., Mottaghi, R., Han, W., VanderBilt, E., Weihs, L., Herrasti, A., Gordon, D., Zhu, Y., Gupta, A., and Farhadi, A.: AI2-THOR: An Interactive 3D Environment for Visual AI, *arXiv* (2017)
- [Lin 23] Lin, B. Y., Huang, C., Liu, Q., Gu, W., Sommerer, S., and Ren, X.: On Grounded Planning for Embodied Tasks with Language Models, in *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 37, pp. 13192–13200 (2023)
- [Nakajima 24] Nakajima, H. and Miura, J.: Combining Ontological Knowledge and Large Language Model for User-Friendly Service Robots, in *2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pp. 4755–4762IEEE (2024)
- [Puig 18] Puig, X., Ra, K., Boben, M., Li, J., Wang, T., Fidler, S., and Torralba, A.: VirtualHome: Simulating Household Activities via Programs, in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)* (2018)

- [Raman 24] Raman, S. S., Cohen, V., Idrees, I., Rosen, E., Mooney, R., Tellex, S., and Paulius, D.: Cape: Corrective actions from precondition errors using large language models, in *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pp. 14070–14077 IEEE (2024)
- [Rana 23] Rana, K., Haviland, J., Garg, S., Abou-Chakra, J., Reid, I. D., and Suenderhauf, N.: Sayplan: Grounding large language models using 3d scene graphs for scalable task planning, *CoRR* (2023)
- [Shridhar 20] Shridhar, M., Thomason, J., Gordon, D., Bisk, Y., Han, W., Mottaghi, R., Zettlemoyer, L., and Fox, D.: ALFRED: A Benchmark for Interpreting Grounded Instructions for Everyday Tasks, in *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 10737–10746 (2020)
- [Song 23] Song, C. H., Wu, J., Washington, C., Sadler, B. M., Chao, W.-L., and Su, Y.: LLM-Planner: Few-Shot Grounded Planning for Embodied Agents with Large Language Models, in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp. 2998–3009 (2023)
- [Zhang 21] Zhang, Y. and Chai, J.: Hierarchical Task Learning from Language Instructions with Unified Transformers and Self-Monitoring, in Zong, C., Xia, F., Li, W., and Navigli, R. eds., *Findings of the Association for Computational Linguistics: ACL-IJCNLP 2021*, pp. 4202–4213, Online (2021), Association for Computational Linguistics

〔担当委員： 〕

年月日 受理

◇ 付 録 ◇

A. 公開実装のプロンプトと知識変換

本付録は、提案手法の公開 Notebook に対応する入力と処理の仕様を示す。テンプレートと実際の送信ログを区別し、比較条件による入力の違いは付録 A・4、実行資料の確認範囲は付録 A・5 に示す。以下の Python 表記では \n を改行とし、role と文字列の組を順に並べたものをメッセージ配列とする。英語表現・空白は実装と一致させている。

A・1 全メッセージの組立て

Listing ??に、終了判定、行動生成、前提条件判定、違反条件特定、再生成の全入力を構成する関数を示す。mode は single または multi、env は付録 A・3 の変換結果全文、history は成功実行した行動の列である。example は example_text で得た選択事例の文字列であり、pc は付録 A・2 の辞書とする。プロンプトにゴール JSON を渡す引数はない。

通常の未完了周回では、検証なしは完了判定と生成の 2 回、条件を充足する検証ありは 3 回、違反条件特定と再生成を行う場合は 5 回の LLM 呼び出しとなる。操作名が条件辞書にない形式不正では、条件判定・違反特定を呼ばず再生成を行うため 3 回である。最初の完了判定で終了する周回は 1 回である。これはコードの呼び出し経路から数えた値であり、通信層の再試行や個々のエピソードの実測費用を含まない。

本文の Listing 1～5 は構成要素を説明する表示である。正確なメッセージ境界・改行・単語は以下を参照する。特に違反理由と再生成指示は別々の user メッセージとなり、前提条件の違反特定には行動生成時の履歴を渡していない。

Listing 8

cap

```
1 """Message specification of the published notebooks (no LLM
2 calls).
3 mode: 'single' or 'multi'; env: exact return_nlp output;
4 history: successfully executed actions; pc: original
5 precondition.json.
6 Whitespace and grammatical errors of the original prompts are
7 preserved.
```

```
6 """
7
8 SYSTEM = "You are a life support robot."
9 CHAT_SYSTEM = "You are a life support robot. "
10 INSTRUCTION = "You need to generate a next action step for
11 completing a household task.\n"
12 ALLOWED = """
13 Allowed actions:
14 Walk, Grab, Switch on, Switch off, Open, Close, Put, Put in
15 Output Format:
16 [WALK] <Object> (ID)
17 [GRAB] <Object> (ID)
18 [SWITCHON] <Object> (ID)
19 [SWITCHOFF] <Object> (ID)
20 [OPEN] <Object> (ID)
21 [CLOSE] <Object> (ID)
22 [PUT] <Object1> (ID) <Object2> (ID)
23 [PUTIN] <Object1> (ID) <Object2> (ID)
24 """
25 CHECK = '\nif the current status satisfies the preconditions,
26 output "Yes"; otherwise, output "No.\n'
27 UNMET = 'Which the preconditions are not satisfied?\nOutput
28 only that.'
29
30 def example_text(name, script):
31     text = f"Example Task: {name}\n"
32     for step, action in enumerate(script, 1):
33         text += f"Step{step}: {action}\n"
34     return text + "\n"
35
36 def task_text(mode, task, history):
37     if mode == 'single':
38         text = "\nGenerate a next action step to complete the
39 following task and output only that.\n"
40     else:
41         text = "Generate a only next action step to complete the
42 following task and output only that.\n"
43     text += f"Task: {task}\n"
44     for step, action in enumerate(history, 1):
45         text += f"Step{step}: {action}\n"
46     return text + f"Step{len(history) + 1}: "
47
48 def end_messages(mode, task, env):
49     if mode == 'single':
50         text = "\nOutput "End" if the following task has already
51 completed based on the current status, otherwise
52 output "Continue".\n"
53     else:
54         text = '\nif the following task has already completed
55 based on the current status, output "End";
56 otherwise, output "Continue".\n'
57     return [('system', SYSTEM), ('user', env + text + f"Task: {
58 task}\n")]
59
60 def generation_messages(mode, task, env, example, history):
61     blocks = [INSTRUCTION, ALLOWED, example, env, task_text(
62 mode, task, history)]
63     if mode == 'single':
64         return [('system', SYSTEM), ('user', ''.join(blocks))]
65     return [('system', CHAT_SYSTEM)] + [(('user', block) for
66 block in blocks)]
67
68 def bind_conditions(action, pc):
69     parts = action.split(' ')
70     operation = parts[0][1:-1]
71     if operation not in pc:
72         return None
73     text = pc[operation]
74     if len(parts) == 5:
75         return text.replace('<Object1>', f'{parts[1]} {parts
76 [2]}').replace('<Object2>', f'{parts[3]} {parts
77 [4]}')
78     return text.replace('<Object>', f'{parts[1]} {parts[2]}')
79
80 def check_messages(env, conditions):
81     return [('user', env + CHECK + conditions)]
82
83 def unmet_messages(env, conditions, check_output):
84     return [('system', CHAT_SYSTEM),
85 ('user', env + CHECK + conditions),
86 ('assistant', check_output),
87 ('user', UNMET + conditions)]
88
89 def feedback(action, unmet_output=None):
90     if unmet_output is None:
91         return f"('{action}') is incorrect output format."
92     return f"('{action}') can not execute, because it is not
93 satisfied the following precondition.\n(unmet_output)"
94
95 def regeneration_messages(mode, task, env, example, history,
96 action, reason):
97     messages = generation_messages(mode, task, env, example,
98 history)
99     messages[0] = ('system', CHAT_SYSTEM)
100     return messages + [(('assistant', action), ('user', reason),
101 ('user', task_text(mode, task, history)).
102 replace('Generate', 'Regenerate')))]
```

A・2 前提条件辞書と代入規則

Listing ??は公開 JSON そのものである。操作文字列を空白で分割し、先頭の角括弧を除いた操作名で辞書を参照する。トークン数が 5 なら Object1 と Object2 へ対象名・ID の組を代入し、それ以外では Object へ最初の対象名・ID を代入する。未定義の操作名なら形

表 A.1 各呼び出しの役割・入力・履歴と分岐

呼び出し	入力メッセージ	出力の利用
完了判定	system (末尾空白なし), user (環境+判定指示+タスク)	End との完全一致. 参照列長 0 では Continue との完全一致も確認.
行動生成 Single	system (末尾空白なし), user (5 要素を連結)	生成した 1 行動を検証または実行.
行動生成 Multi	system (末尾空白あり), 5 個の user (役割指示, 許可操作・形式, 事例, 環境, タスク・成功履歴・次ステップ)	1 回の呼び出しから 1 行動を得る.
前提条件判定	user (環境+判定文+対象を代入した条件)	部分文字列 Yes を含めば充足.
違反条件特定	system (末尾空白あり), 直前の判定入力 user と出力 assistant, 追加問い合わせ user	違反理由のフィードバックを作る.
再生成	system (末尾空白あり), 行動生成時の user 群, 候補 assistant, 理由 user, 再生成指示 user	1 回だけ生成し, 再検証せず実行.

式不正の再生成へ進むが, 必要なトークンがない場合等の例外を捕捉して必ず修正する処理はない.

この辞書の条件は固定した自然言語表現である. 元資料からの作成手順やシミュレータとの網羅的な対応は未確認であり, 規則の完全性を保証しない.

§1 参照可能な VH コードとの条件の照合

作成時の転記記録とは別に, VH の公開 Python グラフ実行器 (コミット 58970fd80951c2eaa1af713e0917d1a105353ad8) の条件検査を現在の辞書と照合した. 表表 A.2 は当該コードで確認できる差であり, 辞書をその版から作成した証拠でも, 接続先 Unity バイナリの内部実装との一致を示すものでもない. 作業中・作成日・転記手順は依然として記録未回収である.

この差からも, 条件辞書の充足をシミュレータ全制約の充足とみなすことはできない. Python 実行器の条件を Unity での実行可能性ラベルとして代用せず, 実行成否は実際の VH 応答で評価する.

A.3 知識抽出と自然言語化

抽出の処理順は Algorithm 2 に示す. 物体記録は状態配列, 単一の支持物・容器・所属部屋, 保持対象のリストを持つ. グラフの nodes・edges の順序で走査し, 単一値の欄は後から見つけた辺で上書きする. 追加ノードが元の抽出集合にある場合にも, その記録を初期化して再走査する. エージェントの保持物は名前・ID の取得対象となるが, 保持物を新たな抽出の起点として再帰展開するわけではない.

自然言語化の全関数を Listing 12 に示す. objId.dic は ID からクラス名への辞書, objProp.dic は ID から属性配列への辞書であり, 初期化後のグラフから作成する. Listing 6・7 のタスク JSON だけでは, 例えば ID 173 の所属部屋を確定できず, 実行時のグラフが必要となる. 基本性能評価には各時刻の完全グラフ・プロンプトの記録がないため, 構成要素比較やケース分析のグラフを, 基本性能評価の個別試行の入力として代用しない.

Listing 10・11 は, 変換関数の振る舞いを示す説明用の合成入力に対する出力である. 実際の VH シーンの観測ではなく, ID も 9000 番台の仮の値を用いる. 入力全文は Listing 9 に示す. 状態例はキッチンの OFF のスイッチへの近接を, 配置例はキッチンのテーブル上の plum と閉じた fridge, エージェントの近接関係を仮定する. ここには座標・壁面・同じ床面といった追加情報はない. 出力中の重複した “and” 等も変換関数の出力をそのまま保持した.

Listing 9

知識変換の説明用合成入力の全文

```
1 {
2   "kind": "synthetic_serialization_example_not_VH_graph_or_experiment_log",
3   "object_names": {
4     "9001": "kitchen",
5     "9002": "lightswitch",
6     "9012": "plum",
7     "9013": "kitchentable",
8     "9014": "fridge"
9   },
10  "properties": {
11    "9002": [],
12    "9012": [],
13    "9013": [],
14    "9014": [
15      "CONTAINERS"
16    ]
17  },
18  "state_objects": {
19    "9002": {
20      "states": [
21        "OFF"
22      ],
23      "on": null,
24      "inside": null,
25      "location": "9001",
26      "hold": []
27    },
28  },
29  "placement_objects": {
30    "9012": {
31      "states": [],
32      "on": "9013",
33      "inside": null,
34      "location": "9001",
35      "hold": []
36    },
37    "9013": {
38      "states": [],
39      "on": null,
40      "inside": null,
41      "location": "9001",
42      "hold": [
43        "9012"
44      ]
45    },
46  },
47 }
```


表 A.2 自然言語条件辞書と公開 Python グラフ実行器の照合範囲

辞書の操作	該当する検査	照合で確認できる追加条件・差
WALK	WalkExecutor.check.walk	辞書は非保持のみ。実行器は人物の座位・臥位や部屋情報も検査する。 近接に加え、GRABBABLE 属性等、閉じた容器内か、空いた手の有無などを検査する。 近接と OFF / ON に加え、HAS_SWITCH 属性を要求する。
GRAB	GrabExecutor	
SWITCHON SWITCHOFF	SwitchExecutor.check.switchable	
OPEN / CLOSE	OpenExecutor.check.openable	近接と CLOSED / OPEN に加え、開閉可能性 (desk・window の例外あり) を検査。OPEN では空いた手と ON 状態でないことも検査する。
PUT	_.check.puttable (ON)	保持と配置先への近接を検査。この実行器の対応操作名は PUTBACK であり、本データの PUT との別名同一性を Unity の実行仕様として仮定しない。
PUTIN	_.check.puttable (INSIDE)	保持・近接に加え、CAN.OPEN を持つ配置先には OPEN を要求する。辞書の単なる「not CLOSED」と同値とは限らない。

```
46 "9014": {
47   "states": [
48     "CLOSED"
49   ],
50   "on": null,
51   "inside": null,
52   "location": 9001,
53   "hold": []
54 }
55 },
56 "state_agent": {
57   "close_to": [
58     9002
59   ],
60   "hold_rh": null,
61   "hold_lh": null,
62   "location": 9001
63 },
64 "placement_agent": {
65   "close_to": [
66     9012,
67     9013
68   ],
69   "hold_rh": null,
70   "hold_lh": null,
71   "location": 9001
72 }
73 }
```

Listing 10

説明用の状態知識の出力 (実験ログではない)

```
1 The current states in the home are as follows:
2 The lightswitch (9002) is OFF and and is INSIDE the kitchen
  (9001).
3 You are INSIDE the kitchen (9001).
4 You are close to the lightswitch (9002).
```

Listing 11

説明用の配置知識の出力 (実験ログではない)

```
1 The current states in the home are as follows:
2 The plum (9012) is ON the kitchentable (9013) and and is
  INSIDE the kitchen (9001).
3 The kitchentable (9013) and is INSIDE the kitchen (9001).
4 plum (9012) is ON the kitchentable (9013).
5 The fridge (9014) is CLOSED and and is INSIDE the kitchen
  (9001).
6 You are INSIDE the kitchen (9001).
7 You are close to the plum (9012) and the kitchentable (9013).
```

Listing 12

両
Note-
book
で
共
通
す
る
自
然
言
語
化
関
数
の
全
文

```

1 def return_nlp(a, b):
2
3     env_prompt = "The current states in the home are as follows
4         : \n"
5     for id, knowledge in a.items():
6         text = "The " + objId_dic[id] + f" ({id})"
7
8         if knowledge["states"]:
9             text += f" is {knowledge['states'][0]} and"
10            if knowledge["on"]:
11                text += f" is ON the {objId_dic[knowledge['on']]}
12                ({knowledge['on']}) and"
13
14            elif knowledge["inside"]:
15                text += f" is INSIDE the {objId_dic[knowledge['
16                inside']]} ({knowledge['inside']}) and"
17
18            else:
19                if knowledge["on"]:
20                    text += f" is ON the {objId_dic[knowledge['on']]}
21                    ({knowledge['on']}) and"
22
23                elif knowledge["inside"]:
24                    text += f" is INSIDE the {objId_dic[knowledge['
25                    inside']]} ({knowledge['inside']}) and"
26
27                if knowledge["location"]:
28                    text += f" and is INSIDE the {objId_dic[knowledge['
29                    location']]} ({knowledge['location']})\n"
30
31            else:
32                text = ""
33
34            if knowledge["hold"]:
35                receptacle_type = "INSIDE" if "CONTAINERS" in
36                objProp_dic[id] else "ON"
37                text += f"{objId_dic[knowledge['hold']][0]} ({
38                knowledge['hold']})"
39                if len(knowledge["hold"]) > 1:
40                    for ho in knowledge["hold"][1:]:
41                        text += f" and {objId_dic[ho]} ({ho})"
42                text += f" are {receptacle_type} the {objId_dic[id
43                ]} ({id})\n"
44
45            else:
46                text += f" is {receptacle_type} the {objId_dic[id
47                ]} ({id})\n"
48
49            env_prompt += text
50
51            agent_prompt = f"You are INSIDE the {objId_dic[b['location
52            ']]} ({b['location']})\n"
53            if b["hold_rh"] and b["hold_lh"]:
54                agent_prompt += f"You are holding the {objId_dic[b['
55                hold_rh']]} ({b['hold_rh']}) in your right hand and
56                the {objId_dic[b['hold_lh']]} ({b['hold_lh']}) in
57                your left hand.\n"
58            elif b["hold_rh"]:
59                agent_prompt += f"You are holding the {objId_dic[b['
60                hold_rh']]} ({b['hold_rh']}) in your right hand.\n"
61            elif b["hold_lh"]:
62                agent_prompt += f"You are holding the {objId_dic[b['
63                hold_lh']]} ({b['hold_lh']}) in your left hand.\n"
64
65            if b["close_to"]:
66                agent_prompt += f"You are close to the {objId_dic[b['
67                close_to']]} ({b['close_to']})"
68                if len(b["close_to"]) > 1:
69                    for c in b["close_to"][1:]:
70                        agent_prompt += f" and the {objId_dic[c]} ({c})"
71            agent_prompt += ".\n"

```

```

55     env_prompt += agent_prompt
56
57     return env_prompt

```

A・4 過程別の記録と状態照合

実シーンでの状態変化 task6 と配置 task65 の環境知識全文、物体の所属部屋、人物位置、行動前後の状態・関係差分は付録 D に示す。構成要素比較の C1・GPT-4o・反復 0 に対応する例であり、合成例や基本性能評価の未保存入力とは区別する。構成要素比較では、候補判定に使う完全グラフと抽出辞書、前提条件判定の入力・応答、別要求の未充足条件、再生成の入力・応答、実行前後のグラフと VH 応答を、タスク・モデル・条件・反復・ステップに対応付けて記録した。C1-budget 等の条件に固有のメッセージ構成は付録 B・5 に示す。

棄却候補の状態照合では、候補判定時のグラフと、再実行イベントに付随する候補実行直前のグラフを比較した。結果要約の前状態欄は実装上、候補実行後の最後のグラフ取得を指していたため、照合対象として用いなかった。照合はノード ID・クラス・状態・属性と関係辺の一致を確認した上で、全ノードの位置差と四元数距離を評価する。具体的な距離の定義と候補別結果は付録 B・7 に示す。VH 成否や人手ラベルはこの照合によって変更していない。

A・5 実験資料と再現性

基本性能評価に関する提案手法の公開コード・データ・結果 JSON は Git コミット 2761158 に含まれ、README のみが異なる delfc8d を照合対象とした。各結果とテスト集合の ID は一致し、結果 JSON から計算した全 18 条件の SR・3 失敗率・平均列長の 90 値は掲載値と小数第 3 位まで一致する。ただし、実行ごとのコード版・日時・API 応答メタデータは記録されていない。

公開 Notebook は gpt-4o-mini というモデル別名と temperature 0.0 を指定する。Multi の評価ループは 1 件で停止する break を含み、Notebook の出力キーは action_script, 基本性能評価の結果 JSON のキーは action_script である。したがって、Notebook の無変更実行で全モデル・全条件の結果を再生成できるとはいえない。本文の処理仕様はこのコードに基づくもので、各試行の実装との完全な一致は確認できない。

基本性能評価の各タスク種別には、ベースライン 1 条件と Single / Multi・2 モデル・検証あり／なしの 8 条件の結果が対応する。ベースラインは Huang ら [Huang 22] の著者公開実装 (<https://github.com/huangwl18/language-planner>) を本研究のデータセットで実行したものであり、原著の報告値の転載ではない。この出所と実行対象は著者による確認に基づく。状態変化 312 件・配置 103 件のタスク別結果 JSON は本研究のテスト集合に対応する。一方、実験時に使用した公開実装のコミット、変更差分、GPT-4o への接続処理、Action Translation・Dynamic Example の具体的なモデル・候補集合・設定、自動探索・停止・結果記録処理の詳細は確認できない。公開リポジトリの現在のコードが入手可能であることと、実験時の実行コード・設定を特定できることは区別する。VH のバイナリ・シーンの固定版や、前提条件の各文と参照資料の対応にも記録がない。現在の公開実装の既定値、構成要素比較の設定や提案実装の検索・停止規則を、これらの不明な設定の代わりに用いない。構成要素比較で確認できる実行設定は付録 B・2 に示す。

著者への確認でも、これらの未確認事項を補う実験時の追加保有資料はなかった。利用できない範囲は、ベースラインの実験時コードの版・変更差分と詳細設定、各試行とコード版・日時の対応、モデル・生成設定・依存環境の実行記録、データの構築・除外・分割履歴、前提条件の原資料と転記・整形記録、途中候補・判定・グラフ、検索の実採択・重み版・候補順序、実験時 VH バイナリ・シーン・プラットフォームの対応である。ベースラインの独自再実装による別の結果への置換は行わず、著者公開実装を用いて得た結果と確認不能な範囲を開示する。保存結果の集計再現と、実験時条件の完全な再実行可能性は異なり、後者を達成したとは主張しない。

B. 実験条件と詳細結果

本付録では、S1・S6 を状態変化の test_task1・test_task6, P1・P65 を配置の test_task1・test_task65 の略記とする。mini は GPT-4o mini, 4o は GPT-4o を表す。

B.1 データの分布と行動列長

表 B.3 にシーン・初期部屋の周辺分布を示す。各区分の合計は状態変化のテスト 312・事例 152, 配置のテスト 103・事例 51 とな

る。部屋は人物の初期配置先であり、物体検索の範囲ではない。周辺分布を組合せの全網羅と解釈しない。

表表 B.4 では成功集合と失敗集合を分け、参照平均も各行と同じ集合から計算した。件数 0 の平均は「-」とする。表表 B.5 は検証あり／なしの両条件で成功したインスタンスだけを対応付けた平均である。成功集合の違いを除く記述的比較であり、成功率や失敗試行を含む総コストの比較ではない。

B.2 構成要素比較の実行設定

実行制御側は Python 3.12.3, spaCy 3.7.5, en_core_web_sm 3.7.1, inflection 0.5.1, NumPy 1.26.4, requests 2.32.4 を用いた。Windows 上の VH へ接続し、シーン番号から 1 を引いて初期化し、タスクの状態配列を上書きした後、表表 B.6 の座標に人物を配置した。同じ位置の参照列実行を比較基準とし、API 要求前に記号状態と全ノードの位置・姿勢を照合した。通信クライアントのコミットは 58970fd80951c2eaa1af713e0917d1a105353ad8 である。接続先 VH のバイナリ版は独立には確認できておらず、シーン・ID の互換性と状態照合を確認した範囲の評価である。

実行時には `findsolution=False`, 録画あり, カメラは `PERSON.FROM.BACK` とした。アニメーション省略と実行順ランダム化は要求の引数に指定せず、通信 API の既定設定を用いた。インフラ障害をタスク失敗と区別し、API・VH 要求の自動再試行は行わない。構成要素比較の 240 件には通信失敗はなかった。参照列長の 2 倍を実行予算とし、C3 では失敗実行も消費する。C3 の失敗後修復は予算が残る場合に限り 1 回行い、修復後の再失敗では終了する。

モデル ID は `gpt-4o-mini-2024-07-18` と `gpt-4o-2024-08-06`, temperature は 0, 要求ごとの出力上限は 256 トークンである。反復ごとにタスク・モデルの 8 ブロックを並べ替え、各ブロック内の 10 条件も並べ替える。Python の疑似乱数生成器を seed 20260907 で初期化し、同じ生成器を 3 反復にわたって用いる。並べ替え前の列挙順は S1, S6, P1, P65, モデルは mini, 4o, 条件は C0, C1, C2, C3, C1-budget, C4-budget, C5, R-random, R-fixed, R-none である。

費用は入力・出力トークン数に記録時点の通常単価を掛けて計算した。100 万トークン当たり mini は入力 0.15・出力 0.60 米ドル, 4o は入力 2.50・出力 10.00 米ドルで、キャッシュ割引を適用しない推定値である。240 件の合計は入力 1052576・出力 30594 トークン, 1.681766 米ドルであり、研究全体の費用ではない。

表表 B.7 の各反復の分母は 4 である。参照成功集合の分母 9 は P1 を除く 3 タスクの各 3 反復からなる。各モデル・条件について、反復別成功数の和は本文の分母 12 の成功数と一致する。

B.3 検索条件と選択事例

意味類似検索は MiniLM によるタスク名のコサイン類似度を用い、選択名に属する事例のうち最長の行動列を採用する。長さ同点ではデータの格納順で先の事例を選ぶ。表表 B.8 の上位差は第 1 位と第 2 位のコサイン類似度の差である。固定検索は候補名を辞書順に並べた最初の名前を使い、状態変化では「Turn off all candles」、配置では「Put all apples in the fridge」となる。none は事例の user メッセージを空文字列にする。

ランダム検索は異なる候補名から一様に 1 名選び、その名前の最長列を採用する。反復別に、文字列 20260906/種別/タスク ID/反復の UTF-8 バイト列の SHA-256 の先頭 16 桁を 16 進整数として seed にする。種別は `state_change_task` または `placement_task`, タスク ID は `test_task1` 等、反復は 0, 1, 2 である。Python の `random.Random(seed).choice` を辞書順の候補名リストへ適用する。選択は両モデルで共通とし、表表 B.9 に具体的な名前を示す。

B.4 記号判定とラベルの定義

条件辞書の 8 操作を原子条件に分解する。WALK は非保持, GRAB は近接と非保持, SWITCHON は近接と OFF, SWITCHOFF は近接と ON, OPEN は近接と CLOSED, CLOSE は近接と OPEN, PUT は対象の保持と配置先への近接, PUTIN はそれらと配置先が CLOSED でないことを要求する。いずれかの原子が false なら false, false がなく unknown があれば unknown, 全原子が true なら true とする。

C2 は抽出辞書を入力とする。近接は抽出対象に ID がなければ unknown, 保持は左右の手の ID との一致、状態は配列が空または欠落なら unknown として判定する。C5 は全ノードと人物 ID 1 の CLOSE・HOLDS_RH・HOLDS_LH 関係を使う。完全グラフの空状態集合は既知の空集合として扱うため、例えば CLOSED でないとい

う否定条件を true とできる点が C2 と異なる。形式不正と条件の情報不足は区別する。

C2 / C5 は true のみを受理し、それ以外は 1 回の再生成へ進む。C2 では false の条件文に続けて unknown の条件を Cannot determine from the available knowledge: という接頭辞付きで列挙する。C5 は false と unknown の条件文をそのまま列挙する。その文字列を Listing 5 の理由へ代入する。これは物理形状や操作適合性を含む VH の全制約の検査ではない。

LLM の正答数は Yes を含む受理と上記 true / false の一致を数え、unknown を分母から除く。誤受理は false に対する受理、誤棄却は true に対する棄却である。終了判定は厳密な End とゴール充足を照合し、非 End と End/Continue 以外の書式違反も区別する。

B.5 比較条件固有のプロンプト

C0・C1・C2・C5 および検索条件の生成・終了・再生成メッセージは付録 A.1 を基礎とする。C3 は失敗後のグラフを再抽出して生成時の環境メッセージを置換し、次の固定文、改行, VH が返した失敗応答の JSON 文字列を理由として再生成へ渡す。

1 The simulator returned failure for this action. The environment knowledge has been refreshed. Revise once.

C1-budget は候補生成の後、Listing 3 の user 入力だけで条件をレビューする。操作が条件辞書にない場合は system を付け、環境文、改行, Candidate: と候補, 改行, Check the output format. Reply Yes or No. を user 入力にする。続いて、レビュー時のメッセージ、その assistant 応答、次の user 文を送る。

1 Briefly explain the satisfied, violated or unknown conditions. If all are satisfied, say so.

C4-budget は system を付け、環境文に続けて改行ごとに Task: と指示, Candidate: と候補, 次のレビュー文を user 入力とする。

1 Review whether this candidate is a sensible next step for the task. Reply Yes or No. Do not use a supplied precondition checklist.

そのメッセージと assistant 応答に、次の user 文を追加する。

1 Briefly explain whether to retain or revise this candidate based on the task and current knowledge.

両 budget 条件はレビューが Yes でも再生成する。再生成は system, 生成時の 5 個の user, 候補 assistant, 説明応答をそのまま入れた user, 最後の生成指示の Generate を Regenerate へ置換した user の順とする。レビューの system は Listing ?? の SYSTEM, 再生成の system は末尾空白付きの CHAT_SYSTEM を用いる。条件違反を断定する追加文は説明に付けない。生成・レビュー・説明・再生成の 4 要求を各 256 トークン上限とし、終了判定の要求は別に数える。

B.6 固定入力による前提条件評価

静的評価は 8 操作の充足例各 1 件と、16 原子条件の一つずつ違反させた 16 件の計 24 入力を用いる。さらに SWITCHON, SWITCHOFF, OPEN, CLOSE について対象の状態を欠落させた 4 入力を用い、unknown として精度の分母から除く。各入力を 2 モデルで 3 反復し、temperature 0, 出力上限 160 トークン、自動再試行なしで問い合わせる。既知ラベルは各モデル 72 判定、除外は 12 判定となる。

物体は apple 101, fridge 102, lightswitch 103, kitchentable 104, 部屋は kitchen 900 とする。基本状態は全物体に近接、両手は空, fridge は CLOSED, lightswitch は OFF, apple と kitchentable の状態配列は空で、すべて kitchen に所属する。fridge だけに CONTAINERS 属性を与える。充足例では SWITCHOFF のみ lightswitch を ON, CLOSE と PUTIN では fridge を OPEN, PUT と PUTIN では apple を保持に変更する。対象は WALK・GRAB では apple, SWITCHON・SWITCHOFF では lightswitch, OPEN・CLOSE では fridge, PUT では apple と kitchentable, PUTIN では apple と fridge とする。

各違反例は対応する充足例から、非保持違反なら apple を保持, 保持違反なら保持を空, 近接違反なら近接集合を空, 状態違反なら ON/OFF または OPEN/CLOSE を反転する。unknown 例では対象状態を欠落させ、自然言語化では状態を述べない。支持・包含関係は付与しない。付録 A.3 の変換と Listing 3 の要求を用いる。既知の正解は true 8 入力・false 16 入力であり、3 反復の正答は mini で true 24・false 27 の 51/72, 4o で true 24・false 29 の 53/72 だった。

表 B.3 シーン・初期部屋別のインスタンス数

区分	値	状態テスト	状態事例	配置テスト	配置事例
シーン	1	48	36	25	14
シーン	2	40	28	17	8
シーン	3	72	28	14	7
シーン	4	32	12	18	12
シーン	5	44	16	8	4
シーン	6	40	12	5	3
シーン	7	36	20	16	3
初期部屋	bathroom	69	34	26	8
初期部屋	bedroom	72	52	24	13
初期部屋	kitchen	86	35	29	17
初期部屋	livingroom	85	31	24	13

表 B.4 全 18 条件の成功・失敗別行動列長（参照平均も各行と同じ集合で計算）

タスク	提示	モデル	検証	成功数	成功平均	参照平均	失敗数	失敗平均	参照平均
状態	Baseline	4o	—	10	0.000	0.000	302	10.828	4.000
状態	Single	mini	あり	195	3.969	3.662	117	6.043	4.222
状態	Single	4o	あり	246	3.923	3.927	66	6.091	3.667
状態	Multi	mini	あり	234	4.179	3.735	78	7.128	4.282
状態	Multi	4o	あり	279	3.584	3.878	33	1.758	3.818
状態	Single	mini	なし	192	4.203	3.792	120	5.942	4.000
状態	Single	4o	なし	237	3.979	3.932	75	5.933	3.680
状態	Multi	mini	なし	217	4.558	4.028	95	6.274	3.516
状態	Multi	4o	なし	272	3.673	3.882	40	2.150	3.800
配置	Baseline	4o	—	0	—	—	103	15.398	9.175
配置	Single	mini	あり	48	8.625	8.771	55	6.109	9.527
配置	Single	4o	あり	76	8.868	9.329	27	5.852	8.741
配置	Multi	mini	あり	42	7.929	8.548	61	5.426	9.607
配置	Multi	4o	あり	84	8.976	9.333	19	5.158	8.474
配置	Single	mini	なし	49	7.490	8.286	54	5.778	9.981
配置	Single	4o	なし	70	8.671	9.029	33	4.455	9.485
配置	Multi	mini	なし	45	7.578	8.400	58	5.017	9.776
配置	Multi	4o	なし	82	8.390	9.305	21	5.333	8.667

B.7 棄却候補の状態照合と人手確認

表表 B.10 の r は反復番号, $step$ は候補を判定したステップを表す. $C1$ は LLM 検証, Rf は R-fixed, Rr は R-random である. 同じ ID 集合の各ノードについてクラス・状態・属性と関係辺を比較し, 順序だけの違いを除いた一致を記号一致とする. 位置差は全ノードのユークリッド距離の最大, 姿勢差は四元数の符号同値を考慮した $\min(\|q_1 - q_2\|, \|q_1 + q_2\|)$ の全ノード最大である. 全ノードに位置・姿勢があり, 記号一致, 位置差 0.001 以下, 姿勢差 0.0001 以下の場合だけ状態一致とする. 距離は表示桁へ丸める前に判定する. 候補実行前にこの検査を行ったものではなく, 記録グラフの事後比較である.

実行直前照合を条件とする評価を表表 B.11 に示す. 候補の番号・行動・モデル・条件・反復は表表 B.10 と同じである. 各候補につき 1 回だけ初期化と成功接頭列の再生を行い, 記号一致・位置差 0.001 以下・姿勢差 0.0001 以下を実行の条件とした. 候補判定に用いたグラフの取得を実行前の最後の RPC とし, 通過時だけ候補を実行して実行後グラフを取得した. 人物追加後の途中グラフ転送や自動再試行は行わない. 全 8 件で初期化照合が通過し, 接頭列の計 15 行動はすべて成功した. 候補は 2 件だけ実行し, 6 件は状態不一致のため未実行だった. 通信エラーと API 要求は 0 件で, API 費用は 0 米ドルである. 照合通過した 2 件は接頭行動数 0 の候補であり, 途中状態を復元できたとは結論しない. グラフで観測できない物理内部状態の一致も保証しない.

判定応答の人手確認では, 上記 8 候補について同じステップの抽出知識・完全グラフ・条件辞書と判定応答を照合するよう依頼した. ラベルは, 主要主張が状態と一致し重要な見落としがない場合を「正

しい」, 一部は一致するが重要な誤り・見落としがある場合を「一部正しい」, 中心的理由が状態と反対または存在しない事実に基づく場合を「誤り」, 応答・状態情報が不足して検証できない場合を「判断不能」とした. 著者 ugai による 2026 年 9 月 7 日のこの票への記入は全 8 件「判断不能」, 根拠「情報が不十分」である. 未充足条件応答の確認記録とは区別する.

表表 B.12 は判定応答と, 別要求で得られた未充足条件の応答を区別して示す. 4 番の判定応答は, `cupcake` の保持が入力から確認できない一方, 配置先への近接と `OPEN` は確認できると述べ, 最後に `No` と結論する文章だった. 表の「条件別説明付き `No`」はこの応答の要約である. 他 7 件の判定は `No` または `No.` のみだった. 未充足条件応答は全文を示し, この応答を対象とする著者の確認記録とその制約を付録 B.7.1 に示す.

接頭列方式で不一致だった 6 件を対象とする, 人物のいないシーンへの保存グラフ復元を表表 B.13 に示す. 元タスクのシーンへリセットし, 人物がいないことを確認してから, 候補時点の完全グラフを `animate_character=True`, `transfer_transform=True`, `randomize=False` で 1 回だけ転送した. 実行直前の最後のグラフ取得で表表 B.11 と同じ照合を行い, 通過時だけ候補を実行した. 全 6 件の初期化と転送要求は応答成功で, 通信エラー・API 要求は 0 件だったが, 転送の成功応答だけを復元成功とは扱わない. 4 件は状態不一致のため候補未実行である.

接頭列方式で通過した 3・7 番と復元方式で通過した 6・8 番を合わせ, 異なる 4 候補で実行直前の照合が通過し, 4 件とも VH 成功だった. 8 件の接頭列方式と不一致 6 件の復元方式は同じ候補を含む段階的な診断であり, 14 件の独立試行として合算しない. 試行結

表 B.5 検証あり／なしの共通成功集合における平均行動列長

タスク	提示	モデル	共通成功数	検証あり	検証なし	参照
状態	Single	mini	161	3.826	3.919	3.627
状態	Single	4o	220	3.777	3.886	3.909
状態	Multi	mini	186	4.027	4.220	3.796
状態	Multi	4o	267	3.584	3.678	3.888
配置	Single	mini	42	8.119	7.571	8.333
配置	Single	4o	64	8.734	8.703	9.078
配置	Multi	mini	36	7.694	7.306	8.000
配置	Multi	4o	78	8.872	8.397	9.346

表 B.6 固定した人物位置（VH 座標）

タスク	x	y	z
S1	2.90539312	1.25	-5.62809753
S6	-2.41545	1.25	-7.44353151
P1	-6.287474	1.247	0.1396097
P65	9.582918	1.25	-4.21981239

果の確認後に、評価範囲を照合通過 4 件と本手順で未再現だった 1・2・4・5 番の開示に限定した。照合基準を緩めたり FACING 辺を除外したりして通過数を増やしていない。全 8 件の同一状態復元や、未選択 51 候補の評価を達成したとはせず、通過 4 件の成功を母集団の誤棄却率とは解釈しない。接頭列方式では人物の位置・姿勢が変化した例があり、同じ行動列の再生だけでは状態一致を保証できない。一方、今回の全差異をアバター動作の変動のみで因果的に説明したものではなく、グラフに現れない内部状態の一致も未確認である。

§1 未充足条件応答に対する著者の確認記録

表表 B.14 は、表表 B.12 の未充足条件応答そのものを対象とした著者 ugai による 2026 年 9 月 7 日の記入である。同じ 8 候補について要求メッセージ全文、応答全文、抽出辞書、関連する完全グラフの状態・関係を提示した。採点基準は、未充足条件の列挙と網羅が妥当なら「正しい」、妥当な部分と誤り・欠落があれば「一部正しい」、主要な説明が不適切なら「誤り」、資料でも判断できなければ「判断不能」とした。根拠・評価者・日付も記録した。表の根拠は著者記入のまま示し、AI による修正文や正解ラベルへ置き換えていない。

評価者は最初に応答文と現在状態の一致で採点したと申告したため、その票（正しい 2 件・誤り 6 件）と未充足条件としての再確認票を分けた。再確認では AI 支援による採点基準の説明と個別例の整合性照会を複数回行い、著者がラベル・根拠を修正した。従って同一著者の支援付き事例確認であり、独立評価・盲検評価ではない。判定応答を対象にした全 8 件「判断不能」の票とも合算しない。著者の最終記入は正しい 1 件、一部正しい 0 件、誤り 7 件、判断不能 0 件である。

この記入結果は説明品質の正解ラベル集合として確定したものではない。例えば 4 番は非保持を示す根拠、6・8 番は近接が必要という根拠を記しているが、それだけでは保持・近接を未充足条件として列挙した応答を誤りとする理由を十分に説明しない。評価対象の読み方と根拠の対応に曖昧さが残り、第三者による裁定も行っていない。著者の判断記録として提示するにとどめ、この比率を説明の確定正解率としたり、全 59 候補への推定値や VH 実行可能性の正解率としたりしない。評価者間一致率も算出しない。

B.8 記録行動列の再生

表表 B.15 は、基本性能評価の Multi・検証ありで得た 8 列の固定位置再生である。表表 B.10 の未実行候補の再実行とは区別する。列長 0 の 2 件も行動を要しない再生として含め、8 列すべてを末尾まで再生できた。失敗した最後の未記録行動と生成時の人物位置は再生対象に含めない。

表 B.7 反復別の成功数と参照成功タスクに限定した成功数

条件	mini	r0	r1	r2	参照成功/9	4o	r0	r1	r2	参照成功/9
C0		2	3	3		8	3	3	3	9
C1		3	3	3		9	3	3	3	9
C2		1	1	2		4	3	4	3	9
C3		2	2	1		5	3	3	3	9
C1-budget		2	1	1		4	4	3	4	9
C4-budget		2	2	2		6	4	3	3	9
C5		1	2	2		5	3	3	3	9
R-random		3	2	3		5	3	3	3	9
R-fixed		2	2	3		6	3	3	3	9
R-none		1	1	1		3	1	1	1	3

表 B.8 意味類似検索で選択した事例

タスク	選択した指示	類似度	上位差	列長
S1	Turn on all tablelamps	0.611	0.066	6
S6	Turn on all tablelamps	0.611	0.066	6
P1	Put all cupcakes on the kitchentable	0.854	0.049	8
P65	Put all plums on the kitchentable	0.761	0.098	8

表 B.9 ランダム検索で選択した指示（両モデル共通）

タスク	反復 0	反復 1	反復 2
S1	Turn on all tablelamps	Turn off all faucets	Turn off all faucets
S6	Turn on all computers	Turn off all faucets	Turn on all tablelamps
P1	Put all bananas on the kitchentable	Put all crackers on the coffeetable	Put all plums on the coffeetable
P65	Put all plums on the coffeetable	Put all bananas on the kitchentable	Put all chips on the coffeetable

表 B.10 棄却候補 8 件の再実行と状態照合（○：一致または成功，×：不一致または失敗）

番号	タスク	モデル	条件	r	step	候補	記号	位置差	姿勢差	状態	VH
1	S6	4o	C1	0	4	[SWITCHON] <lightswitch> (261)	×	0.506386	0.076625	×	○
2	S6	mini	C1	0	4	[SWITCHON] <lightswitch> (261)	×	0.119574	0.007552	×	○
3	S6	4o	Rf	0	1	[SWITCHON] <lightswitch> (261)	○	0.000000	0.000000	○	○
4	P1	mini	Rf	1	7	[PUTIN] <cupcake> (195) <kitchencounter> (238)	○	0.010881	0.003474	×	×
5	P1	mini	Rr	2	2	[OPEN] <desk> (108)	○	0.074607	0.042299	×	×
6	P65	4o	C1	0	2	[OPEN] <fridge> (103)	○	0.037343	1.297491	×	○
7	P65	mini	C1	0	1	[WALK] <kitchencounter> (92)	○	0.000000	0.000000	○	○
8	P65	4o	Rf	0	2	[OPEN] <fridge> (103)	○	0.095187	0.543762	×	○

Algorithm 1 公開実装の 1 タスクの処理（正常に解析できる入力について）**Input:** タスクインスタンス T , 検証使用フラグ p

```

1: シーン  $T.scene - 1$  を初期化し, 状態配列を上書きして初期部屋にエージェントを配置
2: 指示中の関連名詞  $R$  と検索事例  $E$  を取得
3:  $M \leftarrow 2|T.action\_scripts|$ ,  $n \leftarrow 1$ , 成功実行履歴  $H \leftarrow []$ 
4: while true do
5:    $G \leftarrow \text{GetEnvironmentGraph}()$ 
6:    $K \leftarrow \text{Serialize}(\text{Extract}(G, R))$ 
7:    $c \leftarrow \text{LLMEndCheck}(K, T.task)$ 
8:   if  $c$  が文字列 End と完全一致 then
9:     if  $n = 1$  かつ  $M = 0$  then
10:      return Success,  $H$  ▷ グラフの採点を省略する特例
11:     end if
12:     グラフを再取得して通常のゴール採点を行い, Success または Erroneous Terminate と  $H$  を返す
13:   else if  $c$  が Continue と完全一致, かつ  $M = 0$  then
14:     return Reaching Maximum Attempts,  $H$ 
15:   end if
16:    $a \leftarrow \text{LLMGenerate}(K, T.task, E, H, n)$ 
17:   if  $p$  then
18:     if  $a$  の操作名が条件辞書にない then
19:        $a \leftarrow \text{LLMRegenerate}(a, \text{形式不正}, K, T.task, E, H, n)$ 
20:     else
21:        $q \leftarrow \text{LLMPreCheck}(K, \text{BindConditions}(a))$ 
22:       if  $q$  に部分文字列 Yes が含まれない then
23:          $u \leftarrow \text{LLMUnmetConditions}(K, q, a)$ 
24:          $a \leftarrow \text{LLMRegenerate}(a, u, K, T.task, E, H, n)$ 
25:       end if
26:     end if
27:   end if
28:    $s \leftarrow \text{Execute}(a)$  ▷ 再生成後も再検証しない
29:   if  $s$  が成功でない then
30:     return Execution Failure,  $H$ 
31:   end if
32:    $a$  を  $H$  とプロンプト内の実行履歴に追加
33:   if  $n \geq M$  then
34:     return Reaching Maximum Attempts,  $H$ 
35:   end if
36:    $n \leftarrow n + 1$ 
37: end while

```

Algorithm 2 公開コードの知識抽出

Input: 現在のグラフ G , 指示から得た名詞・単数形候補 R

- 1: $O \leftarrow$ クラス名が R に含まれるノードの記録, $A \leftarrow \emptyset$
 - 2: **for** G の各辺 (u, r, v) を格納順に **do**
 - 3: **if** $u \in O$ **then**
 - 4: ON なら支持物を記録し v を A へ追加 (walk, floor は除外)
 - 5: INSIDE なら 4 部屋クラスへの辺を所属部屋として記録
 - 6: 部屋以外への INSIDE なら容器を記録し v を A へ追加
 - 7: **end if**
 - 8: $u, v \in O$ かつ $r \in \{\text{ON}, \text{INSIDE}\}$ なら v の保持対象に u を追加
 - 9: **end for**
 - 10: nodes 順に A のノードを O へ追加 (既存の記録も初期化)
 - 11: **for** G の各辺 (u, r, v) を格納順に **do**
 - 12: $u \in A$ について支持物・容器・所属部屋を記録 (A は追加拡張しない)
 - 13: $v \in A, u \in O$ かつ $r \in \{\text{ON}, \text{INSIDE}\}$ なら v の保持対象に u を追加
 - 14: **end for**
 - 15: ID 1 の出辺から左右の保持物, 4 部屋クラスへの INSIDE, O への CLOSE を取得して B とする
 - 16: **return** O, B
-

表 B.11 実行直前照合を条件とした代表候補評価（番号は表表 B.10 に対応）

番号	接頭数	記号	位置差	姿勢差	候補結果
1	3	×	0.419929	0.035789	未実行
2	3	○	0.091742	0.020617	未実行
3	0	○	0.000000	0.000000	成功
4	6	○	0.247181	0.045965	未実行
5	1	○	0.041228	0.025620	未実行
6	1	○	0.101502	0.920426	未実行
7	0	○	0.000000	0.000000	成功
8	1	○	0.058573	0.206024	未実行

表 B.12 代表候補の判定応答と未充足条件応答（番号は表表 B.10 と共通）

番号	判定応答	別要求の未充足条件応答（全文）
1	No.	<lightswitch> (261) is OFF.
2	No	<lightswitch> (261) is ON.
3	No	<lightswitch> (261) is OFF.
4	条件別説明付き No	You are holding <cupcake> (195) in your right hand or left hand.
5	No	<desk> (108) is CLOSED.
6	No.	You are close to <fridge> (103).
7	No	The precondition that <kitchencounter> (92) is not held in your right hand or left hand is not satisfied.
8	No.	You are close to <fridge> (103).

表 B.13 人物のいないシーンへの候補時点グラフ復元（番号は表表 B.10 と共通）

番号	記号	最大位置差	最大姿勢差	候補結果	不一致の観測
1	×	1.910×10^{-6}	0	未実行	保存グラフにあった FACING 辺 7 本が欠落
2	×	1.910×10^{-6}	0	未実行	保存グラフにあった FACING 辺 14 本が欠落
4	×	1.237802	0.910223	未実行	cupcake 195 の位置・姿勢と ON desk 108 関係が不一致
5	×	2.000×10^{-6}	3.000×10^{-8}	未実行	FACING 辺 1 本が追加
6	○	0	0	成功	許容差内で一致
8	○	0	7.021×10^{-8}	成功	許容差内で一致

表 B.14 未充足条件応答への著者記入ラベルと根拠（番号は表表 B.12 と共通）

番号	著者ラベル	著者記入の根拠
1	正しい	The lightswitch (261) is ON and and is INSIDE the kitchen (205).
2	誤り	The lightswitch (261) is ON and and is INSIDE the kitchen (205). Both conditions are required
3	誤り	The lightswitch (261) is ON and and is INSIDE the kitchen (205). Both conditions are required
4	誤り	cupcake (196) and cupcake (195) are ON the desk (108).
5	誤り	The desk (108) is CLOSED
6	誤り	You are INSIDE the kitchen (11). しかし、冷蔵庫に近いも必要
7	誤り	The precondition that <kitchencounter> (92) is not held in your right hand or left hand is not satisfied. ではなく、プラムがキッチンにあるのでキッチンに歩く
8	誤り	You are INSIDE the kitchen (11). だが冷蔵庫に近いも必要

表 B.15 記録行動列 8 本の再生と最終ゴール（全列の再生は成功）

タスク	モデル	列長	最終ゴール
P1	mini	1	未達
P1	4o	4	未達
P65	mini	5	未達
P65	4o	10	充足
S1	mini	0	充足
S1	4o	0	充足
S6	mini	5	充足
S6	4o	4	充足

C. 分布・対応比較・データ網羅の詳細

本付録の数値は基本性能評価の同じ結果ラベルと記録列から求めた。M1–M18 は表表 C.16 の条件、S/F は成功／失敗、E/R/T は Execution Failure / Reaching Maximum Attempts / Erroneous Terminate を表す。SD は標本標準偏差、IQR は第 3 四分位点と第 1 四分位点の差で、四分位点はソート後の位置 $(n-1)p$ を線形補間した。空集合の統計と 1 件以下の SD は未定義 (–) であり、0 ではない。

表 C.16: 詳細集計に用いる条件番号

番号	タスク	提示	モデル	検証
M1	状態	Baseline	4o	–
M2	状態	Single	mini	あり
M3	状態	Single	4o	あり
M4	状態	Multi	mini	あり
M5	状態	Multi	4o	あり
M6	状態	Single	mini	なし
M7	状態	Single	4o	なし
M8	状態	Multi	mini	なし
M9	状態	Multi	4o	なし
M10	配置	Baseline	4o	–
M11	配置	Single	mini	あり
M12	配置	Single	4o	あり
M13	配置	Multi	mini	あり
M14	配置	Multi	4o	あり
M15	配置	Single	mini	なし
M16	配置	Single	4o	なし
M17	配置	Multi	mini	なし
M18	配置	Multi	4o	なし

表 C.17: 成功・失敗別の列長分布

条件	結果	n	記録中央値	SD	IQR	参照中央値	SD	IQR
M1	S	10	0.000	0.000	0.000	0.000	0.000	0.000
M1	F	302	20.000	9.816	20.000	4.000	2.088	4.000
M2	S	195	4.000	2.568	4.000	4.000	2.194	4.000
M2	F	117	4.000	4.780	6.000	4.000	2.097	4.000
M3	S	246	4.000	2.447	3.750	4.000	2.216	4.000
M3	F	66	4.000	4.488	4.000	4.000	2.003	2.000
M4	S	234	4.000	2.507	4.000	4.000	2.157	4.000
M4	F	78	8.000	4.924	9.000	4.000	2.180	4.000
M5	S	279	3.000	2.122	3.000	4.000	2.238	4.000
M5	F	33	1.000	2.062	2.000	4.000	1.530	2.000
M6	S	192	4.000	2.775	4.000	4.000	2.297	4.000
M6	F	120	4.000	4.314	4.000	4.000	1.958	4.000
M7	S	237	3.000	2.645	4.000	4.000	2.276	4.000
M7	F	75	8.000	4.147	6.000	4.000	1.802	2.000
M8	S	217	4.000	2.965	5.000	4.000	2.305	4.000
M8	F	95	5.000	3.945	4.000	4.000	1.792	2.000
M9	S	272	3.000	2.250	3.000	4.000	2.197	4.000
M9	F	40	2.000	1.929	3.000	4.000	2.015	2.000
M10	S	0	–	–	–	–	–	–
M10	F	103	20.000	7.198	9.500	8.000	3.451	1.000
M11	S	48	8.000	2.655	1.250	8.000	2.528	1.000
M11	F	55	5.000	3.680	4.000	8.000	4.082	1.000
M12	S	76	8.000	2.282	2.000	8.000	3.130	1.000
M12	F	27	5.000	4.605	5.500	8.000	4.266	1.000
M13	S	42	8.000	2.213	2.000	8.000	3.102	1.000
M13	F	61	5.000	3.339	3.000	9.000	3.634	1.000
M14	S	84	8.000	2.464	2.000	8.000	3.031	1.000
M14	F	19	3.000	9.161	4.500	8.000	4.948	1.000
M15	S	49	8.000	1.816	1.000	8.000	1.720	1.000
M15	F	54	4.500	3.790	3.000	9.000	4.342	3.250
M16	S	70	8.000	2.749	1.750	8.000	2.576	1.000
M16	F	33	3.000	4.206	4.000	8.000	4.848	1.000
M17	S	45	8.000	2.210	1.000	8.000	2.016	1.000
M17	F	58	4.000	2.711	2.750	8.000	4.164	1.000
M18	S	82	8.000	2.308	2.000	8.000	3.054	1.000
M18	F	21	2.000	10.155	4.000	8.000	4.757	1.000

表 C.18: 失敗類型別の列長

条件	類型	n	記録平均	中央値	SD	IQR	参照平均
M1	E	0	–	–	–	–	–
M1	R	167	19.329	20.000	2.999	0.000	3.677
M1	T	135	0.311	0.000	1.953	0.000	4.400
M2	E	8	0.875	1.000	0.835	1.250	3.000
M2	R	72	8.500	8.000	4.399	8.000	4.250
M2	T	37	2.378	2.000	1.876	4.000	4.432
M3	E	5	1.000	1.000	0.707	0.000	4.800
M3	R	54	7.259	8.000	4.117	7.000	3.630
M3	T	7	0.714	1.000	0.756	1.000	3.143
M4	E	14	2.000	1.500	1.519	1.750	4.000
M4	R	57	9.123	8.000	4.192	4.000	4.561
M4	T	7	1.143	1.000	1.069	1.000	2.571
M5	E	6	2.333	1.000	3.777	0.000	3.667
M5	R	0	–	–	–	–	–
M5	T	27	1.630	1.000	1.548	2.000	3.852
M6	E	1	5.000	5.000	–	0.000	4.000
M6	R	79	7.747	8.000	4.068	8.000	3.873
M6	T	40	2.400	2.000	2.048	4.000	4.250
M7	E	5	1.200	1.000	0.447	0.000	5.200
M7	R	59	7.254	8.000	3.675	4.000	3.627
M7	T	11	1.000	1.000	0.775	1.000	3.273
M8	E	5	3.000	3.000	1.414	0.000	3.200
M8	R	79	7.139	8.000	3.717	4.000	3.570
M8	T	11	1.545	1.000	1.368	2.000	3.273
M9	E	3	0.667	1.000	0.577	0.500	2.000
M9	R	5	4.000	4.000	0.000	0.000	2.000
M9	T	32	2.000	2.000	1.967	1.500	4.250
M10	E	1	13.000	13.000	–	0.000	8.000
M10	R	59	19.678	20.000	1.345	0.000	7.915
M10	T	43	9.581	9.000	7.926	19.000	10.930
M11	E	15	5.000	5.000	2.976	3.000	8.467
M11	R	3	5.333	0.000	9.238	8.000	2.667
M11	T	37	6.622	6.000	3.361	4.000	10.514

条件	類型	n	記録平均	中央値	SD	IQR	参照平均
M12	E	12	4.417	4.000	2.778	4.000	8.333
M12	R	3	5.333	0.000	9.238	8.000	2.667
M12	T	12	7.417	7.000	4.680	5.250	10.667
M13	E	12	3.083	2.500	2.466	4.000	9.417
M13	R	3	10.667	16.000	9.238	8.000	5.333
M13	T	46	5.696	5.000	2.493	3.000	9.935
M14	E	12	2.500	2.000	2.276	3.000	8.250
M14	R	2	0.000	0.000	0.000	0.000	0.000
M14	T	5	13.600	8.000	15.485	2.000	12.400
M15	E	12	4.500	5.000	1.883	1.250	8.583
M15	R	2	8.000	8.000	11.314	8.000	4.000
M15	T	40	6.050	4.000	3.796	3.250	10.700
M16	E	17	2.529	2.000	2.211	2.000	9.471
M16	R	3	5.333	0.000	9.238	8.000	2.667
M16	T	13	6.769	6.000	3.898	4.000	11.077
M17	E	13	3.692	3.000	3.521	4.000	8.308
M17	R	1	0.000	0.000	-	0.000	0.000
M17	T	44	5.523	5.000	2.215	3.250	10.432
M18	E	12	2.000	2.000	1.477	1.250	8.583
M18	R	3	16.000	0.000	27.713	24.000	8.000
M18	T	6	6.667	7.000	1.862	2.250	9.167

C.1 参照列との差と比

差 $D = L_{exec} - L_{ref}$ は同一 ID ごとに計算する。比 $Q = L_{exec}/L_{ref}$ は参照長が正の ID だけを用い、表の n_Q を分母とする。状態変化 27 件・配置 2 件の参照長 0 は比から除く。成功・失敗ごとに平均の比ではなく各 ID の比を平均する。手法間で成功集合が異なるため、表表 B.5 の共通成功集合による比較も併用する。

表 C.19: 同一 ID での列長差と比

条件	結果	n_D	D 平均	中央値	SD	IQR	n_Q	Q 平均	中央値	SD	IQR
M1	S	10	0.000	0.000	0.000	0.000	0	-	-	-	-
M1	F	302	6.828	12.000	10.259	20.000	285	3.087	2.500	3.540	5.000
M2	S	195	0.308	0.000	1.009	0.000	172	1.081	1.000	0.231	0.000
M2	F	117	1.821	2.000	3.708	5.000	113	1.395	2.000	0.778	1.333
M3	S	246	-0.004	0.000	1.024	1.000	223	0.994	1.000	0.255	0.167
M3	F	66	2.424	2.000	3.239	2.000	62	1.653	2.000	0.719	0.000
M4	S	234	0.444	0.000	1.084	1.000	209	1.127	1.000	0.248	0.250
M4	F	78	2.846	4.000	3.476	6.000	76	1.586	2.000	0.698	1.042
M5	S	279	-0.294	0.000	0.678	1.000	252	0.929	1.000	0.193	0.167
M5	F	33	-2.061	-2.000	1.298	1.000	33	0.370	0.250	0.345	0.500
M6	S	192	0.411	0.000	1.089	0.000	167	1.093	1.000	0.233	0.167
M6	F	120	1.942	2.000	3.252	5.250	118	1.476	2.000	0.753	1.250
M7	S	237	0.046	0.000	1.266	1.000	214	1.005	1.000	0.300	0.167
M7	F	75	2.253	4.000	3.180	4.000	71	1.610	2.000	0.733	0.000
M8	S	217	0.530	0.000	1.371	1.000	194	1.109	1.000	0.275	0.250
M8	F	95	2.758	2.000	2.517	2.000	91	1.749	2.000	0.571	0.000
M9	S	272	-0.210	0.000	0.853	1.000	245	0.942	1.000	0.227	0.167
M9	F	40	-1.650	-2.000	1.642	2.000	40	0.590	0.500	0.602	0.417
M10	S	0	-	-	-	-	0	-	-	-	-
M10	F	103	6.223	11.000	7.863	11.000	101	1.742	2.222	0.905	1.375
M11	S	48	-0.146	0.000	1.052	1.000	48	0.990	1.000	0.159	0.111
M11	F	55	-3.418	-4.000	3.023	1.000	53	0.637	0.556	0.313	0.192
M12	S	76	-0.461	0.000	2.068	1.000	76	0.969	1.000	0.160	0.111
M12	F	27	-2.889	-4.000	3.274	2.500	25	0.651	0.615	0.403	0.250
M13	S	42	-0.619	0.000	1.821	1.000	41	0.941	1.000	0.135	0.125
M13	F	61	-4.180	-4.000	3.413	1.000	60	0.564	0.528	0.340	0.222
M14	S	84	-0.357	0.000	2.098	1.000	84	0.976	1.000	0.168	0.111
M14	F	19	-3.316	-4.000	5.598	5.000	17	0.481	0.444	0.424	0.567
M15	S	49	-0.796	-1.000	0.790	1.000	48	0.902	0.889	0.097	0.125
M15	F	54	-4.204	-4.000	2.616	1.000	53	0.562	0.500	0.255	0.125
M16	S	70	-0.357	0.000	2.200	1.000	70	0.965	1.000	0.194	0.125
M16	F	33	-5.030	-5.000	4.864	2.000	31	0.472	0.375	0.388	0.335
M17	S	45	-0.822	-1.000	0.886	1.000	44	0.898	0.889	0.103	0.125
M17	F	58	-4.759	-4.000	3.289	1.000	57	0.516	0.500	0.250	0.171
M18	S	82	-0.915	-0.500	1.874	1.750	82	0.916	0.971	0.147	0.147
M18	F	21	-3.333	-5.000	6.938	3.000	19	0.511	0.375	0.532	0.375

C.2 タスク名の依存を考慮した成功率

マクロ SR はタスク名ごとの SR を等重み平均する。95%区間はタスク名をクラスターとして復元抽出し、選んだ名前の全インスタンスを保持した 4000 回の再標本化の 2.5・97.5 百分位点である (seed 20260906)。区間内の SR はインスタンス重みであり、マクロ SR の区間ではない。検証有無の差では同じ ID の成功差を保持して再標本化する。家屋の共有による名前間の依存は除去できず、状態変化の 6 名では区間推定自体が不安定になり得る。因果効果や独立タスクによる有意差の検定とは解釈しない。

表 C.20: マクロ成功率とタスク名クラスター区間 (%)

条件	名前数	SR	マクロ SR	SR 下限	SR 上限
M1	6	3.205	5.078	0.000	8.333
M2	6	62.500	57.448	47.727	76.872
M3	6	78.846	84.523	60.981	97.340
M4	6	75.000	70.929	61.275	89.474
M5	6	89.423	84.193	68.182	99.013
M6	6	61.538	57.613	43.750	79.276
M7	6	75.962	79.983	57.243	95.714
M8	6	69.551	68.568	47.436	92.763
M9	6	87.179	79.505	64.773	96.711
M10	38	0.000	0.000	0.000	0.000
M11	38	46.602	38.377	34.065	58.333
M12	38	73.786	63.377	64.102	82.302
M13	38	40.777	42.281	30.000	52.223
M14	38	81.553	63.487	71.111	89.051
M15	38	47.573	41.996	35.632	58.825
M16	38	67.961	54.232	55.262	78.626
M17	38	43.689	39.978	32.999	54.623
M18	38	79.612	64.803	69.663	87.736

表 C.21: 検証なしからありへの対応変化と SR 差 (percentage points)

あり条件	n	改善数	悪化数	両成功	両失敗	SR 差	下限	上限
M2	312	34	31	161	86	0.962	-4.545	5.593
M3	312	26	17	220	49	2.885	0.658	10.000
M4	312	48	31	186	47	5.449	-5.000	14.706

あり条件	<i>n</i>	改善数	悪化数	両成功	両失敗	SR 差	下限	上限
M5	312	12	5	267	28	2.244	0.938	6.944
M11	103	6	7	42	48	-0.971	-8.547	7.059
M12	103	12	6	64	21	5.825	-2.858	13.979
M13	103	6	9	36	52	-2.913	-9.303	4.651
M14	103	6	4	78	15	1.942	-4.168	7.619

C.3 検索類似度と成績の関係

検索の構成と候補名順序は付録 B.3 に従う。表表 C.22 では名前等重みとインスタンス等重みを区別する。表表 C.23 の O/A/D は対象クラス／操作／配置先の一致, 1/0 は一致／不一致を表す。同じ試行を複数軸で分けた記述的集計であり, 各行を合算しない。列長差はその行の成功 ID のみを分母とする。状態変化には配置先がないため D は解釈対象から外す。空の層は成績表に行を設けていない。

表 C.22: 検索類似度の分布

タスク	重み	<i>n</i>	平均	中央値	Q1	Q3	最小	最大
状態	名前	6	0.678	0.606	0.589	0.797	0.499	0.910
状態	事例	312	0.624	0.611	0.585	0.611	0.499	0.910
配置	名前	38	0.782	0.781	0.736	0.829	0.640	0.901
配置	事例	103	0.781	0.792	0.761	0.809	0.640	0.901

表 C.23: 検索類似度・共有構造別の成功率と成功時列長差

条件	層	<i>n</i>	成功数	SR (%)	成功時 D 平均
M8	<0.8	280	201	71.786	0.577
M8	O0	280	201	71.786	0.577
M8	A1	280	201	71.786	0.577
M8	>=0.9	20	9	45.000	0.000
M8	O1	32	16	50.000	-0.062
M8	A0	32	16	50.000	-0.062
M8	0.8-0.9	12	7	58.333	-0.143
M4	<0.8	280	214	76.429	0.481
M4	O0	280	214	76.429	0.481
M4	A1	280	214	76.429	0.481
M4	>=0.9	20	11	55.000	0.182
M4	O1	32	20	62.500	0.050
M4	A0	32	20	62.500	0.050
M4	0.8-0.9	12	9	75.000	-0.111
M9	<0.8	280	253	90.357	-0.209
M9	O0	280	253	90.357	-0.209
M9	A1	280	253	90.357	-0.209
M9	>=0.9	20	9	45.000	-0.222
M9	O1	32	19	59.375	-0.211
M9	A0	32	19	59.375	-0.211
M9	0.8-0.9	12	10	83.333	-0.200
M5	<0.8	280	258	92.143	-0.314
M5	O0	280	258	92.143	-0.314
M5	A1	280	258	92.143	-0.314
M5	>=0.9	20	9	45.000	-0.111
M5	O1	32	21	65.625	-0.048
M5	A0	32	21	65.625	-0.048
M5	0.8-0.9	12	12	100.000	0.000
M6	<0.8	280	180	64.286	0.444
M6	O0	280	180	64.286	0.444
M6	A1	280	180	64.286	0.444
M6	>=0.9	20	7	35.000	-0.143
M6	O1	32	12	37.500	-0.083
M6	A0	32	12	37.500	-0.083
M6	0.8-0.9	12	5	41.667	0.000
M2	<0.8	280	180	64.286	0.328
M2	O0	280	180	64.286	0.328
M2	A1	280	180	64.286	0.328
M2	>=0.9	20	8	40.000	0.125
M2	O1	32	15	46.875	0.067
M2	A0	32	15	46.875	0.067
M2	0.8-0.9	12	7	58.333	0.000
M7	<0.8	280	218	77.857	0.041
M7	O0	280	218	77.857	0.041
M7	A1	280	218	77.857	0.041
M7	>=0.9	20	9	45.000	0.111
M7	O1	32	19	59.375	0.105
M7	A0	32	19	59.375	0.105
M7	0.8-0.9	12	10	83.333	0.100
M3	<0.8	280	222	79.286	-0.014
M3	O0	280	222	79.286	-0.014
M3	A1	280	222	79.286	-0.014
M3	>=0.9	20	12	60.000	0.333
M3	O1	32	24	75.000	0.083
M3	A0	32	24	75.000	0.083
M3	0.8-0.9	12	12	100.000	-0.167
M17	0.8-0.9	44	19	43.182	-0.684
M17	O1	92	43	46.739	-0.860
M17	A1	56	25	44.643	-0.480
M17	D0	92	43	46.739	-0.860
M17	<0.8	57	25	43.860	-0.920
M17	A0	47	20	42.553	-1.250
M17	O0	11	2	18.182	0.000
M17	D1	11	2	18.182	0.000
M17	>=0.9	2	1	50.000	-1.000
M13	0.8-0.9	44	15	34.091	-0.667
M13	O1	92	38	41.304	-0.605
M13	A1	56	27	48.214	-1.037
M13	D0	92	38	41.304	-0.605
M13	<0.8	57	26	45.614	-0.577
M13	A0	47	15	31.915	0.133
M13	O0	11	4	36.364	-0.750
M13	D1	11	4	36.364	-0.750
M13	>=0.9	2	1	50.000	-1.000
M18	0.8-0.9	44	36	81.818	-0.528
M18	O1	92	72	78.261	-0.986
M18	A1	56	44	78.571	-1.159
M18	D0	92	72	78.261	-0.986
M18	<0.8	57	45	78.947	-1.244
M18	A0	47	38	80.851	-0.632
M18	O0	11	10	90.909	-0.400
M18	D1	11	10	90.909	-0.400
M18	>=0.9	2	1	50.000	0.000
M14	0.8-0.9	44	35	79.545	0.229
M14	O1	92	74	80.435	-0.392

条件	層	n	成功数	SR (%)	成功時 D 平均
M14	A1	56	43	76.786	-0.465
M14	D0	92	74	80.435	-0.392
M14	<0.8	57	48	84.211	-0.771
M14	A0	47	41	87.234	-0.244
M14	O0	11	10	90.909	-0.100
M14	D1	11	10	90.909	-0.100
M14	>=0.9	2	1	50.000	-1.000
M15	0.8-0.9	44	20	45.455	-0.550
M15	O1	92	47	51.087	-0.809
M15	A1	56	26	46.429	-0.423
M15	D0	92	47	51.087	-0.809
M15	<0.8	57	28	49.123	-0.964
M15	A0	47	23	48.936	-1.217
M15	O0	11	2	18.182	-0.500
M15	D1	11	2	18.182	-0.500
M15	>=0.9	2	1	50.000	-1.000
M11	0.8-0.9	44	16	36.364	-0.250
M11	O1	92	46	50.000	-0.152
M11	A1	56	26	46.429	-0.115
M11	D0	92	46	50.000	-0.152
M11	<0.8	57	31	54.386	-0.194
M11	A0	47	22	46.809	-0.182
M11	O0	11	2	18.182	0.000
M11	D1	11	2	18.182	0.000
M11	>=0.9	2	1	50.000	3.000
M16	0.8-0.9	44	30	68.182	0.133
M16	O1	92	63	68.478	-0.349
M16	A1	56	39	69.643	-0.641
M16	D0	92	63	68.478	-0.349
M16	<0.8	57	39	68.421	-0.718
M16	A0	47	31	65.957	0.000
M16	O0	11	7	63.636	-0.429
M16	D1	11	7	63.636	-0.429
M16	>=0.9	2	1	50.000	-1.000
M12	0.8-0.9	44	31	70.455	-0.032
M12	O1	92	67	72.826	-0.537
M12	A1	56	43	76.786	-0.558
M12	D0	92	67	72.826	-0.537
M12	<0.8	57	44	77.193	-0.750
M12	A0	47	33	70.213	-0.333
M12	O0	11	9	81.818	0.111
M12	D1	11	9	81.818	0.111
M12	>=0.9	2	1	50.000	-1.000

C.4 全インスタンスの組合せ網羅表

指示 N と初期状態 I は後続の辞書に完全に展開する。状態変化の指示は Turn on/off all, 配置の指示は Put all ... in/on the ... で、対象・目標状態／配置先を指示辞書から一意に読める。S/P は状態変化／配置、T/E はテスト／事例用、部屋 B/D/K/L は bathroom / bedroom / kitchen / livingroom である。ID 欄の整数は test_task または example_task に続く番号で、各 ID の後の文字が initial_room となる。同一指示・シーン・初期状態の行をまとめただけであり、全 618 件を重複なく列挙する。物体位置はシーンに依存し、I はノード状態配列の上書きである。列挙は観測組合せであり、全組合せの設計網羅を主張しない。

表 C.24: タスク指示の辞書

番号	指示全文
N1	Put all alcohols in the microwave
N2	Put all alcohols on the kitchentable
N3	Put all apples in the fridge
N4	Put all apples in the microwave
N5	Put all apples on the kitchencounter
N6	Put all apples on the kitchentable
N7	Put all bananas in the fridge
N8	Put all bananas in the microwave
N9	Put all bananas on the coffeetable
N10	Put all bananas on the desk
N11	Put all bananas on the kitchencounter
N12	Put all bananas on the kitchentable
N13	Put all bananas on the oventray
N14	Put all bellpeppers in the fridge
N15	Put all bellpeppers in the microwave
N16	Put all bellpeppers on the kitchencounter
N17	Put all bellpeppers on the kitchentable
N18	Put all chips in the fridge
N19	Put all chips in the microwave
N20	Put all chips on the coffeetable
N21	Put all chips on the kitchentable
N22	Put all crackers in the fridge
N23	Put all crackers in the microwave
N24	Put all crackers on the coffeetable
N25	Put all crackers on the kitchentable
N26	Put all creamybuns in the fridge
N27	Put all creamybuns in the microwave
N28	Put all creamybuns on the kitchentable
N29	Put all cupcakes in the fridge
N30	Put all cupcakes in the microwave
N31	Put all cupcakes on the coffeetable
N32	Put all cupcakes on the desk
N33	Put all cupcakes on the kitchencounter
N34	Put all cupcakes on the kitchentable
N35	Put all juices in the fridge
N36	Put all juices in the microwave
N37	Put all juices on the coffeetable
N38	Put all milks in the fridge
N39	Put all milks in the microwave
N40	Put all milks on the coffeetable
N41	Put all milks on the cuttingboard
N42	Put all milks on the desk
N43	Put all milks on the kitchencounter
N44	Put all milks on the kitchentable
N45	Put all peaches in the fridge
N46	Put all peaches in the microwave
N47	Put all peaches on the coffeetable
N48	Put all peaches on the kitchencounter
N49	Put all peaches on the kitchentable
N50	Put all peaches on the oventray
N51	Put all plums in the fridge
N52	Put all plums in the fryingpan
N53	Put all plums in the microwave
N54	Put all plums on the coffeetable
N55	Put all plums on the kitchencounter
N56	Put all plums on the kitchentable

番号	指示全文
N57	Put all plums on the oventray
N58	Turn off all candles
N59	Turn off all cellphones
N60	Turn off all computers
N61	Turn off all faucets
N62	Turn off all lightswitches
N63	Turn off all tablelamps
N64	Turn off all tvs
N65	Turn on all computers
N66	Turn on all faucets
N67	Turn on all lightswitches
N68	Turn on all tablelamps
N69	Turn on all tvs

表 C.25: 初期状態の辞書 (ID: 状態配列)

番号	状態上書き
I1	(empty)
I2	101:OFF; 187:OFF
I3	101:OFF; 187:ON
I4	101:ON; 187:OFF
I5	101:ON; 187:ON
I6	102:OFF; 103:OFF
I7	102:OFF; 103:ON
I8	102:ON; 103:OFF
I9	102:ON; 103:ON
I10	103:CLOSED
I11	103:OFF; 201:OFF; 249:OFF; 366:OFF
I12	103:OFF; 201:OFF; 249:OFF; 366:ON
I13	103:OFF; 201:OFF; 249:ON; 366:OFF
I14	103:OFF; 201:OFF; 249:ON; 366:ON
I15	103:OFF; 201:ON; 249:OFF; 366:OFF
I16	103:OFF; 201:ON; 249:OFF; 366:ON
I17	103:OFF; 201:ON; 249:ON; 366:OFF
I18	103:OFF; 201:ON; 249:ON; 366:ON
I19	103:ON; 201:OFF; 249:OFF; 366:OFF
I20	103:ON; 201:OFF; 249:OFF; 366:ON
I21	103:ON; 201:OFF; 249:ON; 366:OFF
I22	103:ON; 201:OFF; 249:ON; 366:ON
I23	103:ON; 201:ON; 249:OFF; 366:OFF
I24	103:ON; 201:ON; 249:OFF; 366:ON
I25	103:ON; 201:ON; 249:ON; 366:OFF
I26	103:ON; 201:ON; 249:ON; 366:ON
I27	103:OPEN
I28	108:OFF; 200:OFF
I29	108:OFF; 200:ON
I30	108:ON; 200:OFF
I31	108:ON; 200:ON
I32	109:CLOSED,OFF
I33	109:OPEN,OFF
I34	111:OFF; 185:OFF; 318:OFF
I35	111:OFF; 185:OFF; 318:ON
I36	111:OFF; 185:ON; 318:OFF
I37	111:OFF; 185:ON; 318:ON
I38	111:ON; 185:OFF; 318:OFF
I39	111:ON; 185:OFF; 318:ON
I40	111:ON; 185:ON; 318:OFF
I41	111:ON; 185:ON; 318:ON
I42	120:OFF; 274:OFF
I43	120:OFF; 274:ON
I44	120:ON; 274:OFF
I45	120:ON; 274:ON
I46	124:OFF; 125:OFF
I47	124:OFF; 125:ON
I48	124:OFF; 127:OFF
I49	124:OFF; 127:ON
I50	124:OFF; 216:OFF; 314:OFF
I51	124:OFF; 216:OFF; 314:ON
I52	124:OFF; 216:ON; 314:OFF
I53	124:OFF; 216:ON; 314:ON
I54	124:ON; 125:OFF
I55	124:ON; 125:ON
I56	124:ON; 127:OFF
I57	124:ON; 127:ON
I58	124:ON; 216:OFF; 314:OFF
I59	124:ON; 216:OFF; 314:ON
I60	124:ON; 216:ON; 314:OFF
I61	124:ON; 216:ON; 314:ON
I62	152:OFF; 300:OFF
I63	152:OFF; 300:ON
I64	152:ON; 300:OFF
I65	152:ON; 300:ON
I66	156:OFF; 327:OFF
I67	156:OFF; 327:ON
I68	156:ON; 327:OFF
I69	156:ON; 327:ON
I70	157:CLOSED
I71	157:OFF; 249:OFF
I72	157:OFF; 249:ON
I73	157:ON; 249:OFF
I74	157:ON; 249:ON
I75	157:OPEN
I76	162:CLOSED,OFF
I77	162:CLOSED
I78	162:OPEN,OFF
I79	162:OPEN
I80	166:CLOSED,OFF
I81	166:OPEN,OFF
I82	169:OFF; 209:OFF; 218:OFF; 300:OFF
I83	169:OFF; 209:OFF; 218:OFF; 300:ON
I84	169:OFF; 209:OFF; 218:ON; 300:OFF
I85	169:OFF; 209:OFF; 218:ON; 300:ON
I86	169:OFF; 209:ON; 218:OFF; 300:OFF
I87	169:OFF; 209:ON; 218:OFF; 300:ON
I88	169:OFF; 209:ON; 218:ON; 300:OFF
I89	169:OFF; 209:ON; 218:ON; 300:ON
I90	169:ON; 209:OFF; 218:OFF; 300:OFF
I91	169:ON; 209:OFF; 218:OFF; 300:ON
I92	169:ON; 209:OFF; 218:ON; 300:OFF
I93	169:ON; 209:OFF; 218:ON; 300:ON
I94	169:ON; 209:ON; 218:OFF; 300:OFF
I95	169:ON; 209:ON; 218:OFF; 300:ON
I96	169:ON; 209:ON; 218:ON; 300:OFF

番号	状態上書き
I97	169:ON; 209:ON; 218:ON; 300:ON
I98	171:CLOSED,OFF
I99	171:OPEN,OFF
I100	174:OFF; 433:OFF
I101	174:OFF; 433:ON
I102	174:ON; 433:OFF
I103	174:ON; 433:ON
I104	188:OFF; 202:OFF; 448:OFF; 449:OFF
I105	188:OFF; 202:OFF; 448:OFF; 449:ON
I106	188:OFF; 202:OFF; 448:ON; 449:OFF
I107	188:OFF; 202:OFF; 448:ON; 449:ON
I108	188:OFF; 202:ON; 448:OFF; 449:OFF
I109	188:OFF; 202:ON; 448:OFF; 449:ON
I110	188:OFF; 202:ON; 448:ON; 449:OFF
I111	188:OFF; 202:ON; 448:ON; 449:ON
I112	188:ON; 202:OFF; 448:OFF; 449:OFF
I113	188:ON; 202:OFF; 448:OFF; 449:ON
I114	188:ON; 202:OFF; 448:ON; 449:OFF
I115	188:ON; 202:OFF; 448:ON; 449:ON
I116	188:ON; 202:ON; 448:OFF; 449:OFF
I117	188:ON; 202:ON; 448:OFF; 449:ON
I118	188:ON; 202:ON; 448:ON; 449:OFF
I119	188:ON; 202:ON; 448:ON; 449:ON
I120	194:OFF; 197:OFF
I121	194:OFF; 197:ON
I122	194:ON; 197:OFF
I123	194:ON; 197:ON
I124	207:OFF; 314:OFF
I125	207:OFF; 314:ON
I126	207:ON; 314:OFF
I127	207:ON; 314:ON
I128	223:OFF; 323:OFF
I129	223:OFF; 323:ON
I130	223:ON; 323:OFF
I131	223:ON; 323:ON
I132	225:CLOSED
I133	225:OPEN
I134	234:CLOSED,OFF
I135	234:OPEN,OFF
I136	235:CLOSED
I137	235:OPEN
I138	239:CLOSED,OFF
I139	239:OPEN,OFF
I140	256:OFF; 376:OFF; 377:OFF
I141	256:OFF; 376:OFF; 377:ON
I142	256:OFF; 376:ON; 377:OFF
I143	256:OFF; 376:ON; 377:ON
I144	256:ON; 376:OFF; 377:OFF
I145	256:ON; 376:OFF; 377:ON
I146	256:ON; 376:ON; 377:OFF
I147	256:ON; 376:ON; 377:ON
I148	264:OFF; 426:OFF
I149	264:OFF; 426:ON
I150	264:ON; 426:OFF
I151	264:ON; 426:ON
I152	268:OFF; 271:OFF
I153	268:OFF; 271:ON
I154	268:ON; 271:OFF
I155	268:ON; 271:ON
I156	274:OFF; 324:OFF
I157	274:OFF; 324:ON
I158	274:ON; 324:OFF
I159	274:ON; 324:ON
I160	29:OFF; 220:OFF
I161	29:OFF; 220:ON
I162	29:ON; 220:OFF
I163	29:ON; 220:ON
I164	30:OFF; 149:OFF
I165	30:OFF; 149:ON
I166	30:ON; 149:OFF
I167	30:ON; 149:ON
I168	305:CLOSED
I169	305:OPEN
I170	313:CLOSED,OFF
I171	313:OPEN,OFF
I172	38:OFF; 199:OFF
I173	38:OFF; 199:ON
I174	38:ON; 199:OFF
I175	38:ON; 199:ON
I176	48:OFF; 97:OFF; 157:OFF; 302:OFF
I177	48:OFF; 97:OFF; 157:OFF; 302:ON
I178	48:OFF; 97:OFF; 157:ON; 302:OFF
I179	48:OFF; 97:OFF; 157:ON; 302:ON
I180	48:OFF; 97:ON; 157:OFF; 302:OFF
I181	48:OFF; 97:ON; 157:OFF; 302:ON
I182	48:OFF; 97:ON; 157:ON; 302:OFF
I183	48:OFF; 97:ON; 157:ON; 302:ON
I184	48:ON; 97:OFF; 157:OFF; 302:OFF
I185	48:ON; 97:OFF; 157:OFF; 302:ON
I186	48:ON; 97:OFF; 157:ON; 302:OFF
I187	48:ON; 97:OFF; 157:ON; 302:ON
I188	48:ON; 97:ON; 157:OFF; 302:OFF
I189	48:ON; 97:ON; 157:OFF; 302:ON
I190	48:ON; 97:ON; 157:ON; 302:OFF
I191	48:ON; 97:ON; 157:ON; 302:ON
I192	50:OFF; 248:OFF
I193	50:OFF; 248:ON
I194	50:ON; 248:OFF
I195	50:ON; 248:ON
I196	54:OFF; 85:OFF; 277:OFF; 332:OFF
I197	54:OFF; 85:OFF; 277:OFF; 332:ON
I198	54:OFF; 85:OFF; 277:ON; 332:OFF
I199	54:OFF; 85:OFF; 277:ON; 332:ON
I200	54:OFF; 85:ON; 277:OFF; 332:OFF
I201	54:OFF; 85:ON; 277:OFF; 332:ON
I202	54:OFF; 85:ON; 277:ON; 332:OFF
I203	54:OFF; 85:ON; 277:ON; 332:ON
I204	54:ON; 85:OFF; 277:OFF; 332:OFF
I205	54:ON; 85:OFF; 277:OFF; 332:ON
I206	54:ON; 85:OFF; 277:ON; 332:OFF
I207	54:ON; 85:OFF; 277:ON; 332:ON
I208	54:ON; 85:ON; 277:OFF; 332:OFF
I209	54:ON; 85:ON; 277:OFF; 332:ON
I210	54:ON; 85:ON; 277:ON; 332:OFF
I211	54:ON; 85:ON; 277:ON; 332:ON
I212	58:OFF; 239:OFF; 278:OFF; 344:OFF; 402:OFF
I213	58:OFF; 239:OFF; 278:OFF; 344:OFF; 402:ON

番号	状態上書き
I214	58:OFF; 239:OFF; 278:OFF; 344:ON; 402:OFF
I215	58:OFF; 239:OFF; 278:OFF; 344:ON; 402:ON
I216	58:OFF; 239:OFF; 278:ON; 344:OFF; 402:OFF
I217	58:OFF; 239:OFF; 278:ON; 344:OFF; 402:ON
I218	58:OFF; 239:OFF; 278:ON; 344:ON; 402:OFF
I219	58:OFF; 239:OFF; 278:ON; 344:ON; 402:ON
I220	58:OFF; 239:ON; 278:OFF; 344:OFF; 402:OFF
I221	58:OFF; 239:ON; 278:OFF; 344:OFF; 402:ON
I222	58:OFF; 239:ON; 278:OFF; 344:ON; 402:OFF
I223	58:OFF; 239:ON; 278:OFF; 344:ON; 402:ON
I224	58:OFF; 239:ON; 278:ON; 344:OFF; 402:OFF
I225	58:OFF; 239:ON; 278:ON; 344:OFF; 402:ON
I226	58:OFF; 239:ON; 278:ON; 344:ON; 402:OFF
I227	58:OFF; 239:ON; 278:ON; 344:ON; 402:ON
I228	58:ON; 239:OFF; 278:OFF; 344:OFF; 402:OFF
I229	58:ON; 239:OFF; 278:OFF; 344:OFF; 402:ON
I230	58:ON; 239:OFF; 278:OFF; 344:ON; 402:OFF
I231	58:ON; 239:OFF; 278:OFF; 344:ON; 402:ON
I232	58:ON; 239:OFF; 278:ON; 344:OFF; 402:OFF
I233	58:ON; 239:OFF; 278:ON; 344:OFF; 402:ON
I234	58:ON; 239:OFF; 278:ON; 344:ON; 402:OFF
I235	58:ON; 239:OFF; 278:ON; 344:ON; 402:ON
I236	58:ON; 239:ON; 278:OFF; 344:OFF; 402:OFF
I237	58:ON; 239:ON; 278:OFF; 344:OFF; 402:ON
I238	58:ON; 239:ON; 278:OFF; 344:ON; 402:OFF
I239	58:ON; 239:ON; 278:OFF; 344:ON; 402:ON
I240	58:ON; 239:ON; 278:ON; 344:OFF; 402:OFF
I241	58:ON; 239:ON; 278:ON; 344:OFF; 402:ON
I242	58:ON; 239:ON; 278:ON; 344:ON; 402:OFF
I243	58:ON; 239:ON; 278:ON; 344:ON; 402:ON
I244	67:OFF; 110:OFF; 205:OFF; 315:OFF
I245	67:OFF; 110:OFF; 205:OFF; 315:ON
I246	67:OFF; 110:OFF; 205:ON; 315:OFF
I247	67:OFF; 110:OFF; 205:ON; 315:ON
I248	67:OFF; 110:ON; 205:OFF; 315:OFF
I249	67:OFF; 110:ON; 205:OFF; 315:ON
I250	67:OFF; 110:ON; 205:ON; 315:OFF
I251	67:OFF; 110:ON; 205:ON; 315:ON
I252	67:ON; 110:OFF; 205:OFF; 315:OFF
I253	67:ON; 110:OFF; 205:OFF; 315:ON
I254	67:ON; 110:OFF; 205:ON; 315:OFF
I255	67:ON; 110:OFF; 205:ON; 315:ON
I256	67:ON; 110:ON; 205:OFF; 315:OFF
I257	67:ON; 110:ON; 205:OFF; 315:ON
I258	67:ON; 110:ON; 205:ON; 315:OFF
I259	67:ON; 110:ON; 205:ON; 315:ON
I260	69:OFF; 181:OFF
I261	69:OFF; 181:ON
I262	69:ON; 181:OFF
I263	69:ON; 181:ON
I264	71:OFF; 173:OFF; 261:OFF; 427:OFF
I265	71:OFF; 173:OFF; 261:OFF; 427:ON
I266	71:OFF; 173:OFF; 261:ON; 427:OFF
I267	71:OFF; 173:OFF; 261:ON; 427:ON
I268	71:OFF; 173:ON; 261:OFF; 427:OFF
I269	71:OFF; 173:ON; 261:OFF; 427:ON
I270	71:OFF; 173:ON; 261:ON; 427:OFF
I271	71:OFF; 173:ON; 261:ON; 427:ON
I272	71:ON; 173:OFF; 261:OFF; 427:OFF
I273	71:ON; 173:OFF; 261:OFF; 427:ON
I274	71:ON; 173:OFF; 261:ON; 427:OFF
I275	71:ON; 173:OFF; 261:ON; 427:ON
I276	71:ON; 173:ON; 261:OFF; 427:OFF
I277	71:ON; 173:ON; 261:OFF; 427:ON
I278	71:ON; 173:ON; 261:ON; 427:OFF
I279	71:ON; 173:ON; 261:ON; 427:ON
I280	78:OFF; 229:OFF
I281	78:OFF; 229:ON
I282	78:ON; 229:OFF
I283	78:ON; 229:ON
I284	91:OFF; 195:OFF
I285	91:OFF; 195:ON
I286	91:ON; 195:OFF
I287	91:ON; 195:ON
I288	94:OFF; 295:OFF
I289	94:OFF; 295:ON
I290	94:ON; 295:OFF
I291	94:ON; 295:ON

表 C.26: 全インスタンスの組合せ (ID: 初期部屋)

種別	分割	指示	シーン	初期状態	件数	ID: 部屋
P	E	N3	1	I168	1	12:K
P	E	N3	1	I169	1	11:D
P	E	N3	2	I132	1	18:K
P	E	N3	2	I133	1	17:D
P	E	N4	1	I170	1	14:L
P	E	N4	1	I171	1	13:D
P	E	N4	2	I134	1	20:D
P	E	N4	2	I135	1	19:K
P	E	N6	1	I1	1	3:B
P	E	N6	2	I1	1	15:K
P	E	N6	7	I1	1	49:L
P	E	N12	1	I1	1	2:D
P	E	N12	5	I1	1	43:B
P	E	N15	1	I170	1	8:K
P	E	N15	1	I171	1	7:D
P	E	N18	1	I168	1	10:K
P	E	N18	1	I169	1	9:L
P	E	N18	2	I132	1	22:B
P	E	N18	2	I133	1	21:K
P	E	N18	4	I10	1	39:D
P	E	N18	4	I27	1	38:L
P	E	N20	4	I1	1	35:D
P	E	N24	4	I1	1	36:D
P	E	N29	1	I168	1	6:B
P	E	N29	1	I169	1	5:L
P	E	N29	3	I77	1	29:L
P	E	N29	3	I79	1	28:K
P	E	N29	4	I10	1	41:K
P	E	N29	4	I27	1	40:L
P	E	N29	5	I70	1	45:D
P	E	N29	5	I75	1	44:L

種別	分割	指示	シーン	初期状態	件数	ID: 部屋
P	E	N34	1	I1	1	I:D
P	E	N34	4	I1	1	37:K
P	E	N34	5	I1	1	42:L
P	E	N34	7	I1	1	51:K
P	E	N36	3	I98	1	25:K
P	E	N36	3	I99	1	24:D
P	E	N37	3	I1	1	23:L
P	E	N38	3	I77	1	27:L
P	E	N38	3	I79	1	26:D
P	E	N38	6	I136	1	48:K
P	E	N38	6	I137	1	47:K
P	E	N44	6	I1	1	46:B
P	E	N47	4	I1	1	31:B
P	E	N50	4	I1	1	30:K
P	E	N54	4	I1	1	34:K
P	E	N56	1	I1	1	4:L
P	E	N56	2	I1	1	16:L
P	E	N56	4	I1	1	32:B
P	E	N56	7	I1	1	50:K
P	E	N57	4	I1	1	33:B
P	T	N1	7	I80	1	97:L
P	T	N1	7	I81	1	96:D
P	T	N2	7	I1	1	90:K
P	T	N5	1	I1	1	6:K
P	T	N7	1	I168	1	13:B
P	T	N7	1	I169	1	12:L
P	T	N7	3	I77	1	52:L
P	T	N7	3	I79	1	51:K
P	T	N7	5	I70	1	80:B
P	T	N7	5	I75	1	79:K
P	T	N8	1	I170	1	15:D
P	T	N8	1	I171	1	14:D
P	T	N8	3	I98	1	54:L
P	T	N8	3	I99	1	53:D
P	T	N8	5	I76	1	82:K
P	T	N8	5	I78	1	81:L
P	T	N9	3	I1	1	45:K
P	T	N10	5	I1	1	76:K
P	T	N11	1	I1	1	2:L
P	T	N13	3	I1	1	44:K
P	T	N14	1	I168	1	17:D
P	T	N14	1	I169	1	16:D
P	T	N16	1	I1	1	4:B
P	T	N17	1	I1	1	3:K
P	T	N19	2	I134	1	42:K
P	T	N19	2	I135	1	41:D
P	T	N19	7	I80	1	95:D
P	T	N19	7	I81	1	94:K
P	T	N21	1	I1	1	5:K
P	T	N21	2	I1	1	28:L
P	T	N21	7	I1	1	89:D
P	T	N22	4	I10	1	70:D
P	T	N22	4	I27	1	69:D
P	T	N23	4	I32	1	72:K
P	T	N23	4	I33	1	71:K
P	T	N25	4	I1	1	58:D
P	T	N26	2	I132	1	38:K
P	T	N26	2	I133	1	37:B
P	T	N27	2	I134	1	40:B
P	T	N27	2	I135	1	39:K
P	T	N27	7	I80	1	93:L
P	T	N27	7	I81	1	92:K
P	T	N28	2	I1	1	27:L
P	T	N28	7	I1	1	88:B
P	T	N30	1	I170	1	11:D
P	T	N30	1	I171	1	10:K
P	T	N30	3	I98	1	56:B
P	T	N30	3	I99	1	55:D
P	T	N30	4	I32	1	74:L
P	T	N30	4	I33	1	73:L
P	T	N30	5	I76	1	78:L
P	T	N30	5	I78	1	77:L
P	T	N30	7	I80	1	103:D
P	T	N30	7	I81	1	102:D
P	T	N31	3	I1	1	46:B
P	T	N31	4	I1	1	59:D
P	T	N32	5	I1	1	75:D
P	T	N33	1	I1	1	1:B
P	T	N35	3	I77	1	48:K
P	T	N35	3	I79	1	47:B
P	T	N39	3	I98	1	50:D
P	T	N39	3	I99	1	49:B
P	T	N39	6	I138	1	87:L
P	T	N39	6	I139	1	86:L
P	T	N40	3	I1	1	43:B
P	T	N41	6	I1	1	84:B
P	T	N42	6	I1	1	85:D
P	T	N43	6	I1	1	83:K
P	T	N45	1	I168	1	19:L
P	T	N45	1	I169	1	18:K
P	T	N45	2	I132	1	30:K
P	T	N45	2	I133	1	29:B
P	T	N45	4	I10	1	61:L
P	T	N45	4	I27	1	60:L
P	T	N46	1	I170	1	21:K
P	T	N46	1	I171	1	20:D
P	T	N46	2	I134	1	32:K
P	T	N46	2	I135	1	31:B
P	T	N46	4	I32	1	63:L
P	T	N46	4	I33	1	62:D
P	T	N46	7	I80	1	99:K
P	T	N46	7	I81	1	98:L
P	T	N48	1	I1	1	8:K
P	T	N49	1	I1	1	7:D
P	T	N49	2	I1	1	26:B
P	T	N49	4	I1	1	57:L
P	T	N49	7	I1	1	91:B
P	T	N51	1	I168	1	23:B
P	T	N51	1	I169	1	22:L
P	T	N51	2	I132	1	34:B
P	T	N51	2	I133	1	33:L
P	T	N51	4	I10	1	65:D
P	T	N51	4	I27	1	64:K
P	T	N52	4	I1	1	68:B
P	T	N53	1	I170	1	25:B
P	T	N53	1	I171	1	24:B
P	T	N53	2	I134	1	36:L

種別	分割	指示	シーン	初期状態	件数	ID: 部屋
P	T	N53	2	I135	1	35:B
P	T	N53	4	I32	1	67:B
P	T	N53	4	I33	1	66:B
P	T	N53	7	I80	1	101:K
P	T	N53	7	I81	1	100:B
P	T	N55	1	I1	1	9:K
S	E	N58	1	I260	1	20:L
S	E	N58	1	I261	1	19:K
S	E	N58	1	I262	1	18:D
S	E	N58	1	I263	1	17:B
S	E	N58	2	I120	1	64:K
S	E	N58	2	I121	1	63:D
S	E	N58	2	I122	1	62:D
S	E	N58	2	I123	1	61:B
S	E	N58	3	I50	1	88:L
S	E	N58	3	I51	1	87:L
S	E	N58	3	I52	1	86:B
S	E	N58	3	I53	1	85:K
S	E	N58	3	I58	1	84:D
S	E	N58	3	I59	1	83:L
S	E	N58	3	I60	1	82:K
S	E	N58	3	I61	1	81:K
S	E	N58	7	I48	1	148:D
S	E	N58	7	I49	1	147:B
S	E	N58	7	I56	1	146:D
S	E	N58	7	I57	1	145:K
S	E	N59	1	I104	1	36:B
S	E	N59	1	I105	1	35:L
S	E	N59	1	I106	1	34:D
S	E	N59	1	I107	1	33:D
S	E	N59	1	I108	1	32:B
S	E	N59	1	I109	1	31:B
S	E	N59	1	I110	1	30:K
S	E	N59	1	I111	1	29:L
S	E	N59	1	I112	1	28:D
S	E	N59	1	I113	1	27:K
S	E	N59	1	I114	1	26:B
S	E	N59	1	I115	1	25:B
S	E	N59	1	I116	1	24:L
S	E	N59	1	I117	1	23:D
S	E	N59	1	I118	1	22:K
S	E	N59	1	I119	1	21:B
S	E	N59	2	I34	1	60:K
S	E	N59	2	I35	1	59:B
S	E	N59	2	I36	1	58:K
S	E	N59	2	I37	1	57:D
S	E	N59	2	I38	1	56:D
S	E	N59	2	I39	1	55:D
S	E	N59	2	I40	1	54:D
S	E	N59	2	I41	1	53:D
S	E	N59	3	I42	1	80:L
S	E	N59	3	I43	1	79:K
S	E	N59	3	I44	1	78:D
S	E	N59	3	I45	1	77:D
S	E	N59	4	I71	1	104:K
S	E	N59	4	I72	1	103:K
S	E	N59	4	I73	1	102:D
S	E	N59	4	I74	1	101:D
S	E	N59	5	I2	1	116:K
S	E	N59	5	I3	1	115:B
S	E	N59	5	I4	1	114:D
S	E	N59	5	I5	1	113:D
S	E	N59	6	I128	1	132:B
S	E	N59	6	I129	1	131:L
S	E	N59	6	I130	1	130:D
S	E	N59	6	I131	1	129:D
S	E	N59	7	I152	1	152:L
S	E	N59	7	I153	1	151:K
S	E	N59	7	I154	1	150:B
S	E	N59	7	I155	1	149:D
S	E	N61	1	I192	1	16:D
S	E	N61	1	I193	1	15:B
S	E	N61	1	I194	1	14:B
S	E	N61	1	I195	1	13:L
S	E	N61	2	I160	1	52:L
S	E	N61	2	I161	1	51:D
S	E	N61	2	I162	1	50:K
S	E	N61	2	I163	1	49:B
S	E	N61	3	I66	1	92:K
S	E	N61	3	I67	1	91:K
S	E	N61	3	I68	1	90:K
S	E	N61	3	I69	1	89:B
S	E	N61	4	I284	1	100:D
S	E	N61	4	I285	1	99:D
S	E	N61	4	I286	1	98:L
S	E	N61	4	I287	1	97:B
S	E	N61	5	I62	1	120:L
S	E	N61	5	I63	1	119:B
S	E	N61	5	I64	1	118:B
S	E	N61	5	I65	1	117:B
S	E	N61	6	I172	1	128:B
S	E	N61	6	I173	1	127:D
S	E	N61	6	I174	1	126:K
S	E	N61	6	I175	1	125:B
S	E	N61	7	I164	1	144:L
S	E	N61	7	I165	1	143:D
S	E	N61	7	I166	1	142:L
S	E	N61	7	I167	1	141:D
S	E	N65	1	I100	1	12:L
S	E	N65	1	I101	1	11:K
S	E	N65	1	I102	1	10:D
S	E	N65	1	I103	1	9:L
S	E	N65	2	I288	1	44:D
S	E	N65	2	I289	1	43:D
S	E	N65	2	I290	1	42:K
S	E	N65	2	I291	1	41:B
S	E	N65	7	I156	1	140:K
S	E	N65	7	I157	1	139:D
S	E	N65	7	I158	1	138:D
S	E	N65	7	I159	1	137:K
S	E	N66	1	I192	1	4:D
S	E	N66	1	I193	1	3:D
S	E	N66	1	I194	1	2:D
S	E	N66	1	I195	1	1:B
S	E	N66	2	I160	1	40:L
S	E	N66	2	I161	1	39:D
S	E	N66	2	I162	1	38:D

種別	分割	指示	シーン	初期状態	件数	ID: 部屋
S	E	N66	2	I163	1	37:K
S	E	N66	3	I66	1	68:L
S	E	N66	3	I67	1	67:L
S	E	N66	3	I68	1	66:D
S	E	N66	3	I69	1	65:D
S	E	N66	4	I284	1	96:L
S	E	N66	4	I285	1	95:L
S	E	N66	4	I286	1	94:B
S	E	N66	4	I287	1	93:D
S	E	N66	5	I62	1	112:L
S	E	N66	5	I63	1	111:B
S	E	N66	5	I64	1	110:B
S	E	N66	5	I65	1	109:K
S	E	N66	6	I172	1	124:K
S	E	N66	6	I173	1	123:D
S	E	N66	6	I174	1	122:D
S	E	N66	6	I175	1	121:K
S	E	N66	7	I164	1	136:L
S	E	N66	7	I165	1	135:L
S	E	N66	7	I166	1	134:L
S	E	N66	7	I167	1	133:D
S	E	N68	1	I6	1	8:L
S	E	N68	1	I7	1	7:K
S	E	N68	1	I8	1	6:D
S	E	N68	1	I9	1	5:K
S	E	N68	2	I46	1	48:B
S	E	N68	2	I47	1	47:B
S	E	N68	2	I54	1	46:B
S	E	N68	2	I55	1	45:L
S	E	N68	3	I140	1	76:K
S	E	N68	3	I141	1	75:D
S	E	N68	3	I142	1	74:L
S	E	N68	3	I143	1	73:L
S	E	N68	3	I144	1	72:B
S	E	N68	3	I145	1	71:D
S	E	N68	3	I146	1	70:D
S	E	N68	3	I147	1	69:K
S	E	N68	5	I280	1	108:K
S	E	N68	5	I281	1	107:K
S	E	N68	5	I282	1	106:B
S	E	N68	5	I283	1	105:D
S	T	N60	1	I100	1	44:B
S	T	N60	1	I101	1	43:L
S	T	N60	1	I102	1	42:K
S	T	N60	1	I103	1	41:D
S	T	N60	2	I288	1	84:B
S	T	N60	2	I289	1	83:D
S	T	N60	2	I290	1	82:K
S	T	N60	2	I291	1	81:K
S	T	N60	7	I156	1	312:L
S	T	N60	7	I157	1	311:L
S	T	N60	7	I158	1	310:D
S	T	N60	7	I159	1	309:L
S	T	N62	1	I264	1	36:L
S	T	N62	1	I265	1	35:B
S	T	N62	1	I266	1	34:D
S	T	N62	1	I267	1	33:K
S	T	N62	1	I268	1	32:L
S	T	N62	1	I269	1	31:D
S	T	N62	1	I270	1	30:D
S	T	N62	1	I271	1	29:L
S	T	N62	1	I272	1	28:L
S	T	N62	1	I273	1	27:K
S	T	N62	1	I274	1	26:L
S	T	N62	1	I275	1	25:B
S	T	N62	1	I276	1	24:L
S	T	N62	1	I277	1	23:L
S	T	N62	1	I278	1	22:L
S	T	N62	1	I279	1	21:L
S	T	N62	2	I176	1	80:D
S	T	N62	2	I177	1	79:B
S	T	N62	2	I178	1	78:D
S	T	N62	2	I179	1	77:L
S	T	N62	2	I180	1	76:B
S	T	N62	2	I181	1	75:K
S	T	N62	2	I182	1	74:B
S	T	N62	2	I183	1	73:K
S	T	N62	2	I184	1	72:B
S	T	N62	2	I185	1	71:B
S	T	N62	2	I186	1	70:L
S	T	N62	2	I187	1	69:D
S	T	N62	2	I188	1	68:D
S	T	N62	2	I189	1	67:D
S	T	N62	2	I190	1	66:L
S	T	N62	2	I191	1	65:L
S	T	N62	3	I212	1	152:L
S	T	N62	3	I213	1	151:L
S	T	N62	3	I214	1	150:K
S	T	N62	3	I215	1	149:D
S	T	N62	3	I216	1	148:D
S	T	N62	3	I217	1	147:K
S	T	N62	3	I218	1	146:B
S	T	N62	3	I219	1	145:L
S	T	N62	3	I220	1	144:K
S	T	N62	3	I221	1	143:B
S	T	N62	3	I222	1	142:D
S	T	N62	3	I223	1	141:L
S	T	N62	3	I224	1	140:D
S	T	N62	3	I225	1	139:K
S	T	N62	3	I226	1	138:L
S	T	N62	3	I227	1	137:D
S	T	N62	3	I228	1	136:L
S	T	N62	3	I229	1	135:D
S	T	N62	3	I230	1	134:D
S	T	N62	3	I231	1	133:B
S	T	N62	3	I232	1	132:B
S	T	N62	3	I233	1	131:B
S	T	N62	3	I234	1	130:B
S	T	N62	3	I235	1	129:L
S	T	N62	3	I236	1	128:B
S	T	N62	3	I237	1	127:B
S	T	N62	3	I238	1	126:L
S	T	N62	3	I239	1	125:B
S	T	N62	3	I240	1	124:B
S	T	N62	3	I241	1	123:K
S	T	N62	3	I242	1	122:B
S	T	N62	3	I243	1	121:K

種別	分割	指示	シーン	初期状態	件数	ID: 部屋
S	T	N62	4	182	1	192:L
S	T	N62	4	183	1	191:B
S	T	N62	4	184	1	190:L
S	T	N62	4	185	1	189:D
S	T	N62	4	186	1	188:D
S	T	N62	4	187	1	187:K
S	T	N62	4	188	1	186:B
S	T	N62	4	189	1	185:B
S	T	N62	4	190	1	184:L
S	T	N62	4	191	1	183:K
S	T	N62	4	192	1	182:L
S	T	N62	4	193	1	181:B
S	T	N62	4	194	1	180:K
S	T	N62	4	195	1	179:L
S	T	N62	4	196	1	178:K
S	T	N62	4	197	1	177:L
S	T	N62	5	111	1	232:L
S	T	N62	5	112	1	231:K
S	T	N62	5	113	1	230:K
S	T	N62	5	114	1	229:B
S	T	N62	5	115	1	228:D
S	T	N62	5	116	1	227:L
S	T	N62	5	117	1	226:B
S	T	N62	5	118	1	225:L
S	T	N62	5	119	1	224:L
S	T	N62	5	120	1	223:K
S	T	N62	5	121	1	222:L
S	T	N62	5	122	1	221:B
S	T	N62	5	123	1	220:B
S	T	N62	5	124	1	219:K
S	T	N62	5	125	1	218:K
S	T	N62	5	126	1	217:D
S	T	N62	6	1244	1	272:L
S	T	N62	6	1245	1	271:L
S	T	N62	6	1246	1	270:D
S	T	N62	6	1247	1	269:B
S	T	N62	6	1248	1	268:K
S	T	N62	6	1249	1	267:K
S	T	N62	6	1250	1	266:L
S	T	N62	6	1251	1	265:L
S	T	N62	6	1252	1	264:K
S	T	N62	6	1253	1	263:D
S	T	N62	6	1254	1	262:K
S	T	N62	6	1255	1	261:K
S	T	N62	6	1256	1	260:D
S	T	N62	6	1257	1	259:K
S	T	N62	6	1258	1	258:B
S	T	N62	6	1259	1	257:B
S	T	N62	7	1196	1	308:D
S	T	N62	7	1197	1	307:L
S	T	N62	7	1198	1	306:L
S	T	N62	7	1199	1	305:B
S	T	N62	7	1200	1	304:B
S	T	N62	7	1201	1	303:D
S	T	N62	7	1202	1	302:B
S	T	N62	7	1203	1	301:D
S	T	N62	7	1204	1	300:L
S	T	N62	7	1205	1	299:L
S	T	N62	7	1206	1	298:D
S	T	N62	7	1207	1	297:L
S	T	N62	7	1208	1	296:K
S	T	N62	7	1209	1	295:K
S	T	N62	7	1210	1	294:D
S	T	N62	7	1211	1	293:L
S	T	N63	1	16	1	40:K
S	T	N63	1	17	1	39:K
S	T	N63	1	18	1	38:D
S	T	N63	1	19	1	37:L
S	T	N63	2	146	1	88:B
S	T	N63	2	147	1	87:K
S	T	N63	2	154	1	86:B
S	T	N63	2	155	1	85:K
S	T	N63	3	1140	1	160:K
S	T	N63	3	1141	1	159:L
S	T	N63	3	1142	1	158:D
S	T	N63	3	1143	1	157:B
S	T	N63	3	1144	1	156:D
S	T	N63	3	1145	1	155:K
S	T	N63	3	1146	1	154:L
S	T	N63	3	1147	1	153:B
S	T	N63	5	1280	1	216:K
S	T	N63	5	1281	1	215:K
S	T	N63	5	1282	1	214:K
S	T	N63	5	1283	1	213:K
S	T	N64	1	1148	1	48:K
S	T	N64	1	1149	1	47:K
S	T	N64	1	1150	1	46:D
S	T	N64	1	1151	1	45:L
S	T	N64	5	128	1	236:K
S	T	N64	5	129	1	235:D
S	T	N64	5	130	1	234:K
S	T	N64	5	131	1	233:D
S	T	N64	6	1124	1	276:L
S	T	N64	6	1125	1	275:K
S	T	N64	6	1126	1	274:B
S	T	N64	6	1127	1	273:L
S	T	N67	1	1264	1	16:D
S	T	N67	1	1265	1	15:B
S	T	N67	1	1266	1	14:B
S	T	N67	1	1267	1	13:B
S	T	N67	1	1268	1	12:B
S	T	N67	1	1269	1	11:D
S	T	N67	1	1270	1	10:D
S	T	N67	1	1271	1	9:D
S	T	N67	1	1272	1	8:K
S	T	N67	1	1273	1	7:K
S	T	N67	1	1274	1	6:K
S	T	N67	1	1275	1	5:B
S	T	N67	1	1276	1	4:K
S	T	N67	1	1277	1	3:K
S	T	N67	1	1278	1	2:B
S	T	N67	1	1279	1	1:L
S	T	N67	2	1176	1	64:D
S	T	N67	2	1177	1	63:L
S	T	N67	2	1178	1	62:K
S	T	N67	2	1179	1	61:K
S	T	N67	2	1180	1	60:B

種別	分割	指示	シーン	初期状態	件数	ID: 部屋
S	T	N67	2	1181	1	59:B
S	T	N67	2	1182	1	58:D
S	T	N67	2	1183	1	57:K
S	T	N67	2	1184	1	56:D
S	T	N67	2	1185	1	55:K
S	T	N67	2	1186	1	54:B
S	T	N67	2	1187	1	53:D
S	T	N67	2	1188	1	52:L
S	T	N67	2	1189	1	51:B
S	T	N67	2	1190	1	50:K
S	T	N67	2	1191	1	49:D
S	T	N67	3	1212	1	120:D
S	T	N67	3	1213	1	119:B
S	T	N67	3	1214	1	118:D
S	T	N67	3	1215	1	117:L
S	T	N67	3	1216	1	116:D
S	T	N67	3	1217	1	115:L
S	T	N67	3	1218	1	114:K
S	T	N67	3	1219	1	113:L
S	T	N67	3	1220	1	112:D
S	T	N67	3	1221	1	111:D
S	T	N67	3	1222	1	110:D
S	T	N67	3	1223	1	109:K
S	T	N67	3	1224	1	108:D
S	T	N67	3	1225	1	107:D
S	T	N67	3	1226	1	106:K
S	T	N67	3	1227	1	105:D
S	T	N67	3	1228	1	104:B
S	T	N67	3	1229	1	103:K
S	T	N67	3	1230	1	102:B
S	T	N67	3	1231	1	101:K
S	T	N67	3	1232	1	100:K
S	T	N67	3	1233	1	99:L
S	T	N67	3	1234	1	98:L
S	T	N67	3	1235	1	97:K
S	T	N67	3	1236	1	96:L
S	T	N67	3	1237	1	95:B
S	T	N67	3	1238	1	94:K
S	T	N67	3	1239	1	93:K
S	T	N67	3	1240	1	92:K
S	T	N67	3	1241	1	91:L
S	T	N67	3	1242	1	90:D
S	T	N67	3	1243	1	89:L
S	T	N67	4	182	1	176:K
S	T	N67	4	183	1	175:B
S	T	N67	4	184	1	174:L
S	T	N67	4	185	1	173:K
S	T	N67	4	186	1	172:B
S	T	N67	4	187	1	171:D
S	T	N67	4	188	1	170:B
S	T	N67	4	189	1	169:L
S	T	N67	4	190	1	168:D
S	T	N67	4	191	1	167:B
S	T	N67	4	192	1	166:K
S	T	N67	4	193	1	165:K
S	T	N67	4	194	1	164:D
S	T	N67	4	195	1	163:L
S	T	N67	4	196	1	162:B
S	T	N67	4	197	1	161:D
S	T	N67	5	111	1	208:D
S	T	N67	5	112	1	207:K
S	T	N67	5	113	1	206:K
S	T	N67	5	114	1	205:L
S	T	N67	5	115	1	204:D
S	T	N67	5	116	1	203:K
S	T	N67	5	117	1	202:B
S	T	N67	5	118	1	201:D
S	T	N67	5	119	1	200:B
S	T	N67	5	120	1	199:D
S	T	N67	5	121	1	198:L
S	T	N67	5	122	1	197:L
S	T	N67	5	123	1	196:L
S	T	N67	5	124	1	195:K
S	T	N67	5	125	1	194:B
S	T	N67	5	126	1	193:L
S	T	N67	6	1244	1	252:D
S	T	N67	6	1245	1	251:B
S	T	N67	6	1246	1	250:D
S	T	N67	6	1247	1	249:D
S	T	N67	6	1248	1	248:L
S	T	N67	6	1249	1	247:B
S	T	N67	6	1250	1	246:L
S	T	N67	6	1251	1	245:B
S	T	N67	6	1252	1	244:K
S	T	N67	6	1253	1	243:B
S	T	N67	6	1254	1	242:L
S	T	N67	6	1255	1	241:K
S	T	N67	6	1256	1	240:K
S	T	N67	6	1257	1	239:D
S	T	N67	6	1258	1	238:L
S	T	N67	6	1259	1	237:K
S	T	N67	7	1196	1	292:K
S	T	N67	7	1197	1	291:L
S	T	N67	7	1198	1	290:L
S	T	N67	7	1199	1	289:K
S	T	N67	7	1200	1	288:D
S	T	N67	7	1201	1	287:K
S	T	N67	7	1202	1	286:D
S	T	N67	7	1203	1	285:L
S	T	N67	7	1204	1	284:K
S	T	N67	7	1205	1	283:K
S	T	N67	7	1206	1	282:B
S	T	N67	7	1207	1	281:L
S	T	N67	7	1208	1	280:L
S	T	N67	7	1209	1	279:K
S	T	N67	7	1210	1	278:L
S	T	N67	7	1211	1	277:D
S	T	N69	1	1148	1	20:K
S	T	N69	1	1149	1	19:K
S	T	N69	1	1150	1	18:D
S	T	N69	1	1151	1	17:B
S	T	N69	5	128	1	212:B
S	T	N69	5	129	1	211:B
S	T	N69	5	130	1	210:L
S	T	N69	5	131	1	209:D
S	T	N69	6	1124	1	256:K
S	T	N69	6	1125	1	255:L

種別	分割	指示	シーン	初期状態	件数	ID: 部屋
S	T	N69	6	I126	1	254:L
S	T	N69	6	I127	1	253:L

D. 実シーンでの入力と行動前後の変化

構成要素比較の C1・GPT-4o・反復 0 から、状態変化 task6 と配置 task65 を固定して示す。結果の良否による選び直しは行わない。これは基本性能評価の未保存入力を復元したものではなく、付録の合成例とも異なる実際の観測である。以下の環境文は最初の終了判定へ送信した全文から末尾の判定指示のみを除いたもので、重複した and 等も保持した。

D.1 状態変化 task6

人物の初期位置は [-2.41545, 1.25, -7.44353151] である。

Listing 13

最初の判定へ送信した環境知識全文

1 The current states in the home are as follows:
2 The lightswitch (71) is ON and and is INSIDE the bathroom (11).
3 The lightswitch (173) is OFF and and is INSIDE the bedroom (73).
4 The lightswitch (261) is ON and and is INSIDE the kitchen (205).
5 The lightswitch (427) is OFF and and is INSIDE the livingroom (335).
6 You are INSIDE the kitchen (205).

表 D.27: 初期グラフの対象・人物からの関係抜粋

始点 ID	クラス	関係	終点 ID	クラス
71	lightswitch	INSIDE	11	bathroom
173	lightswitch	INSIDE	73	bedroom
261	lightswitch	INSIDE	205	kitchen
427	lightswitch	INSIDE	335	livingroom
1	character	INSIDE	205	kitchen
1	character	CLOSE	175	cpuscreen
1	character	CLOSE	230	tvstand
1	character	CLOSE	232	bench
1	character	CLOSE	249	bookshelf
1	character	CLOSE	253	rug
1	character	CLOSE	260	orchid
1	character	CLOSE	264	tv
1	character	CLOSE	286	clothespile
1	character	CLOSE	287	box
1	character	CLOSE	288	dishbowl
1	character	CLOSE	289	book
1	character	CLOSE	290	book
1	character	CLOSE	291	book
1	character	CLOSE	292	book
1	character	CLOSE	293	book
1	character	CLOSE	294	condimentbottle
1	character	CLOSE	295	condimentbottle
1	character	CLOSE	296	condimentshaker
1	character	CLOSE	297	condimentshaker
1	character	CLOSE	298	wineglass
1	character	CLOSE	302	paper
1	character	CLOSE	303	paper
1	character	CLOSE	315	bananas
1	character	CLOSE	316	bananas
1	character	CLOSE	317	dishbowl

関係変化の +/- は追加／削除を表し、対象辞書内の物体と人物を始点とする ON・INSIDE・保持・CLOSE に限定する。座標変化そのものや無関係な辺は省略する。

表 D.28: 行動と状態・関係の変化

step	実行行動	VH	変化
1	[WALK] <lightswitch> (173)	成功	- (1, 'CLOSE', 230); - (1, 'CLOSE', 232); - (1, 'CLOSE', 253); - (1, 'CLOSE', 260); - (1, 'CLOSE', 264); - (1, 'CLOSE', 287); - (1, 'CLOSE', 298); - (1, 'CLOSE', 303); - (1, 'CLOSE', 315); - (1, 'CLOSE', 316); - (1, 'CLOSE', 317); - (1, 'INSIDE', 205); + (1, 'CLOSE', 107); + (1, 'CLOSE', 108); + (1, 'CLOSE', 172); + (1, 'CLOSE', 173); + (1, 'CLOSE', 174); + (1, 'CLOSE', 193); + (1, 'CLOSE', 194); + (1, 'CLOSE', 195); + (1, 'CLOSE', 196); + (1, 'CLOSE', 261); + (1, 'CLOSE', 262); + (1, 'CLOSE', 263); + (1, 'CLOSE', 265); + (1, 'INSIDE', 73); + (173, 'CLOSE', 1); + (261, 'CLOSE', 1)
2	[SWITCHON] <lightswitch> (173)	成功	173: OFF -> ON
3	[WALK] <lightswitch> (261)	成功	- (1, 'CLOSE', 107); - (1, 'CLOSE', 108); - (1, 'CLOSE', 172); - (1, 'CLOSE', 174); - (1, 'CLOSE', 175); - (1, 'CLOSE', 193); - (1, 'CLOSE', 194); - (1, 'CLOSE', 195); - (1, 'CLOSE', 196); - (1, 'CLOSE', 249); - (1, 'CLOSE', 286); - (1, 'CLOSE', 288); - (1, 'CLOSE', 289); - (1, 'CLOSE', 290); - (1, 'CLOSE', 291); - (1, 'CLOSE', 292); - (1, 'CLOSE', 293); - (1, 'CLOSE', 294); - (1, 'CLOSE', 295); - (1, 'CLOSE', 296); - (1, 'CLOSE', 297); - (1, 'CLOSE', 302); - (1, 'INSIDE', 73); + (1, 'CLOSE', 178); + (1, 'CLOSE', 229); + (1, 'CLOSE', 231); + (1, 'CLOSE', 233); + (1, 'CLOSE', 252); + (1, 'CLOSE', 253); + (1, 'CLOSE', 254); + (1, 'CLOSE', 255); + (1, 'CLOSE', 256); + (1, 'CLOSE', 268); + (1, 'CLOSE', 270); + (1, 'CLOSE', 271); + (1, 'CLOSE', 272); + (1, 'CLOSE', 273); + (1, 'CLOSE', 278); + (1, 'CLOSE', 279); + (1, 'CLOSE', 280); + (1, 'CLOSE', 281); + (1, 'CLOSE', 319); + (1, 'INSIDE', 205)
4	[WALK] <lightswitch> (427)	成功	- (1, 'CLOSE', 173); - (1, 'CLOSE', 178); - (1, 'CLOSE', 229); - (1, 'CLOSE', 231); - (1, 'CLOSE', 233); - (1, 'CLOSE', 252); - (1, 'CLOSE', 253); - (1, 'CLOSE', 254); - (1, 'CLOSE', 255); - (1, 'CLOSE', 256); - (1, 'CLOSE', 261); - (1, 'CLOSE', 262); - (1, 'CLOSE', 263); - (1, 'CLOSE', 265); - (1, 'CLOSE', 268); - (1, 'CLOSE', 270); - (1, 'CLOSE', 271); - (1, 'CLOSE', 272); - (1, 'CLOSE', 273); - (1, 'CLOSE', 278); - (1, 'CLOSE', 279); - (1, 'CLOSE', 280); - (1, 'CLOSE', 281); - (1, 'CLOSE', 319); - (1, 'INSIDE', 205); - (173, 'CLOSE', 1); - (261, 'CLOSE', 1); + (1, 'CLOSE', 251); + (1, 'CLOSE', 332); + (1, 'CLOSE', 333); + (1, 'CLOSE', 334); + (1, 'CLOSE', 415); + (1, 'CLOSE', 418); + (1, 'CLOSE', 420); + (1, 'CLOSE', 427); + (1, 'CLOSE', 428); + (1, 'CLOSE', 453); + (1, 'INSIDE', 335); + (427, 'CLOSE', 1)
5	[SWITCHON] <lightswitch> (427)	成功	427: OFF -> ON; + (1, 'CLOSE', 258)

D・2 配置 task65

人物の初期位置は [9.582918, 1.25, -4.21981239] である。

Listing 14

最初の判定へ送信した環境知識全文

```
1 The current states in the home are as follows:
2 The plum (53) is ON the kitchencounter (92) and and is INSIDE the kitchen (11).
3 The plum (54) is ON the kitchencounter (92) and and is INSIDE the kitchen (11).
4 The fridge (103) is CLOSED and and is INSIDE the kitchen (11).
5 The kitchencounter (92) is CLOSED and is INSIDE the dishwasher (104) and and is INSIDE the kitchen (11).
6 plum (53) and plum (54) are ON the kitchencounter (92).
7 You are INSIDE the bedroom (211).
```

表 D.29: 初期グラフの対象・人物からの関係抜粋

始点 ID	クラス	関係	終点 ID	クラス
53	plum	INSIDE	11	kitchen
54	plum	INSIDE	11	kitchen
92	kitchencounter	INSIDE	11	kitchen
103	fridge	INSIDE	11	kitchen
1	character	INSIDE	211	bedroom
53	plum	ON	92	kitchencounter
54	plum	ON	92	kitchencounter
92	kitchencounter	ON	19	floor
92	kitchencounter	INSIDE	104	dishwasher
1	character	CLOSE	214	desk
1	character	CLOSE	217	cabinet
1	character	CLOSE	218	lightswitch
1	character	CLOSE	231	apple
1	character	CLOSE	232	apple
1	character	CLOSE	233	apple
1	character	CLOSE	234	apple
1	character	CLOSE	235	apple
1	character	CLOSE	236	apple
1	character	CLOSE	237	apple

—— 著 者 紹 介 ——



青山 仁

2023 年青山学院大学理工学部情報テクノロジー学科卒業。同年 7 月から 2025 年 3 月まで、産業技術総合研究所リサーチアシスタント。同年同大学院理工学研究科前期博士課程修了。在学時に本研究に従事。現在に至る。



チャクラボルティ シュデシナ

2023 年カナダのウェスタンオンタリオ大学医学部神経科学プログラム大学院博士課程修了。同年、ウェスタンオンタリオ大学 Robart Research Institute 客員研究員。2024 年より青山学院大学理工学部情報テクノロジー学科助教。現在に至る。博士（神経科学）。脳 MRI 画像を用いた認知神経科学研究に従事。Organization for Human Brain Mapping 会員。



森田 武史(正会員)

2008 年慶應義塾大学大学院理工学研究科後期博士課程修了。同年、日本学術振興会特別研究員 (PD)。2009 年慶應義塾大学大学院理工学研究科特別研究助教。2011 年青山学院大学社会情報学部助手。2014 年同助教。2015 年慶應義塾大学理工学部管理工学科専任講師 (有期)。2019 年同准教授 (有期)。2020 年より青山学院大学理工学部情報テクノロジー学科准教授。2023 年同教授。現在に至る。2022 年より産業技術総合研究所人工知能研究センターの招聘研究員を兼任。博士 (工学)。セマンティック Web とオントロジーに関する研究に従事。情報システム学会、ACM、日本データベース学会、電子情報通信学会、情報処理学会、言語処理学会の各会員。



江上 周作(正会員)

2018 年日本学術振興会特別研究員 (DC2)。2019 年電気通信大学大学院情報理工学研究科博士後期課程修了。同年海上・港湾・航空技術研究所研究員。2020 年より産業技術総合研究所研究員。2023 年より同研究所人工知能研究センター主任研究員。現在に至る。2019 年より法政大学理工学部兼任講師。2023 年より電気通信大学大学院情報理工学研究科連携准教授を兼任。博士 (工学)。セマンティック Web、オントロジー、知識グラフの構築と活用の研究に従事。2018 年度、2022 年度人工知能学会研究会優秀賞。2022 年度同学会全国大会優秀賞。ISWC2021 Best Poster Award。言語処理学会、情報処理学会、IEEE、ACM、IAOA の各会員。



鵜飼 孝典(正会員)

1992 年 3 月東京工業大学大学院理工学研究科修士課程修了。2013 年東京工業大学大学院情報理工学研究科博士課程修了。1992 年より 2026 年 7 月まで富士通株式会社研究員。2026 年 8 月より産業技術総合研究所招聘研究員。博士 (工学)。専門は知識グラフ、グラフ・ニューラル・ネットワーク、要求工学、人工知能学会、情報処理学会の各会員。



福田 賢一郎(正会員)

2001 年東京大学大学院理学系研究科情報科学専攻博士後期課程修了。2000 年日本学術振興会特別研究員。2001 年より産業技術総合研究所研究員。2020 年より同人工知能研究センター研究チーム長。現在に至る。2023 年より電気通信大学大学院情報理工学研究科連携教授を兼任。2024 年より東北大学非常勤講師。博士 (理学)。専門は知識表現、人工知能、サービス工学、バイオインフォマティクス。人間の日常生活、とりわけ人と環境、エージェント、サービスの間のインタラクションで構成される生活活動の知識表現、実世界に埋め込まれる人工知能の研究に従事。2015 年電気情報通信学会優秀研究賞、2016 年情報処理学会優秀発表賞、2017 年、2023 年人工知能学会研究会優秀賞。HCI2021 Best Paper Award, ISWC2021 Best Poster Award。サービス学会、ACM、OMG Robotics DTF の各会員。